UNIVERSIDAD SANTO TOMÁS
PROYECTO DE GRADO — ESTADÍSTICA

ESTADO DEL ARTE, MARCO TEÓRICO, DISEÑO METODOLÓGICO Y DIVISIÓN DE TRABAJO

INFORME 1 — VERSIÓN INTEGRADA

Contratación pública y vulnerabilidad socioeconómica municipal en Colombia

Pregunta central:
¿Existe una correspondencia entre la distribución territorial de la contratación pública y las condiciones de vulnerabilidad socioeconómica de los municipios colombianos?

Juan Diego Gallo Quintero
Juan David Parada Fonseca

Programa de Estadística — Octavo semestre
Documento de trabajo académico — Primer informe integrado
Septiembre de 2026

Este documento integra, en una sola versión, el estado del arte y marco teórico del proyecto, el diseño metodológico de muestreo estadístico ya definido para su ejecución, y la división de trabajo entre los dos integrantes de la pareja de investigación, articulada con el diagrama de flujo del proyecto.

Índice

1 Alcance y decisiones de investigación **3**

2 Verificación inicial del repositorio y ventana temporal **3**

3 Estado del arte **4**
3.1 Desigualdad territorial, gasto público y desarrollo regional 4
3.2 Pobreza multidimensional y vulnerabilidad territorial 4
3.3 Contratación pública como instrumento de política territorial 5
3.4 SECOP II y análisis estadístico de datos abiertos en Colombia 5
3.5 Estadística espacial y brechas territoriales 6
3.6 Síntesis crítica y vacío de investigación 6

4 Matriz bibliográfica inicial **6**

5 Marco teórico **7**
5.1 Desarrollo territorial y desigualdad 7
5.2 Pobreza multidimensional y vulnerabilidad socioeconómica 7
5.3 Índices sintéticos y PCA 8
5.4 Contratación pública como distribución de recursos 8
5.5 Asociación, correspondencia y brechas 8
5.6 Dependencia espacial 9
5.7 Estructura temporal y datos de panel 9

6 Modelo conceptual de investigación **9**

7 Variables y operacionalización preliminar **9**

8 Hipótesis de trabajo **10**

9 Diseño metodológico: integración de muestreo estadístico **10**
9.1 Naturaleza poblacional de los datos y necesidad del muestreo 10
9.2 Justificación del diseño muestral seleccionado: por qué muestreo aleatorio estratificado 11
9.3 Procedimiento 1: auditoría de calidad de SECOP II mediante muestreo estratificado 12
9.4 Procedimiento 2: validación del Índice de Vulnerabilidad mediante *bootstrap* 13
9.5 Procedimiento 3: prueba de permutación para la correspondencia vulnerabilidad–contratación 15
9.6 Línea de trabajo futuro: diseño muestral para validación externa 16
9.7 Integración de los procedimientos en el flujo de fases del proyecto 17

10 Limitaciones previstas **17**

11 Agenda de investigación inmediata **18**

12 División de trabajo entre integrantes **18**
12.1 Principio de división 18

12.2 Responsable: Juan Diego Gallo Quintero — Eje de Vulnerabilidad 19
12.3 Responsable: Juan David Parada Fonseca — Eje de Contratación 20
12.4 Trabajo conjunto — Fases 6 a 10 20
12.5 Regla de coordinación 21

13 Nota metodológica sobre originalidad **21**

14 Referencias bibliográficas — APA 7 **22**

1. Alcance y decisiones de investigación

Este documento constituye la primera versión integrada del estado del arte, el marco teórico, el diseño metodológico (incluyendo el componente de muestreo estadístico) y la división de trabajo para un proyecto de grado orientado a estudiar la correspondencia entre la contratación pública y la vulnerabilidad socioeconómica de los municipios colombianos. El proyecto toma como punto de partida el repositorio público `desarrollo_social_y_economico` de la Universidad Santo Tomás, pero no lo considera un trabajo propio ni un límite metodológico: el objetivo es desarrollar una investigación original, reproducible y estadísticamente rigurosa.

La unidad principal de análisis será el municipio, siempre que la calidad y disponibilidad de los datos permitan la integración territorial. El nivel departamental se utilizará como apoyo para contextualización y visualización. La contratación pública será caracterizada mediante el número de contratos y su valor monetario, complementados por modalidad de contratación, sector, tipo de contrato y duración. La vulnerabilidad socioeconómica se conceptualizará a partir del enfoque multidimensional del DANE y se estudiará la construcción de un índice sintético basado en el Índice de Pobreza Multidimensional (IPM), con PCA como técnica estadística central.

El análisis no buscará establecer causalidad. El alcance inferencial se limitará a estudiar asociación, correspondencia y brechas territoriales. El análisis espacial será incorporado cuando los diagnósticos de dependencia espacial lo justifiquen, y el componente de muestreo estadístico — ya definido y detallado en la Sección 9 — se incorpora para resolver dos problemas metodológicos concretos: la auditoría de calidad de un histórico de gran volumen y la validación de la estabilidad de las estimaciones.

2. Verificación inicial del repositorio y ventana temporal

La revisión directa del repositorio muestra que su componente de datos documenta un histórico de procesos SECOP II organizado trimestralmente. El notebook `Historico_de_Datos.ipynb` registra trimestres desde el segundo trimestre de 2015 hasta el cuarto trimestre de 2025, aunque este último trimestre está disponible solo hasta el 5 de octubre en la ejecución registrada. El histórico reporta 7.827.129 registros y 59 variables, con última fecha de publicación 2025-10-05 en la ejecución consultada.

Por tanto, la ventana potencial de contratación disponible en el repositorio es aproximadamente 2015–2025. Sin embargo, esto no significa que todos los años sean igualmente comparables: será necesario revisar cobertura municipal, cambios de variables, calidad de identificación territorial y posibles cambios en el sistema de contratación antes de fijar la ventana definitiva del estudio — verificación que, precisamente, se formaliza mediante el muestreo estratificado de auditoría descrito en la Sección 9.

El README del repositorio indica que la fuente de contratación es SECOP y que la integración con DANE 2018 fue concebida inicialmente con departamentos y, si era posible, municipios. También señala que la información de SECOP se descarga mediante API/CSV y se organiza en archivos Parquet para facilitar el tratamiento de grandes volúmenes.

Decisión metodológica

Se utilizará 2015–2025 como ventana de exploración del componente contractual, pero el periodo analítico definitivo se seleccionará después de auditar la cobertura y armonización de las variables socioeconómicas. Esta decisión evita forzar una comparabilidad temporal que los datos de DANE podrían no sostener.

3. Estado del arte

3.1. Desigualdad territorial, gasto público y desarrollo regional

La literatura colombiana ha mostrado históricamente que las diferencias territoriales en ingreso, capacidad fiscal y prestación de servicios son persistentes. Ardila-Rueda (2004) estudió la convergencia del ingreso per cápita departamental y el papel del consumo e inversión pública, encontrando una alta persistencia en la distribución del ingreso y efectos del gasto público — especialmente de la inversión — sobre la posición relativa de algunos departamentos, sin que ello implicara una transformación completa de la distribución territorial.

Bonet-Morón (2006) analizó los desequilibrios de la descentralización y mostró diferencias importantes en ingresos fiscales per cápita y en las condiciones de provisión de servicios entre entidades territoriales. Su argumento es especialmente relevante para este proyecto porque advierte que la descentralización y las transferencias no garantizan por sí mismas equidad territorial.

Estos antecedentes establecen una primera base conceptual: la distribución de recursos públicos debe analizarse en relación con las características estructurales de los territorios y no solamente en términos de montos absolutos. Para el presente proyecto, esto justifica la utilización de medidas per cápita y medidas relativas, además del valor total de contratación.

3.2. Pobreza multidimensional y vulnerabilidad territorial

El enfoque de pobreza multidimensional constituye una referencia central para operacionalizar la vulnerabilidad socioeconómica. El DANE adopta una medición multidimensional que integra dimensiones y privaciones relacionadas con las condiciones de vida. A nivel municipal, la fuente censal de 2018 permite disponer de una medida territorial de IPM con amplia cobertura municipal.

El uso del IPM resulta especialmente pertinente porque permite evitar una definición unidimensional de vulnerabilidad basada exclusivamente en ingreso. No obstante, el proyecto va un paso más allá: el IPM será el núcleo conceptual del indicador, mientras que variables adicionales disponibles y compatibles se evaluarán mediante PCA para construir un índice sintético de vulnerabilidad socioeconómica municipal.

Un antecedente reciente particularmente cercano al componente territorial es Monsalvo Herrera y Jiménez (2025), quienes analizaron el IPM en municipios de Cundinamarca mediante indicadores locales de asociación espacial (LISA). El estudio encontró agrupamientos espaciales de pobreza y plantea la relevancia del efecto vecindario para orientar acciones de política pública. Este antecedente es directamente útil para justificar que, si los diagnósticos lo respaldan, el proyecto incorpore estadística espacial.

3.3. Contratación pública como instrumento de política territorial

La contratación pública puede interpretarse no solo como una actividad administrativa de compra de bienes y servicios, sino como un mecanismo mediante el cual el Estado canaliza recursos hacia territorios, sectores y proveedores. La literatura internacional reciente ha estudiado explícitamente esta dimensión territorial. Ferry et al. (2023) analizaron más de 90.000 contratos de autoridades locales del Reino Unido y encontraron diferencias regionales en la selección de proveedores, planteando que la contratación puede tener una dimensión territorial asociada al desarrollo regional.

Arachia et al. (2024), a partir de más de 50.000 contratos de obras públicas municipales en Italia, estudiaron la cooperación intermunicipal mediante modelos de efectos fijos y estimadores de *matching*. Sus resultados muestran que la forma institucional de organizar la contratación puede relacionarse con resultados de ejecución. Aunque el contexto institucional es distinto al colombiano, el estudio es útil para mostrar que la contratación municipal puede analizarse estadísticamente como fenómeno territorial y no únicamente jurídico.

Sarter (2024) plantea una relación multidimensional entre contratación pública y desigualdad laboral, argumentando que el objeto comprado, los requisitos del proceso y el tipo de proveedor pueden afectar resultados distributivos. Este marco apoya la decisión de no limitar el análisis a los montos, sino incorporar modalidad, sector, tipo de contrato y características de ejecución.

Rodriguez-Plesa et al. (2022) muestran, desde la contratación pública sostenible a nivel local, que las compras gubernamentales pueden utilizarse estratégicamente para abordar objetivos sociales, económicos y ambientales. Para el presente proyecto, esto fortalece la interpretación de la contratación como instrumento potencial de política pública, aunque no permite asumir que todo gasto contractual tenga un efecto social positivo.

3.4. SECOP II y análisis estadístico de datos abiertos en Colombia

La disponibilidad de SECOP II permite estudiar la contratación pública con microdatos administrativos. El conjunto de contratos electrónicos identifica información sobre entidades, ubicación, fechas, sectores, valores y otras características del contrato. El repositorio estudiado utiliza esta fuente y ha construido un proceso de extracción trimestral y consolidación histórica.

En Colombia, Figueroa-Gómez y Galpin (2024) utilizaron datos abiertos de SECOP II para desarrollar modelos de clasificación destinados a identificar procesos de contratación de interés, señalando que la investigación aplicada a contratación pública colombiana todavía se encuentra en una etapa de desarrollo. Salazar, Pérez y Gallego (2024) desarrollaron VigIA, una herramienta basada en datos abiertos de SECOP II para detectar ineficiencias y construir índices de riesgo; su unidad de análisis y objetivo se concentran en riesgo e ineficiencia contractual, no en correspondencia socioeconómica territorial. Gutiérrez Vanegas (2024) utilizó *Isolation Forest* sobre datos abiertos de SECOP II para identificar banderas rojas asociadas con periodos inusualmente cortos, valores anómalos y procesos con una sola oferta; nuevamente, el problema de investigación es la detección de anomalías y no la equidad territorial.

Díaz Díez (2023) analiza el carácter transaccional de SECOP II y su relación con los principios de publicidad y transparencia. Desde la perspectiva del proyecto, esta literatura ayuda a comprender la naturaleza institucional de la fuente y sus limitaciones, evitando interpretar los datos de SECOP como una medición directa del desarrollo social.

3.5. Estadística espacial y brechas territoriales

La dimensión espacial es relevante porque municipios próximos pueden compartir condiciones económicas, sociales, geográficas e institucionales. El estudio de Monsalvo Herrera y Jiménez (2025) evidencia que el IPM municipal puede presentar patrones de dependencia espacial y agrupamientos identificables mediante LISA. Esto sugiere que la correlación convencional entre vulnerabilidad y contratación podría ser insuficiente si existe autocorrelación espacial.

En consecuencia, el análisis espacial no se asumirá automáticamente como una técnica decorativa. La secuencia metodológica será: primero, diagnóstico de autocorrelación espacial; después, si existe evidencia suficiente, incorporación de modelos o indicadores espaciales. Esta regla es coherente con una práctica estadística rigurosa y evita sobreajustar el proyecto a técnicas avanzadas sin necesidad.

3.6. Síntesis crítica y vacío de investigación

La revisión muestra cuatro cuerpos de literatura parcialmente conectados. Primero, la investigación sobre desigualdad regional colombiana documenta disparidades persistentes y diferencias en capacidad fiscal y prestación de servicios. Segundo, la literatura sobre pobreza multidimensional permite operacionalizar condiciones de vulnerabilidad con una perspectiva territorial. Tercero, la literatura sobre contratación pública reconoce que la compra estatal puede ser un instrumento de política y que sus características pueden tener implicaciones distributivas. Cuarto, la literatura reciente sobre SECOP II demuestra el potencial de los datos abiertos para estadística, aprendizaje automático y control de riesgos.

Sin embargo, en la revisión inicial no se identificó un estudio que integre de manera sistemática, a escala nacional y con unidad municipal, un índice multidimensional de vulnerabilidad construido desde el IPM/PCA con medidas de contratación pública y un análisis conjunto de asociación, correspondencia y brechas territoriales. Los trabajos encontrados sobre SECOP II se concentran principalmente en riesgo, eficiencia, clasificación o detección de anomalías; los trabajos sobre pobreza territorial estudian la distribución y dependencia espacial de la pobreza, pero no la correspondencia con la distribución de contratos públicos.

Este vacío es provisional y deberá comprobarse mediante una revisión bibliográfica más exhaustiva en Scopus, Web of Science, SciELO, Redalyc y repositorios universitarios. No obstante, constituye una justificación razonable para la pregunta central del proyecto.

4. Matriz bibliográfica inicial

Referencia	Datos y unidad	Método	Resultado principal	Limitación / utilidad
Ardila-Rueda (2004)	Ingreso departamental + gasto público; Colombia	Análisis de dinámica distributiva	Persistencia regional; la inversión afecta posiciones relativas	Antiguo, nivel departamental; fundamenta relación gasto–territorio
Bonet-Morón (2006)	Ingresos fiscales, transferencias, servicios; departamentos/municipios	Análisis fiscal regional	Persisten desigualdades fiscales y de servicios	Antiguo; justifica medidas relativas y equidad territorial

Referencia	Datos y unidad	Método	Resultado principal	Limitación / utilidad
Rodriguez-Plesa et al. (2022)	Contratación sostenible local; EE. UU./internacional	Indicadores/modelos institucionales	La compra pública puede perseguir objetivos sociales/económicos	No estudia vulnerabilidad municipal; marco de contratación como política pública
Ferry et al. (2023)	90.000 contratos 2015–2019; autoridades locales, Reino Unido	Análisis cuantitativo regional	Existen patrones territoriales de selección de proveedores	Contexto institucional distinto; aporta dimensión territorial de contratación
Sarter (2024)	Literatura sobre contratación; procesos/proveedores	Marco conceptual	Objeto, proceso y proveedor pueden afectar desigualdad laboral	No es estudio municipal colombiano; justifica variables contractuales
Arachia et al. (2024)	50.905 contratos de obras; municipios, Italia	Efectos fijos + *matching*	Cooperación intermunicipal se relaciona con desempeño	No estudia pobreza; referencia para panel/municipios
Figueroa-Gómez & Galpin (2024)	SECOP II; procesos de contratación, Colombia	Modelos de clasificación	Potencial de ML sobre contratación pública	Enfoque en licitaciones de interés; antecedente de ciencia de datos
Salazar et al. (2024)	SECOP II + sanciones; contratos, Colombia	ML + índices de riesgo	Detección de ineficiencias y riesgos	No estudia vulnerabilidad territorial; referencia metodológica para índices
Gutiérrez Vanegas (2024)	SECOP II; contratos, Colombia	*Isolation Forest*	Detección de banderas rojas	Trabajo de grado, foco en anomalías; referencia de ML aplicado a SECOP II
Díaz Díez (2023)	SECOP II y normativa; sistema de contratación, Colombia	Análisis jurídico	SECOP II es transaccional y fortalece publicidad/transparencia	No es análisis estadístico; marco institucional de la fuente
Monsalvo Herrera & Jiménez (2025)	IPM municipal; municipios de Cundinamarca, Colombia	LISA/análisis espacial	Agrupamientos espaciales de pobreza	Cobertura regional; justifica diagnóstico espacial
DANE (2018/2024)	CNPV/IPM; municipios, Colombia	Medición multidimensional	Base oficial de condiciones de vida	Cobertura temporal no anual; núcleo del índice de vulnerabilidad

5. Marco teórico

5.1. Desarrollo territorial y desigualdad

El desarrollo territorial se entiende aquí como un proceso diferenciado espacialmente en el que interactúan condiciones económicas, sociales, institucionales y de provisión de bienes públicos. La desigualdad territorial implica que los municipios enfrentan capacidades y necesidades diferentes, por lo que la comparación de recursos públicos debe considerar el tamaño poblacional y las condiciones socioeconómicas.

5.2. Pobreza multidimensional y vulnerabilidad socioeconómica

El IPM proporciona una base conceptual para reconocer que el bienestar no puede reducirse al ingreso. Para este proyecto, vulnerabilidad socioeconómica será un concepto operativo más

amplio que pobreza: representará un conjunto de privaciones o condiciones estructurales que pueden limitar el desarrollo de la población municipal. El IPM será el referente principal y las variables adicionales solo se incorporarán cuando exista respaldo conceptual, calidad estadística y disponibilidad comparable.

5.3. Índices sintéticos y PCA

Un índice sintético busca resumir múltiples variables correlacionadas en una medida interpretable. El PCA permite transformar un conjunto de variables estandarizadas en componentes ortogonales que maximizan la varianza explicada. Si Z representa la matriz estandarizada de indicadores, la descomposición puede expresarse como:

$$Z = U\Lambda V'$$

La construcción del índice no se decidirá únicamente por la mayor varianza explicada. Se evaluarán correlaciones, adecuación muestral, cargas, signos, estabilidad y coherencia sustantiva. También se invertirán las variables cuyo aumento represente menor vulnerabilidad, para asegurar que la dirección del índice sea consistente. La estabilidad del índice — signos, magnitudes relativas y varianza explicada — se valida formalmente mediante remuestreo *bootstrap*, descrito en la Sección 9.4.

5.4. Contratación pública como distribución de recursos

Para el análisis, la contratación pública se operacionalizará mediante al menos cuatro familias de indicadores: magnitud monetaria, frecuencia contractual, estructura contractual y temporalidad. Entre los indicadores candidatos se encuentran valor total, número de contratos, valor per cápita, valor mediano, ticket promedio, participación sectorial, distribución por modalidad y duración.

El valor per cápita será especialmente importante porque un valor absoluto elevado puede reflejar simplemente mayor población. La comparación entre municipios requiere, por tanto, medidas que controlen al menos parcialmente el tamaño poblacional.

5.5. Asociación, correspondencia y brechas

La asociación se refiere a la relación estadística entre vulnerabilidad y contratación. Se utilizarán correlaciones de Pearson o Spearman según escala, distribución y supuestos, complementadas con modelos multivariados y, como verificación no paramétrica, con la prueba de permutación descrita en la Sección 9.5.

La correspondencia será un concepto analítico distinto: no preguntará solamente si dos variables se mueven juntas, sino si la intensidad de contratación resulta proporcional o compatible con la posición relativa de vulnerabilidad de los municipios. Se estudiarán diferentes definiciones de correspondencia y se seleccionará aquella que pueda justificarse estadísticamente.

Las brechas territoriales identificarán municipios cuyo nivel de contratación observado sea bajo o alto respecto de lo esperado según su vulnerabilidad y otras características relevantes. El lenguaje será deliberadamente prudente: una brecha no significará automáticamente ineficiencia, corrupción o mala política pública.

5.6. Dependencia espacial

La estadística espacial será utilizada si existe evidencia de dependencia espacial. Se evaluará Moran global y, posteriormente, indicadores locales LISA. Si la dependencia espacial afecta los residuos de un modelo, podrán considerarse modelos espaciales como SAR/lag, SEM o SDM, según diagnóstico y factibilidad.

5.7. Estructura temporal y datos de panel

La disponibilidad de contratación desde 2015 hasta 2025 permite explorar una estructura municipio–año. Cuando las variables socioeconómicas no tengan frecuencia anual, no se imputará artificialmente su evolución; la solución se definirá después de auditar la disponibilidad de indicadores. Si existe suficiente variación temporal, los modelos de panel con efectos fijos o aleatorios se evaluarán mediante pruebas y criterios de especificación.

6. Modelo conceptual de investigación

La estructura conceptual del proyecto es:

Condiciones socioeconómicas → *Índice de Vulnerabilidad* → *Indicadores de Contratación* → *Asociación* → *Correspondencia* → *Brechas* → *Diagnóstico espacial/temporal* → *Clasificación territorial.*

La pregunta no presupone que los municipios más vulnerables deban recibir necesariamente más contratos. La investigación pretende determinar empíricamente si existe un patrón de correspondencia y cómo se distribuyen las desviaciones respecto de ese patrón. El muestreo estratificado de auditoría y el *bootstrap* de validación (Sección 9) se insertan en los dos primeros eslabones de esta cadena — calidad del dato de entrada y estabilidad del índice — antes de avanzar a las etapas de asociación y correspondencia.

7. Variables y operacionalización preliminar

Constructo	Variable	Operacionalización	Escala	Rol
Vulnerabilidad	Índice sintético	PCA basado en IPM + indicadores compatibles	Continua	Principal
IPM	Pobreza multidimensional	Fuente DANE	Continua	Base conceptual
Contratación	Valor contratado	Suma por municipio–año	Continua	Dependiente/resultado
Contratación	Número de contratos	Conteo por municipio–año	Conteo	Resultado
Contratación	Valor per cápita	Valor contratado / población	Continua	Resultado
Estructura	Modalidad	Frecuencia/participación por modalidad	Categórica	Explicativa/descriptiva
Estructura	Sector	Participación por sector	Categórica	Explicativa/descriptiva
Estructura	Tipo de contrato	Participación por tipo	Categórica	Explicativa/descriptiva
Temporal	Duración	Días entre inicio y terminación, cuando exista	Continua	Explicativa/descriptiva
Contexto	Población	Población municipal	Continua	Control
Territorio	Municipio/departamento	DIVIPOLA u homologación oficial	Categórica	Identificación

Constructo	Variable	Operacionalización	Escala	Rol
Calidad del dato	Indicadores de auditoría	Duplicidad, inconsistencia territorial, campos incompletos, atipicidad (ver Sección 9.3)	Binaria/proporción	Control de calidad

8. Hipótesis de trabajo

Hipótesis H1 – H6

H1. Existe una asociación estadísticamente significativa entre el índice de vulnerabilidad socioeconómica municipal y la intensidad de contratación pública.

H2. La asociación entre vulnerabilidad y contratación difiere según la forma de medir la contratación: valor absoluto, valor per cápita y número de contratos.

H3. Existen municipios cuya intensidad de contratación presenta desviaciones sistemáticas respecto de la correspondencia esperada con su vulnerabilidad socioeconómica.

H4. La distribución espacial de vulnerabilidad y/o contratación presenta autocorrelación espacial cuando los diagnósticos correspondientes así lo indiquen.

H5. La tasa de inconsistencias (duplicados, campos incompletos, valores atípicos no justificados) en el histórico de SECOP II, estimada mediante muestreo estratificado, no supera un umbral que comprometa la validez de las métricas de contratación agregadas a nivel municipio–año.

H6. Las cargas factoriales del componente principal utilizado para construir el IVS son estables ante remuestreo *bootstrap*: sus intervalos de confianza no cambian de signo ni de orden de magnitud relativo entre indicadores.

Ninguna de estas hipótesis plantea causalidad. Los resultados se interpretarán como asociación, correspondencia y validez estadística.

9. Diseño metodológico: integración de muestreo estadístico

Esta sección formaliza el componente de muestreo estadístico del proyecto. No se trata de una posibilidad exploratoria: es el diseño ya definido que se ejecutará como parte del pipeline metodológico, en los puntos precisos del diagrama de flujo que se indican en cada procedimiento.

9.1. Naturaleza poblacional de los datos y necesidad del muestreo

Tanto SECOP II (7.827.129 registros = universo administrativo de contratos, no una muestra de ellos) como el IPM del DANE 2018 (medición de fuente censal) son datos de naturaleza **poblacional**. El muestreo no se introduce para reemplazar el análisis censal, sino para resolver dos problemas concretos que la propia escala de los datos genera:

1. La auditoría manual exhaustiva de 7,8 millones de registros para diagnosticar su calidad es inviable en el tiempo disponible para el proyecto.

2. La construcción del IVS mediante PCA y la medida de correspondencia producen estimaciones puntuales cuya estabilidad no queda establecida solo con los supuestos asintóticos convencionales.

Principio metodológico

El muestreo se utiliza para (a) hacer viable la auditoría de calidad de una base de gran volumen mediante inferencia hacia esa misma población, y (b) cuantificar la incertidumbre de estimaciones (PCA, correspondencia) mediante remuestreo, cuando la teoría asintótica clásica es insuficiente o sus supuestos son dudosos.

9.2. Justificación del diseño muestral seleccionado: por qué muestreo aleatorio estratificado

La condición determinante para elegir el diseño muestral es que la calidad de los registros de SECOP II **no se distribuye de manera homogénea** a lo largo de la ventana 2015–2025. Existen al menos tres fuentes documentadas de heterogeneidad conocida *a priori*: (i) cambios normativos en las reglas de reporte de la contratación pública electrónica a lo largo del periodo; (ii) migraciones y actualizaciones de la plataforma SECOP II, que históricamente han generado periodos de transición con mayor incidencia de campos vacíos, duplicados o cambios de esquema; y (iii) crecimiento no lineal del volumen de contratos publicados año a año.

Esta heterogeneidad conocida y estructurada entre años es, precisamente, la condición bajo la cual la teoría de muestreo establece que la estratificación domina a las demás alternativas en eficiencia estadística (Cochran, 1977; Lohr, 2019). La siguiente tabla sustenta, frente a cada alternativa clásica, por qué el diseño estratificado es la opción seleccionada y no otra:

Diseño	Por qué no se selecciona	Criterio técnico
Aleatorio simple (MAS)	No garantiza representación proporcional de los años/periodos con mayor incidencia de error; puede sobrerepresentar por azar los años de mayor volumen y dejar sin observaciones los años de transición de plataforma, que son los más críticos para el diagnóstico.	Varianza del estimador MAS $\geq$ varianza del estimador estratificado siempre que exista heterogeneidad entre estratos; aquí la heterogeneidad está documentada.
Sistemático	Requiere un marco muestral ordenado y un salto fijo k. Si el archivo está ordenado por fecha o identificador correlativo, el salto puede coincidir con patrones periódicos de carga de datos, introduciendo sesgo de periodicidad.	Riesgo de covarianza no nula entre el intervalo k y ciclos administrativos de reporte.
Conglomerados (p. ej. por entidad contratante)	Auditar conglomerados completos implica revisar registros muy similares entre sí (una misma entidad repite sus propios errores de captura), lo cual reduce la información efectiva por unidad auditada.	Efecto de diseño (*design effect*) > 1 cuando existe correlación intraconglomerado.

Diseño	Por qué no se selecciona	Criterio técnico
Estratificado (seleccionado)	Aprovecha la heterogeneidad conocida (año/periodo de plataforma) para reducir la varianza, garantiza representación mínima de cada año — incluidos los años críticos de transición — y entrega una estimación de calidad por estrato.	Varianza del estimador estratificado $\leq$ varianza MAS bajo asignación proporcional, y estrictamente menor bajo asignación de Neyman (Cochran, 1977, cap. 5).

Adicionalmente, únicamente un diseño estratificado produce, sin supuestos adicionales ni post-estratificación correctiva, estimaciones separadas y válidas **por año**, que se usarán directamente para priorizar las reglas de limpieza automatizada por periodo en la Fase 3. Por estas razones — heterogeneidad documentada, menor varianza y utilidad directa para la limpieza posterior — se selecciona el muestreo aleatorio estratificado como el diseño del proyecto.

9.3. Procedimiento 1: auditoría de calidad de SECOP II mediante muestreo estratificado

Objetivo. Estimar, con un nivel de confianza y margen de error predefinidos, la proporción de registros de SECOP II que presentan problemas de calidad, sin necesidad de revisar el universo completo de 7,8 millones de contratos.

Marco muestral y unidad de muestreo. Población objetivo: totalidad de registros de SECOP II del histórico consolidado, dentro de la ventana temporal definitiva que se fije tras esta misma auditoría (provisionalmente 2015–2025). Unidad de muestreo: el contrato individual. Marco muestral: el archivo histórico en formato Parquet ya consolidado por trimestre, una vez verificada su completitud a nivel de archivo.

Pasos de ejecución.

1. Definir los estratos $h = 1, \ldots, L$ cruzando año (o trimestre) con rango de valor del contrato (cuartiles).

2. Calcular N_h, el número de registros en cada estrato dentro del marco muestral.

3. Determinar el tamaño de muestra total n a partir de una proporción esperada de inconsistencia p (usar $p = 0.5$ como escenario conservador si no hay estimación previa), un margen de error e y un nivel de confianza $1 - \alpha$:

$$n_0 = \frac{z^2_{1-\alpha/2}\, p(1-p)}{e^2}, \qquad n = \frac{n_0}{1 + \dfrac{n_0 - 1}{N}}$$

   aplicando la corrección por población finita, relevante porque N es grande pero conocido y fijo.

4. Asignar la muestra entre estratos mediante asignación proporcional como opción base ($n_h = n \cdot N_h/N$), evaluando asignación de Neyman como alternativa en estratos con mayor variabilidad

esperada de calidad:

$$n_h^{\text{Neyman}} = n \cdot \frac{N_h S_h}{\sum_h N_h S_h}$$

5. Extraer la muestra mediante muestreo aleatorio simple dentro de cada estrato, con semilla aleatoria documentada para reproducibilidad.

6. Auditar cada registro muestreado sobre cinco dimensiones binarias de calidad: duplicidad; inconsistencia territorial (código DIVIPOLA inexistente o contradictorio); campos clave incompletos; valor atípico no justificado; e incoherencia temporal (duración negativa o implausible).

7. Estimar, para cada dimensión, la proporción poblacional y su intervalo de confianza mediante el estimador estratificado:

$$\hat{p}_{st} = \sum_{h=1}^{L} \frac{N_h}{N} \hat{p}_h, \qquad \widehat{\text{Var}}(\hat{p}_{st}) = \sum_{h=1}^{L} \left(\frac{N_h}{N}\right)^2 \frac{\hat{p}_h(1-\hat{p}_h)}{n_h - 1} \left(1 - \frac{n_h}{N_h}\right)$$

8. Redactar el reporte de calidad y la recomendación de reglas de limpieza priorizadas por estrato, según la tasa de error estimada.

Entregables. Ficha técnica del diseño muestral; base auditada con las cinco dimensiones de calidad codificadas; reporte de estimaciones poblacionales con intervalos de confianza por dimensión y por estrato; recomendación de reglas de limpieza para la Fase 3.

Ubicación en el flujo del proyecto. Este procedimiento se ejecuta entre las fases 2 (Revisión de datos y fuentes) y 3 (Preparación y limpieza de datos); formaliza estadísticamente el paso 2.1 (auditoría de la base SECOP II) ya previsto.

9.4. Procedimiento 2: validación del Índice de Vulnerabilidad mediante *bootstrap*

Objetivo. Cuantificar la estabilidad estadística de los resultados del PCA (Fase 4) utilizado para construir el IVS, complementando la validación por adecuación muestral (KMO/Bartlett) con una medida explícita de incertidumbre sobre las cargas factoriales.

Justificación: por qué *bootstrap* y no otra alternativa. El PCA entrega cargas factoriales y varianza explicada como estimaciones puntuales; sin una medida de incertidumbre no es posible saber si esas cargas son estables o son un artefacto de la muestra particular de municipios disponible. Existen al menos tres alternativas para cuantificar esa incertidumbre, y se descartan por razones concretas:

Alternativa	Por qué no se selecciona	Criterio técnico
Fórmulas analíticas asintóticas (teoría clásica de PCA)	Suponen normalidad multivariada de los indicadores y un tamaño de muestra grande para que la aproximación asintótica sea válida. Los indicadores de pobreza y vulnerabilidad son característicamente asimétricos (colas pesadas, concentración en valores bajos), por lo que el supuesto de normalidad es cuestionable con ∼1.100 municipios.	La varianza asintótica de los *eigenvectors* depende de la separación entre *eigenvalues*; con valores propios cercanos, la aproximación de primer orden es inestable, mientras que el *bootstrap* no depende de esa aproximación.
Jackknife (*leave-one-out*)	Es conocido que el *jackknife* se comporta erráticamente para estadísticos no suaves como los vectores propios de un PCA, especialmente cuando dos *eigenvalues* están próximos (riesgo de rotación/cambio de signo abrupto al remover una sola observación).	El *jackknife* solo genera N pseudo-réplicas (una por municipio removido) frente a $B \geq 1000$ del *bootstrap*, ofreciendo una aproximación mucho más pobre de la distribución muestral completa.
Validación cruzada (*cross-validation*)	Está diseñada para evaluar capacidad predictiva o error de generalización, no para construir intervalos de confianza de parámetros como cargas factoriales o varianza explicada. Usarla aquí respondería una pregunta distinta a la que exige H6.	No genera una distribución muestral del parámetro de interés, solo una estimación de error de predicción fuera de muestra.
***Bootstrap* (seleccionado)**	No requiere supuestos distribucionales sobre los indicadores: remuestrea directamente la distribución empírica observada. Genera $B \geq 1000$ réplicas completas del PCA, permitiendo construir intervalos de confianza (percentil o BC_a) que capturan asimetría real en la distribución de las cargas, en lugar de asumir simetría como la teoría asintótica.	Es el método estándar en estadística multivariada para validar la estabilidad de cargas factoriales e índices sintéticos basados en PCA (Efron & Tibshirani, 1993).

Pasos de ejecución.

1. Definir la matriz de indicadores estandarizados Z (municipios × variables IPM/compatibles), ya construida en la Fase 4.

2. Generar $B \geq 1000$ remuestras *bootstrap* por remuestreo con reemplazo de las filas (municipios) de Z; cuando exista agrupamiento departamental relevante, ejecutar adicionalmente un *bootstrap* por bloques (remuestreo de departamentos completos) para no romper la posible dependencia espacial intradepartamental.

3. Para cada remuestra $b = 1, \ldots, B$, reajustar el PCA y registrar: las cargas factoriales del/los componente(s) retenido(s), la proporción de varianza explicada y el IVS resultante por municipio.

4. Construir, para cada carga factorial y para la varianza explicada, un intervalo de confianza *bootstrap* (percentil o BC_a).

5. Verificar H6: comprobar si el signo y el orden relativo de magnitud de cada carga se mantienen estables a través de las B remuestras.

Criterio de interpretación. Cargas con intervalos que no cruzan cero y mantienen signo consistente: variable con contribución estable al índice. Cargas con intervalos que cruzan cero o cambian de signo: variable candidata a revisión. Municipios cuyo IVS varía sustancialmente entre remuestras: señal de sensibilidad del índice para ese municipio.

Entregables. Intervalos de confianza *bootstrap* para cargas factoriales y varianza explicada; gráfico de distribución *bootstrap* del IVS para los municipios en los extremos del ranking; reporte de sensibilidad del índice.

Ubicación en el flujo del proyecto. Se ejecuta dentro de la Fase 4.6 (Validación y sensibilidad del índice), ya prevista en el flujo original; este procedimiento especifica el método concreto para ejecutar esa validación.

9.5. Procedimiento 3: prueba de permutación para la correspondencia vulnerabilidad–contratación

Objetivo. Aportar una vía de inferencia no paramétrica, complementaria a las pruebas clásicas de correlación y a los modelos de regresión de la Fase 7, para evaluar si la asociación observada entre el IVS y los indicadores de contratación es mayor de lo esperable bajo aleatoriedad.

Justificación: por qué prueba de permutación y no otra alternativa. La pregunta que exige H1 es puntual: ¿la asociación observada entre IVS y contratación es mayor de lo esperable bajo aleatoriedad? Existen varias formas de responderla, y se descartan por razones concretas frente a la permutación:

Alternativa	Por qué no se selecciona	Criterio técnico
Prueba paramétrica (correlación de Pearson / regresión OLS)	Supone normalidad bivariada y relación lineal entre IVS y contratación. Los indicadores de contratación (valor total, valor per cápita) son característicamente asimétricos a la derecha, con una masa importante de municipios en valores bajos o nulos y una cola larga de valores altos, lo que viola el supuesto de normalidad requerido para que el valor p paramétrico sea válido.	El valor p paramétrico depende de la distribución teórica t de Student bajo normalidad; con datos sesgados, esa distribución teórica no coincide con la distribución real del estadístico, sesgando la inferencia.
Correlación de Spearman/Kendall con p asintótico	El valor p reportado por defecto en la mayoría de *software* es una aproximación asintótica (válida solo para muestras grandes) y pierde precisión cuando hay muchos empates (*ties*) — frecuentes aquí porque varios municipios comparten el mismo número de contratos o el mismo rango de IVS.	La aproximación asintótica de Spearman/Kendall no está diseñada para corregir empates de forma exacta; la permutación sí, porque recalcula la distribución nula empírica directamente sobre los datos observados, empates incluidos.

Alternativa	Por qué no se selecciona	Criterio técnico
Prueba de bondad de ajuste (chi-cuadrado) sobre categorías de IVS/contratación	Exige discretizar variables continuas en categorías, lo que descarta información al convertir el IVS y la contratación en pocos grupos, y el resultado depende arbitrariamente de dónde se coloquen los puntos de corte.	Pérdida de potencia estadística frente a un estadístico calculado sobre las variables continuas originales.
Prueba de permutación (seleccionada)	No exige ningún supuesto distribucional: solo requiere que, bajo la hipótesis nula de no asociación, cualquier reasignación de los valores de contratación entre municipios sea igual de probable. Construye la distribución nula **directamente desde los datos observados**, respetando su asimetría real y sus empates, y produce un valor p válido incluso en muestras finitas (no depende de aproximaciones asintóticas).	Es el método estándar para pruebas de independencia libres de distribución cuando los supuestos paramétricos son dudosos (Good, 2005); además permite usar el mismo estadístico de correspondencia definido en la Fase 7.4, en lugar de forzar el uso de una prueba genérica.

Pasos de ejecución.

1. Calcular el estadístico de asociación o correspondencia observado entre IVS y el indicador de contratación de interés (correlación de Spearman o el índice de correspondencia definido en la Fase 7.4).

2. Generar $P \geq 5000$ permutaciones de la asignación municipio–valor de contratación, rompiendo el vínculo real entre vulnerabilidad y contratación pero preservando la distribución marginal de cada variable.

3. Recalcular el estadístico en cada permutación para construir la distribución nula empírica.

4. Calcular el valor p empírico como la proporción de estadísticos permutados iguales o más extremos que el observado.

Entregables. Distribución nula empírica graficada junto al estadístico observado; valor p empírico reportado junto al valor p paramétrico de la prueba clásica correspondiente, señalando concordancia o discrepancia entre ambos.

Ubicación en el flujo del proyecto. Se ejecuta como complemento metodológico dentro de la Fase 7.1 (Análisis de correlación bivariada) y la Fase 7.4 (Medidas de correspondencia).

9.6. Línea de trabajo futuro: diseño muestral para validación externa

Como línea de trabajo futuro — coherente con la agenda de investigación de la Sección 11 — se deja documentado, sin implicar su ejecución dentro del alcance temporal actual, el diseño conceptual de un muestreo probabilístico por conglomerados (municipios como conglomerados, estratificados por región y nivel de vulnerabilidad) para una eventual encuesta de percepción de

equidad en la contratación pública dirigida a funcionarios municipales o ciudadanía. Este diseño serviría como validación externa cualitativa de los hallazgos cuantitativos del proyecto, pero su levantamiento excede los recursos y el tiempo disponibles para el presente trabajo de grado.

Justificación: por qué conglomerados estratificados y no muestreo estratificado simple. A diferencia de la auditoría de SECOP II (donde la unidad de muestreo es un contrato y no existe costo de desplazamiento), aquí la unidad es un municipio que hay que visitar o contactar directamente. Un diseño estratificado simple podría seleccionar municipios dispersos por todo el país, lo que encarecería el levantamiento de forma prohibitiva para un trabajo de grado. Al usar los municipios como conglomerados dentro de cada estrato región–nivel de vulnerabilidad, el esfuerzo de campo se concentra geográficamente sin sacrificar la representación de las distintas regiones y niveles de vulnerabilidad del país. Es, por tanto, el único diseño que equilibra representatividad estadística con factibilidad logística para este componente específico, aunque — como ya se indicó — su ejecución efectiva queda fuera del alcance temporal actual.

9.7. Integración de los procedimientos en el flujo de fases del proyecto

Fase del flujo	Procedimiento	Función
2 → 3	Muestreo estratificado de auditoría (Procedimiento 1)	Estimar con IC la tasa de errores de calidad en SECOP II sin auditoría exhaustiva
4.6	*Bootstrap* del IVS (Procedimiento 2)	Cuantificar estabilidad de cargas factoriales y del índice
7.1 / 7.4	Prueba de permutación (Procedimiento 3)	Inferencia no paramétrica complementaria sobre la correspondencia
Agenda futura	Diseño muestral para validación externa	Documentar línea de trabajo futura, no ejecutada en este alcance

10. Limitaciones previstas

- El IPM municipal no tiene necesariamente frecuencia anual comparable con la contratación anual.
- SECOP II es información administrativa autodeclarada y puede contener errores, cambios de campos, duplicados o registros incompletos — riesgo que el muestreo estratificado de auditoría (Sección 9.3) permite cuantificar, no eliminar por completo.
- El valor de un contrato no equivale necesariamente al gasto efectivamente ejecutado ni al beneficio social generado.
- La localización de una entidad contratante no implica que el beneficio económico del contrato permanezca en el mismo municipio.
- Una asociación estadística no identifica causalidad.
- Los municipios presentan tamaños poblacionales y estructuras institucionales muy diferentes.

- Los cambios metodológicos de SECOP y DANE deberán documentarse antes de comparar periodos.

11. Agenda de investigación inmediata

1. Auditar completamente las variables y años del histórico SECOP II del repositorio (formalizado mediante el Procedimiento 1, Sección 9.3).
2. Construir un diccionario de variables de contratación y clasificar cada campo por función analítica.
3. Identificar las variables municipales DANE compatibles con el IPM y la dimensión temporal.
4. Definir el mecanismo de integración territorial mediante DIVIPOLA.
5. Realizar EDA y auditoría de calidad antes de construir el índice.
6. Evaluar la factibilidad estadística del PCA y construir versiones alternativas del índice, validadas mediante *bootstrap* (Procedimiento 2, Sección 9.4).
7. Definir formalmente la medida de correspondencia y compararla con varias alternativas, incluyendo la prueba de permutación (Procedimiento 3, Sección 9.5).
8. Construir medidas de brecha territorial.
9. Diagnosticar dependencia espacial antes de utilizar modelos espaciales.
10. Definir el modelo temporal/panel según la disponibilidad real de datos.
11. Ampliar la revisión bibliográfica en Scopus, Web of Science, SciELO, Redalyc y repositorios nacionales.
12. Redactar problema, justificación, objetivo general, objetivos específicos y metodología definitiva.

12. División de trabajo entre integrantes

12.1. Principio de división

La división se organiza alrededor de los dos pipelines de datos independientes que el proyecto requiere integrar (vulnerabilidad DANE/IPM y contratación SECOP II), de manera que cada integrante sea responsable completo de una fuente hasta el punto de integración territorial, evitando duplicar esfuerzo. Las fases posteriores a la integración (6 a 10) se dividen por tarea específica dentro de cada fase, dado que dependen de ambas fuentes simultáneamente.

Integrante	**Eje principal**
Juan Diego Gallo Quintero	Vulnerabilidad socioeconómica (DANE / IPM)
Juan David Parada Fonseca	Contratación pública (SECOP II)

12.2. Responsable: Juan Diego Gallo Quintero — Eje de Vulnerabilidad

Fase 2 (parte DANE/IPM) — Revisión de datos y fuentes

1. Auditar las variables disponibles del IPM municipal 2018 (dimensiones, privaciones, factores de expansión).
2. Verificar cobertura municipal completa e identificar municipios con datos faltantes o no certificados.
3. Construir el diccionario de variables IPM con definición, escala y fuente de cada indicador.
4. Evaluar qué otras variables municipales (TerriData/DNP u otras) son compatibles en periodo y calidad para complementar el IPM.

Entregable: diccionario de variables DANE/IPM, matriz de disponibilidad municipal, decisión documentada sobre variables adicionales candidatas.

Fase 4 completa — Construcción del Índice de Vulnerabilidad Socioeconómica

1. Seleccionar y estandarizar los indicadores base (IPM + complementarios aprobados).
2. Ejecutar pruebas de adecuación muestral (KMO y esfericidad de Bartlett) antes de correr el PCA.
3. Ejecutar el Análisis de Componentes Principales y decidir el número de componentes a retener, justificando el criterio (varianza explicada, criterio de Kaiser, gráfico de sedimentación).
4. Verificar signos de las cargas e invertir variables cuyo aumento represente menor vulnerabilidad.
5. Construir el IVS final combinando los componentes retenidos.
6. Ejecutar la validación mediante *bootstrap* (Procedimiento 2, Sección 9.4) sobre las cargas factoriales y el índice resultante.
7. Redactar el reporte de validación y sensibilidad del índice.

Entregable: IVS calculado por municipio, cargas factoriales con intervalos de confianza *bootstrap*, reporte de validación.

Transversal — Redacción teórica y bibliográfica

1. Mantener y ampliar el estado del arte y el marco teórico con la revisión bibliográfica pendiente en Scopus, Web of Science, SciELO y Redalyc.
2. Redactar planteamiento del problema, justificación, objetivos y metodología definitiva del artículo final.
3. Consolidar la matriz bibliográfica y las referencias en formato APA 7.

Entregable: documento de estado del arte y marco teórico en su versión final, integrado con los resultados empíricos del proyecto.

12.3. Responsable: Juan David Parada Fonseca — Eje de Contratación

Fase 2 (parte SECOP II) — Revisión de datos y fuentes

1. Auditar el notebook `Historico_de_Datos.ipynb` y verificar de forma directa el número de registros, variables y cobertura temporal reportados.
2. Ejecutar el muestreo estratificado de auditoría de calidad (Procedimiento 1, Sección 9.3): definir estratos, calcular tamaño de muestra, extraer la muestra y codificar las dimensiones de calidad.
3. Estimar, con intervalos de confianza, la tasa de duplicados, inconsistencias territoriales, campos incompletos y valores atípicos.
4. Definir, junto con Juan Diego, el periodo analítico definitivo a partir de la calidad y cobertura real encontrada.

Entregable: ficha técnica del diseño muestral, reporte de calidad de SECOP II con intervalos de confianza, recomendación de ventana temporal definitiva.

Fase 3 completa — Preparación y limpieza de datos

1. Descargar/integrar los datos SECOP II desde los archivos Parquet consolidados.
2. Estandarizar entidades territoriales mediante códigos DIVIPOLA, resolviendo homologaciones y municipios no identificables.
3. Aplicar las reglas de limpieza priorizadas según el resultado del muestreo de auditoría (Procedimiento 1): tratamiento de duplicados, valores faltantes y atípicos.
4. Agregar los contratos a nivel panel municipio–año.
5. Construir la base final "SECOP II limpia" y el panel municipio–año de contratación pública.

Entregable: base SECOP II limpia, panel municipio–año, métricas de contratación agregadas.

Fase 5 completa — Índices e indicadores de contratación pública

1. Calcular métricas principales: valor total, número de contratos, valor per cápita (usando población municipal como control).
2. Construir indicadores por modalidad de contratación.
3. Construir indicadores por sector.
4. Construir indicadores por tipo de contrato.
5. Construir indicadores por duración (días entre inicio y terminación).
6. Construir los índices compuestos de contratación que resuman las familias anteriores.

Entregable: métricas y clasificación de contratación por municipio-año, índices compuestos, tablas descriptivas documentadas.

12.4. Trabajo conjunto — Fases 6 a 10

Estas fases dependen simultáneamente del IVS (eje Juan Diego) y de las métricas de contratación (eje Juan David), por lo que no se dividen por fase completa sino por tarea específica dentro de cada una. Ambos revisan y validan el resultado del otro antes de avanzar a la siguiente fase.

Fase	Tarea	Responsable principal
6	Estadísticos descriptivos y distribuciones por municipio/año	Ambos (cada uno su eje)
6	Mapas temáticos (IVS y contratación) y curvas de Lorenz/Gini	Juan Diego
6	Comparaciones departamentales de contexto	Juan David
7	Análisis de correlación bivariada + prueba de permutación (Procedimiento 3)	Juan David
7	Modelos de regresión múltiple y de panel	Juan Diego
7	Definición de la medida de correspondencia y de brechas territoriales	Ambos (definición conjunta)
8	Matriz de pesos espaciales y pruebas de autocorrelación (Moran's I, LISA)	Juan Diego
8	Interpretación conjunta de clústeres espaciales	Ambos
9	Reducción de dimensionalidad y clustering de municipios	Juan David
9	Perfilamiento socioeconómico y contractual de los clústeres	Ambos
10	Diseño de dashboard y mapas interactivos	Juan David
10	Redacción del reporte final y recomendaciones de política pública	Juan Diego

12.5. Regla de coordinación

- Ningún integrante avanza a una fase conjunta (6 en adelante) sin que los entregables de su fase individual (2–5) estén validados por el otro integrante.
- La integración territorial (unión de los paneles de vulnerabilidad y de contratación por código DIVIPOLA–año) se ejecuta de forma conjunta, dado que requiere acuerdo explícito sobre el nivel de agregación y el tratamiento de casos no homologables.
- Todo cambio en el periodo analítico definitivo, en la definición de correspondencia o en el tratamiento de valores atípicos debe documentarse y acordarse entre ambos antes de ejecutarse, dado su impacto sobre el trabajo del otro integrante.

13. Nota metodológica sobre originalidad

El repositorio revisado es una referencia externa utilizada como punto de partida para identificar fuentes, estructura de datos y antecedentes. El presente proyecto se plantea como una investigación independiente. El aporte original propuesto consiste en integrar, a escala municipal, un índice de vulnerabilidad socioeconómica basado en IPM/PCA con medidas de contratación pública, y desarrollar un marco estadístico explícito — que incluye muestreo, remuestreo y pruebas de permutación — para estudiar asociación, correspondencia y brechas, incorporando dimensión temporal y espacial cuando los datos lo justifiquen.

14. Referencias bibliográficas — APA 7

Arachia, G., Assisi, D., Cesi, B., Giuranno, M. G., & Russo, F. (2024). Intermunicipal cooperation in public procurement. *Regional Studies, 58*(11), 2055–2073. https://doi.org/10.1080/00343404.2024.2350615

Ardila-Rueda, L. (2004). Gasto público y convergencia regional en Colombia. *Ensayos Sobre Política Económica, 22*(45), 222–268.

Bonet-Morón, J. (2006). *Desequilibrios regionales en la política de descentralización en Colombia* (Documento de Trabajo sobre Economía Regional y Urbana No. 77). Banco de la República.

Cochran, W. G. (1977). *Sampling techniques* (3.ª ed.). John Wiley & Sons.

Colombia Compra Eficiente. (2026). *SECOP II: Sistema Electrónico para la Contratación Pública.*

DANE. (2018). *Medida de pobreza multidimensional de fuente censal.* Departamento Administrativo Nacional de Estadística.

Datos Abiertos Colombia. (2026). *SECOP II — Contratos Electrónicos.*

Departamento Nacional de Planeación. (2024). *TerriData: Sistema de Estadísticas Territoriales.* DNP.

Díaz Díez, C. A. (2023). Obligatoriedad del Sistema Electrónico de Contratación Pública (SECOP) para las entidades estatales con régimen contractual excepcional: un supuesto de retorno del Derecho Administrativo en Colombia. *Revista Eurolatinoamericana de Derecho Administrativo, 10*(2).

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap.* Chapman & Hall/CRC.

Ferry, L., et al. (2023). Public procurement as a policy tool: The territorial dimension. *Regional Studies, 57*(11), 2087–2101. https://doi.org/10.1080/00343404.2022.2134850

Figueroa-Gómez, Y., & Galpin, I. (2024). Identifying public tenders of interest using classification models: A comparative analysis. *SN Computer Science, 5*, 87. https://doi.org/10.1007/s42979-023-02443-3

Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.ª ed.). Springer.

Gutiérrez Vanegas, K. F. (2024). *Implementación de banderas rojas en la contratación pública en Colombia utilizando datos abiertos* [Trabajo de grado]. Fundación Universitaria Los Libertadores.

Lohr, S. L. (2019). *Sampling: Design and analysis* (3.ª ed.). CRC Press.

Monsalvo Herrera, A. E., & Jiménez, W. G. (2025). Pobreza multidimensional: un análisis espacial en los municipios de Cundinamarca, Colombia. *Novum Jus, 19*(2), 213–251. https://doi.org/10.14718/NovumJus.2

Norbäck, M., & Zapata Campos, M. J. (2022). The market made us do it: Public procurement and collaborative labour market inclusion governance from below. *Social Policy & Administration, 56*(4), 632–647. https://doi.org/10.1111/spol.12787

Open Contracting Partnership. (2023). *Open contracting reforms to boost civic engagement and participation: The experience of nine regions in Colombia.*

Rodriguez-Plesa, E., Dimand, A.-M., & Alkadry, M. G. (2022). Community social capital, political values, or organizational capacity? Indicators of engagement in sustainable public procurement at

the local level. *Journal of Cleaner Production, 338*, 130556. https://doi.org/10.1016/j.jclepro.2022.130556

Salazar, A., Pérez, J. F., & Gallego, J. (2024). VigIA: Prioritizing public procurement oversight with machine learning models and risk indices. *Data & Policy, 6*, e75. https://doi.org/10.1017/dap.2024.83

Sarter, E. K. (2024). Public procurement and labour market inequality: Conceptualising a multi-faceted relationship. *Journal of Industrial Relations, 66*(1), 130–152. https://doi.org/10.1177/00221856231221417

Särndal, C.-E., Swensson, B., & Wretman, J. (1992). *Model assisted survey sampling*. Springer-Verlag.