INFORME 1 METODOLÓGICO

Proyecto Desarrollo Social Económico

¿Existe una correspondencia entre la distribución territorial de la contratación pública y las condiciones de vulnerabilidad socioeconómica de los municipios colombianos?

Elaborado por:

Juan Diego Gallo

Investigador en Estadística Aplicada

Octubre de 2026

Versión 1.0

Resumen

Este informe documenta el proceso metodológico del proyecto *Desarrollo Social Económico*, cuyo objetivo central es estudiar la correspondencia entre la distribución territorial de la contratación pública (SECOP II) y las condiciones de vulnerabilidad socioeconómica de los municipios colombianos. La pregunta de investigación guía es: **¿Existe una correspondencia entre la distribución territorial de la contratación pública y las condiciones de vulnerabilidad socioeconómica de los municipios colombianos?**

El presente informe cubre las etapas completadas hasta la fecha: selección y auditoría de fuentes de información (CNPV 2018, IPM 2018, DIVIPOLA), definición de la unidad de análisis municipal (1.122 municipios), homologación territorial, tratamiento de datos faltantes, construcción de indicadores socioeconómicos municipales, control de calidad y diagnósticos estadísticos preliminares. Se han construido 14 indicadores candidatos (7 para análisis PCA provisional y 7 de descripción/solapamiento con IPM) a partir de 8 cuadros censales seleccionados, con fórmulas explícitas de numeradores y denominadores, y se han documentado las decisiones sobre dirección de vulnerabilidad y tratamiento de no respuesta (escenarios de base total y base válida).

Los diagnósticos preliminares reportan KMO global $\approx 0,642$, prueba de Bartlett significativa ($p < 0,001$), determinante $\approx 0,0154$, ausencia de pares con correlación $|r| \geq 0,90$, y 32 municipios con al menos un $|z| > 4$. El MSA del indicador de estrato 1–2 es bajo ($\approx 0,414$). Estos resultados son **diagnósticos previos**; **no se ha ejecutado un PCA definitivo** y la auditoría estadística integral permanece pendiente.

El Índice de Vulnerabilidad Socioeconómica (IVS) **no está construido**. El IPM municipal se reserva como validación externa futura para evitar circularidad. La integración con SECOP II, el análisis de asociación y el análisis espacial son etapas posteriores condicionadas a la consolidación del IVS.

Este informe está diseñado para ser modular y ampliable, permitiendo incorporar posteriormente la auditoría estadística completa, el PCA, la construcción del IVS, su validación, la integración SECOP II y los análisis espaciales sin reescribir las secciones metodológicas ya consolidadas.

Fecha de corte: 13 de octubre de 2026.

Scripts de referencia: `R/00_config.R`, `R/01_verificar_consolidados.R`, `R/02_base_final_indicadores.R`, `R/03_auditoria_indicadores.R`.

Productos reproducibles: `datos/trabajo/`, `resultados/base_trabajo/`, `resultados/auditoria_estadistica`

Palabras clave

Vulnerabilidad socioeconómica, Análisis de Componentes Principales (PCA), Indicadores municipales, Censo Nacional de Población y Vivienda 2018 (CNPV 2018), Índice de Pobreza Multidimensional (IPM) 2018, DIVIPOLA, Contratación pública (SECOP II), Medición multidimensional, Análisis territorial, Metodología de investigación cuantitativa.

Índice

Resumen I

Palabras clave II

1. Introducción 1

2. Contexto y planteamiento del problema 1

3. Justificación 1

4. Antecedentes del proyecto 1

5. Objetivo del informe 2

6. Alcance y limitaciones declaradas 2

7. Estructura del documento 3

8. Planteamiento metodológico 4

9. Pregunta de investigación 4

10. Objetivo general 4

11. Objetivos específicos 4

12. Unidad de análisis 5

13. Alcance del estudio **5**

14. Naturaleza del análisis **5**

15. Marco metodológico y conceptual **6**

16. Vulnerabilidad socioeconómica **6**

17. Medición multidimensional **6**

18. Indicadores socioeconómicos **6**

19. Reducción de dimensionalidad y PCA **7**

20. Relación futura con contratación pública (SECOP II) **8**

21. Fuentes de información **9**

22. Censo Nacional de Población y Vivienda 2018 (CNPV 2018) **9**

23. Índice de Pobreza Multidimensional 2018 (IPM 2018) **9**

24. DIVIPOLA – Códigos municipales **10**

25. SECOP II – Contratación pública (fuente futura) **10**

26. Justificación de las fuentes **10**

27. Unidad territorial y universo de análisis **11**

28. Municipio como unidad de análisis **11**

29. Códigos territoriales **11**

30. Cobertura municipal **11**

31. Coincidencias entre fuentes **12**

32. No coincidencias y casos especiales **12**

32.1. Municipios sin cabecera (20 casos) 12

32.2. Código 94663 (Mapiripana) – Relación con 94343 (Barrancominas) 12

32.3. Código 27493 (Nuevo Belén de Bajirá) – Conflicto territorial 13
32.4. Municipios sin centro poblado (192 casos) 13
32.5. Áreas territorialmente inexistentes 13
32.6. Ausencias estructurales en combinaciones demográficas 13

33. Resumen de decisiones territoriales **14**

34. Proceso de selección y depuración de bases **15**

35. Inventario inicial **15**

36. Inspección de hojas/cuadros **15**

37. Selección de cuadros relevantes **15**

38. Selección de variables **16**

39. Criterios de inclusión **16**

40. Criterios de exclusión **16**

41. Homologación territorial **17**

42. Consolidación **17**

43. Tratamiento de datos faltantes **19**

44. Definición de faltante **19**

45. No respuesta (NR) **19**
45.1. Distinción: `no_tiene_estrato` vs. `no_sabe_no_responde` 19

46. Ausencia estructural **20**

47. Denominadores nulos **20**

48. Casos 0/0 **20**

49. Municipios sin determinadas áreas **21**

50. Decisiones de tratamiento adoptadas **21**

51. Justificación de no imputación **21**

52. Construcción de indicadores socioeconómicos **22**

53. Principios de construcción **22**

54. Numeradores **22**

55. Denominadores y poblaciones de referencia **23**

56. Verificación de población de referencia **23**

57. Escala **23**

58. Dirección de vulnerabilidad **24**

59. Indicadores seleccionados (matriz candidata provisional) **24**

60. Indicadores descartados del PCA (descripción/solapamiento IPM) **25**

61. Indicadores reservados para validación **25**

62. Especificación técnica **26**

63. Control de calidad de los indicadores **27**

64. Validaciones estructurales **27**

65. Consistencia de conteos **27**

66. Rangos **27**

67. Valores imposibles **28**

68. Duplicados **28**

69. Cobertura territorial **28**

70. Integridad de fuentes **29**

71. Resumen de hallazgos de control **29**

72. Diagnóstico estadístico preliminar **31**

73. Estadística descriptiva disponible **31**

74. Variabilidad **31**

75. Correlaciones preliminares **31**

76. Outliers **32**

77. Diagnósticos de adecuación multivariada **32**

78. Medida de Adecuación Muestral Individual (MSA por indicador) **32**

79. Sensibilidad a No Respuesta (NR) **33**

80. Estado de la auditoría estadística **33**

81. Preparación para PCA **35**

82. Objetivo del PCA **35**

83. Justificación metodológica **35**

84. Variables candidatas **36**

85. Criterios que deberán evaluarse **36**

86. Procedimientos pendientes **37**

87. Precauciones frente a circularidad con IPM **38**

88. Configuración técnica **38**

89. Reproducibilidad y arquitectura computacional **39**

90. Organización del repositorio **39**

91. Scripts principales **40**

92. Flujo de procesamiento **40**

93. Trazabilidad **41**

94. Control de integridad **41**

95. Reproducibilidad **41**

96. Limitaciones actuales **43**

97. Auditoría estadística integral pendiente **43**

98. PCA no ejecutado **43**

99. IVS (Índice de Vulnerabilidad Socioeconómica) no construido **43**

100. Validación externa con IPM pendiente **44**

101 Integración SECOP II pendiente **44**

102 Análisis de asociación/correspondencia pendiente **44**

103 Análisis espacial condicionado **44**

104 Otras limitaciones técnicas **45**

105 Estado del proyecto y etapas siguientes **46**

106. Tabla de estado general **46**

107 Decisiones vigentes registradas (extracto de `Resumen_General.md`) **46**

108 Resultados comprobados que orientan el siguiente paso **46**

109 Pendientes y decisiones del autor (próximas acciones) **47**

110 Arquitectura futura del proyecto **48**

111. Conclusiones metodológicas **49**

112 ¿Qué se ha construido hasta ahora? **49**

113 ¿Qué decisiones metodológicas están consolidadas? **49**

114¿Qué problemas fueron detectados y cómo fueron tratados? 50

115¿Qué información queda lista para el análisis multivariado? 50

116¿Qué etapas faltan? 51

117Cierre 51

Anexos 53

A. Especificación completa de indicadores (fuente: `especificacion_indicadores.csv`) 53

B. Inventario de productos reproducibles (CSV generados) 54

B.1. Archivos en `datos/intermedio/` (entradas de solo lectura, verificadas por MD5) . . . 54

B.2. Archivos en `datos/trabajo/` (denominadores, indicadores, matrices) 54

B.3. Archivos en `resultados/verificacion_consolidados/` (inventario y validaciones) 55

B.4. Archivos en `resultados/base_trabajo/` (25 CSV: calidad, sensibilidad, diagnósticos) 55

B.5. Archivos en `resultados/auditoria_estadistica/` (diagnósticos multivariados) . . 56

B.6. Archivos de configuración y scripts 56

Índice de cuadros

1. Fuentes CNPV 2018 utilizadas 9
2. Justificación de fuentes utilizadas 10
3. Universo municipal y cobertura 12
4. Decisiones territoriales clave 14
5. Cuadros seleccionados del CNPV 2018 16
6. Resumen de decisiones sobre faltantes 21
7. Denominadores por indicador 23
8. Dirección de vulnerabilidad por indicador 24
9. Validaciones estructurales clave (extracto de `validaciones.csv`) 27
10. Cobertura territorial y calidad por fuente 28
11. Estadísticos descriptivos por indicador (matriz base total) – extracto de `estadisticos_indicadores.csv` 31
12. Diagnósticos globales de aptitud para PCA (matriz base total, 7 indicadores) 32
13. Scripts principales del pipeline activo 40
14. Trazabilidad decisiones – archivo evidencia 41
15. Estado del proyecto por etapa (corte 13/10/2026) 46
16. Problemas detectados y tratamiento 50
17. Especificación completa de indicadores 53

Índice de figuras

1 Introducción

2 Contexto y planteamiento del problema

La distribución territorial de la contratación pública en Colombia ha sido objeto de creciente atención académica y de política pública. La pregunta central de este proyecto es:

> **¿Existe una correspondencia entre la distribución territorial de la contratación pública y las condiciones de vulnerabilidad socioeconómica de los municipios colombianos?**

Esta interrogante conecta dos dimensiones fundamentales del desarrollo: la asignación de recursos públicos a través de la contratación estatal y las condiciones estructurales de los territorios donde esos recursos se ejecutan. Una correspondencia sistemática (o su ausencia) tendría implicaciones directas para el diseño de políticas de equidad territorial, la focalización de la inversión pública y los mecanismos de control y transparencia.

3 Justificación

Los municipios colombianos presentan heterogeneidad marcada en sus condiciones socioeconómicas, infraestructura, capacidad institucional y acceso a mercados. Simultáneamente, la contratación pública —principal instrumento de ejecución del gasto público— sigue patrones territoriales que pueden reflejar capacidad de gestión, redes políticas, dinámicas de mercado o necesidades reales de la población. Estudiar la correspondencia entre ambas dimensiones permite:

- Evaluar si la contratación pública se concentra en municipios con mayores condiciones de vulnerabilidad (enfoque de equidad) o si reproduce desigualdades preexistentes.
- Proporcionar evidencia empírica para el diseño de mecanismos de focalización territorial.
- Contribuir a la literatura sobre economía política de la contratación pública y desarrollo territorial en contextos de descentralización.

4 Antecedentes del proyecto

El proyecto se origina en la necesidad de construir una base de evidencia rigurosa, reproducible y metodológicamente transparente. Las etapas precedentes han incluido:

1. Revisión del estado del arte sobre vulnerabilidad socioeconómica, medición multidimensional y contratación pública en Colombia.
2. Selección y auditoría de fuentes primarias: Censo Nacional de Población y Vivienda 2018 (CNPV 2018), Índice de Pobreza Multidimensional 2018 (IPM 2018) y DIVIPOLA.
3. Definición de la unidad de análisis (municipio) y homologación territorial entre fuentes.
4. Construcción de indicadores socioeconómicos municipales comparables.
5. Diagnósticos estadísticos preliminares de aptitud para análisis multivariado.

El presente informe consolida metodológicamente estas etapas.

5 Objetivo del informe

Documentar de manera rigurosa, reproducible y trazable **todo el proceso metodológico realizado hasta el estado actual del proyecto**, desde la selección y auditoría inicial de las fuentes de información hasta la construcción de los indicadores socioeconómicos municipales y los diagnósticos preliminares. Este documento es el **primer informe metodológico formal del proyecto** y está diseñado para crecer modularmente con las etapas subsiguientes.

6 Alcance y limitaciones declaradas

- **No se afirma** que los indicadores hayan sido aprobados definitivamente para PCA.
- **No se afirma** que se haya ejecutado un Análisis de Componentes Principales (PCA).
- **No se afirma** que exista un Índice de Vulnerabilidad Socioeconómica (IVS) definitivo.
- **No se afirma** que se haya seleccionado definitivamente la estructura factorial.
- **No se afirma** que se haya realizado validación estadística definitiva del índice.
- **No se afirma** que SECOP II haya sido integrado.
- **No se afirma** que se haya realizado análisis espacial.

Cuando una etapa esté pendiente, se identifica explícitamente en la sección 96 y en la tabla de estado del proyecto (Sección 105).

7 Estructura del documento

El informe sigue una estructura académica estándar para tesis de Estadística aplicada / investigación cuantitativa, organizada en secciones que cubren: planteamiento metodológico, marco conceptual, fuentes, unidad de análisis, proceso de selección de bases, tratamiento de faltantes, construcción de indicadores, control de calidad, diagnóstico preliminar, preparación para PCA, reproducibilidad, limitaciones, estado del proyecto y conclusiones metodológicas.

8 Planteamiento metodológico

9 Pregunta de investigación

¿Existe una correspondencia entre la distribución territorial de la contratación pública y las condiciones de vulnerabilidad socioeconómica de los municipios colombianos?

10 Objetivo general

Analizar la correspondencia territorial entre la contratación pública (SECOP II) y la vulnerabilidad socioeconómica municipal, mediante la construcción de un Índice de Vulnerabilidad Socioeconómica (IVS) basado en Análisis de Componentes Principales (PCA) sobre indicadores derivados del CNPV 2018, validado externamente con el IPM 2018.

11 Objetivos específicos

1. Auditar y homologar las fuentes de información territorial y socioeconómica (CNPV 2018, IPM 2018, DIVIPOLA) a nivel municipal.
2. Construir indicadores socioeconómicos municipales comparables, con fórmulas explícitas, poblaciones de referencia definidas y dirección de vulnerabilidad orientada.
3. Realizar control de calidad estructural y estadístico de los indicadores (consistencia, cobertura, rangos, outliers, correlaciones, aptitud multivariada).
4. Evaluar la adecuación de la matriz de indicadores para Análisis de Componentes Principales (KMO, Bartlett, MSA, estructura de correlaciones, distribución).
5. Ejecutar PCA, seleccionar componentes, interpretar cargas y construir el IVS (etapa **pendiente**).
6. Validar el IVS externamente mediante correlación con el IPM municipal agregado, evitando circularidad (etapa **pendiente**).
7. Integrar datos de contratación pública SECOP II a nivel municipal-año (etapa **pendiente**).
8. Analizar la asociación/correspondencia entre IVS y patrones de contratación pública (etapa **pendiente**).
9. Realizar análisis espacial condicionado a resultados previos (etapa **pendiente**).

12 Unidad de análisis

El **municipio** es la unidad de análisis. Se utilizan los 1.122 códigos municipales presentes en el CNPV 2018 y el IPM 2018, identificados mediante `codigo_municipio` como texto de cinco caracteres (formato DIVIPOLA). No se fusionan ni excluyen códigos en los datos de 2018; los conflictos territoriales se reservan para un *crosswalk* futuro con SECOP II (ver `resultados/base_trabajo/crosswalk_enlace.csv`).

13 Alcance del estudio

- **Cobertura territorial:** 1.122 municipios de Colombia según CNPV/IPM 2018.
- **Período de referencia:** Año censal 2018 (fotografía transversal).
- **Dimensión analítica:** Vulnerabilidad socioeconómica medida mediante indicadores censales.
- **Variables excluidas del alcance actual:** Contratación pública (SECOP II), análisis longitudinal, inferencia causal.

14 Naturaleza del análisis

El análisis es **descriptivo y asociativo**. No se realizan inferencias causales. El PCA se plantea como técnica de reducción de dimensionalidad y síntesis de información socioeconómica multidimensional; el IVS resultante sería un indicador compuesto de vulnerabilidad. La validación externa con IPM y la asociación con SECOP II son pasos posteriores de validación y análisis sustantivo, respectivamente.

15 Marco metodológico y conceptual

16 Vulnerabilidad socioeconómica

La vulnerabilidad socioeconómica se entiende aquí como la **propensión de una población territorial a experimentar privaciones en múltiples dimensiones del bienestar** (salud, educación, trabajo, vivienda, servicios públicos, ingreso), de modo que la ocurrencia de eventos adversos o la ausencia de capacidades de respuesta generan deterioros sostenidos en las condiciones de vida (Alkire et al., 2011; CEPAL, 2016).

A diferencia de la pobreza monetaria unidimensional, el enfoque de vulnerabilidad adopta una perspectiva **multidimensional, relacional y territorial**: las privaciones se manifiestan en combinaciones específicas según el contexto local, y la capacidad de respuesta depende de activos individuales, colectivos e institucionales disponibles en el territorio (Sen, 1999; Rodríguez et al., 2010).

17 Medición multidimensional

La medición de la vulnerabilidad socioeconómica requiere:

1. **Selección de dimensiones y indicadores** teóricamente fundados y empíricamente observables.
2. **Construcción de indicadores comparables** a nivel municipal (tasas, proporciones, índices normalizados).
3. **Agregación** que respete la multidimensionalidad (evitando compensabilidad indebida entre dimensiones).
4. **Validación** interna (consistencia estadística) y externa (con criterios independientes).

En el contexto colombiano, el **Índice de Pobreza Multidimensional (IPM)** del DANE constituye el referente oficial (DANE, 2019). El IPM 2018 incluye 15 privaciones agrupadas en 5 dimensiones (educación, niñez y juventud, trabajo, salud, vivienda y servicios públicos). Este proyecto **no replica el IPM**; construye un índice sintético propio (IVS) a partir de indicadores censales complementarios y no redundantes con el IPM, reservando al IPM la función de *validación externa posterior* (Sección 23).

18 Indicadores socioeconómicos

Un indicador socioeconómico municipal debe cumplir:

- **Relevancia:** Captar una faceta de vulnerabilidad (privación, carencia, rezago, exclusión).
- **Comparabilidad:** Mismo denominador conceptual y escala homogénea (proporción $[0, 1]$ o tasa por 10^3/ 10^4 hab.).
- **Direccionalidad:** Valor alto $\Rightarrow$ mayor vulnerabilidad (o se documenta la excepción).
- **Independencia relativa:** Baja colinealidad con otros indicadores de la matriz; no duplicar privaciones ya capturadas por el IPM si se busca validación externa no circular.
- **Disponibilidad:** Observado para la totalidad (o casi totalidad) del universo municipal.

19 Reducción de dimensionalidad y PCA

El Análisis de Componentes Principales (PCA) es una técnica de **reducción de dimensionalidad** que transforma un conjunto de variables correlacionadas en un conjunto menor de componentes no correlacionados (componentes principales), combinaciones lineales de las variables originales que explican la máxima varianza posible (Jolliffe, 2002; Abdi and Williams, 2010).

En el contexto de índices compuestos de vulnerabilidad, el PCA se utiliza para:

- Identificar la estructura común latente entre indicadores.
- Sintetizar la información en pocos componentes (idealmente el primer componente, PC1).
- Construir un índice sintético (scores del PC1) ponderado por la estructura de covarianzas/correlaciones de los datos, no por pesos arbitrarios.

Supuestos y precauciones críticas:

1. **Adecuación multivariada:** KMO global $> 0,6$ (idealmente $> 0,7$), MSA individual $> 0,5$, Bartlett significativa (Kaiser, 1974).
2. **Linealidad y correlaciones:** El PCA captura estructura lineal; correlaciones muy altas ($|r| > 0,9$) indican redundancia; correlaciones muy bajas sugieren ausencia de factor común.
3. **Distribución:** Asimetría y curtosis extremas pueden distorsionar componentes; se evalúan transformaciones (log, raíz cuadrada, winsorización).
4. **Escalado:** Se estandarizan variables (media 0, desviación 1) cuando tienen unidades o rangos distintos; aquí todas son proporciones $[0, 1]$.

5. **Interpretabilidad:** El PC1 debe representar un constructo teóricamente coherente ("vulnerabilidad general"), no un artefacto matemático.

6. **No circularidad con validación externa:** Si el IPM se usa para validar el IVS, los indicadores que replican directamente privaciones del IPM deben excluirse de la matriz PCA o tratarse con extrema cautela (Booysen, 2002).

Estado actual: Los diagnósticos preliminares (KMO $\approx 0,642$, Bartlett $p < 0,001$, determinante $\approx 0,0154$, MSA estrato 1–2 $\approx 0,414$) son **insuficientes** para aprobar el PCA. La auditoría estadística integral está pendiente (Sección 97).

20 Relación futura con contratación pública (SECOP II)

La integración con SECOP II es una etapa **posterior y condicionada** a la consolidación del IVS. El diseño metodológico previsto contempla:

- **Unidad de análisis municipal-año:** Panel de municipios (1.122) $\times$ años (ventana exploratoria 2015–2025).
- **Indicadores SECOP II:** Valor total contratado, número de contratos, concentración (Herfindahl), tipos de contrato, sectores, adjudicatarios.
- **Denominadores:** PIB municipal, población, presupuesto municipal, o valor total de contratación nacional como referencia.
- **Análisis de asociación:** Correlaciones, modelos de panel, análisis de correspondencia, pruebas de hipótesis sobre focalización.
- **Análisis espacial:** Autocorrelación espacial (Moran's I), modelos espaciales, clústeres de vulnerabilidad-contratación, solo si el diagnóstico lo justifica.

El `crosswalk_enlace.csv` documenta las equivalencias territoriales pendientes para este enlace futuro (códigos 94663 $\rightarrow$ 94343, hipótesis 27493 $\rightarrow$ 27615).

21 Fuentes de información

22 Censo Nacional de Población y Vivienda 2018 (CNPV 2018)

El CNPV 2018 es la fuente primaria de información sociodemográfica y de vivienda a nivel municipal. Se utilizaron cuatro de los seis tomos temáticos publicados por el DANE:

Cuadro 1: *Fuentes CNPV 2018 utilizadas*

Tomo	Archivo original	Cuadros municipales seleccionados	Uso principal
Hogares	`HOGARES_Cuadros_CNPV_2018.XLSX`	1HM, 2HM	Estructura hogares: menores 15 años, adultos 60+
Personas Demográfico	`PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx`	1PM, 17PM	Población total (denominadores), nivel educativo
Personas Social	`PERSONAS_SOCIAL_Cuadros_CNPV_2018.XLSX`	5PM	Actividad laboral (desocupación, inactividad)
Viviendas	`VIVIENDAS_Cuadros_CNPV_2018.XLSX`	1V_MPIO, 6V_MPIO, 8V_MPIO, 10V_MPIO	Condición ocupación, materiales, servicios, estrato

Los cuadros departamentales y nacionales fueron **descartados** por no corresponder a la unidad de análisis municipal. La selección de cuadros y variables se documenta en `docs/diccionario/decisiones_variables_` (115 filas, con decisión, motivo y notas de verificación).

23 Índice de Pobreza Multidimensional 2018 (IPM 2018)

El IPM 2018 organizado por región (`IPM_2018_organizado_region.xlsx`) contiene:

- Hoja `IPM_municipios_region`: 1.122 municipios × 15 indicadores de privación + IPM Municipal (agregado).
- Hojas por dominio geográfico (Cabeceras, Centros poblados y Rural disperso) — **no usadas para PCA**, solo para análisis de brechas urbano-rural futuras.
- Diccionarios y controles de calidad internos.

Uso en el proyecto:

- **Validación externa futura:** El IPM Municipal agregado se reserva como criterio de validación del IVS (Sección 23). **No entra al PCA** para evitar circularidad.
- **Exclusión de indicadores redundantes:** Las 15 privaciones del IPM se compararon con los indicadores censales candidatos; aquellas que replican directamente conceptos del IPM (ej. material inadecuado de paredes, hacinamiento, agua, alcantarillado, analfabetismo, rezago escolar, inasistencia, barreras primera infancia, trabajo infantil, informalidad, dependencia, barreras salud, aseguramiento, pisos) se marcaron como `DESCARTAR` o `DESCRIPCIÓN` en la especificación de indicadores, según el criterio documentado en `decisiones_variables_IVS_CNPV2018.csv`.

24 DIVIPOLA – Códigos municipales

Archivo: `DIVIPOLA-_Codigos_municipios_20260917.csv` (82.076 bytes).

- Provee la lista maestra de códigos municipales (5 dígitos), nombres, departamentos y tipos de cabecera.
- Se utiliza como **referencia territorial** para homologación y verificación de cobertura.
- Los 1.122 códigos del universo CNPV/IPM 2018 se validan contra DIVIPOLA; las discrepancias (ej. códigos 94663, 27493, 18 áreas no municipalizadas – ANM) se documentan y **no se resuelven en la base 2018**, reservándose para el *crosswalk* SECOP.

25 SECOP II – Contratación pública (fuente futura)

El Sistema Electrónico de Contratación Pública (SECOP II) es la fuente de datos de contratación pública a nivel nacional. **No se ha integrado aún**. Su incorporación está planificada como etapa posterior (Sección 20). Requiere:

- Obtención de datos (parquet trimestrales, API, o descarga masiva).
- Definición de ventana temporal (exploratoria 2015–2025).
- Construcción de indicadores municipales-año (valor, número, concentración, sectores).
- *Crosswalk* territorial con códigos 2018 (ver `crosswalk_enlace.csv`).

26 Justificación de las fuentes

Cuadro 2: *Justificación de fuentes utilizadas*

Fuente	Justificación	Limitaciones reconocidas
CNPV 2018	Cobertura censal universal; desglose municipal; variables de vivienda, demografía, educación, trabajo, hogares.	Fotografía 2018; no captura dinámicas recientes; algunas variables con categorías NR amplias.
IPM 2018	Referente oficial de pobreza multidimensional; 15 privaciones validadas; disponible a nivel municipal.	Agrega privaciones en un índice; usar sus componentes en PCA generaría circularidad si se valida con el agregado.
DIVIPOLA	Estándar oficial de códigos territoriales; permite homologación y trazabilidad.	Versión 2026 vs. datos 2018: cambios administrativos recientes no reflejados en datos censales.
SECOP II	Fuente primaria de contratación pública; detalle contractual, temporal, geográfico.	Pendiente de obtención, limpieza, agregación municipal y definición de denominadores.

27 Unidad territorial y universo de análisis

28 Municipio como unidad de análisis

El municipio es la unidad territorial básica de la organización político-administrativa colombiana (Constitución de 1991, Art. 286; Ley 136 de 1994). Es el nivel donde convergen:

- Competencias en prestación de servicios públicos (educación, salud, agua, saneamiento).
- Ejecución de contratación pública local y departamental.
- Disponibilidad de información censal y estadística oficial desagregada.
- Identidad territorial para análisis de vulnerabilidad y políticas públicas.

La elección del municipio (y no el departamento, la localidad o el corregimiento) responde a la necesidad de **comparabilidad nacional** y **coherencia con la unidad de contratación pública** (SECOP II registra entidad contratante y lugar de ejecución a nivel municipal).

29 Códigos territoriales

- **Formato:** `codigo_municipio` como **texto de 5 caracteres** (DIVIPOLA), p.ej. "11001" (Bogotá), "05001" (Medellín).
- **Nunca se usa el nombre municipal como llave** (riesgo de homónimos, variaciones ortográficas, cambios de nombre).
- **Longitud fija:** Se valida que todos los códigos tengan 5 caracteres; se completan con ceros a la izquierda si es necesario.
- **Consistencia entre fuentes:** La unión entre tablas CNPV, IPM y DIVIPOLA se realiza exclusivamente por `codigo_municipio`.

30 Cobertura municipal

El universo de trabajo adoptado son los **1.122 códigos municipales** que tienen datos en el CNPV 2018 y el IPM 2018. Esta cifra se valida en `resultados/base_trabajo/validaciones.csv` (validación "Llave/prefijo ipm_municipal_ancho": 1.122 evaluados, 0 violaciones).

Cuadro 3: *Universo municipal y cobertura*

Concepto	Cantidad	Fuente/Evidencia
Municipios en CNPV 2018 (cuadros municipales)	1.122	universo_municipal_maestro.csv
Municipios en IPM 2018 (hoja municipal)	1.122	validaciones.csv
Municipios en DIVIPOLA 20260917	≈1.122	DIVIPOLA-_Codigos_municipios_20260917.csv
Coincidencia CNPV ∩ IPM	1.122	Final_Base.md, validaciones

31 Coincidencias entre fuentes

La homologación territorial entre CNPV 2018, IPM 2018 y DIVIPOLA se realizó mediante codigo_municipio. Los controles de llave/prefijo en validaciones.csv reportan **cero violaciones** para todas las tablas intermedias (contexto_1PM, contexto_1V, hogares_1HM_2HM, persona_demo_17PM, persona_social_5PM, viviendas_6V, viviendas_8V, viviendas_10V, ipm_municipal_ancho).

32 No coincidencias y casos especiales

A pesar de la coincidencia en el conteo total (1.122), existen **diferencias estructurales** que no son errores sino consecuencias de definiciones territoriales distintas:

32.1 Municipios sin cabecera (20 casos)

Veinte municipios no tienen área "Cabecera" censada en 2018. Estos coinciden exactamente con los **20 valores NA estructurales del IPM para Cabeceras** (validación "20 NA IPM cabeceras = municipios sin cabecera": 20 evaluados, 0 violaciones).

- 18 corresponden a **Áreas No Municipalizadas (ANM)** en DIVIPOLA 2026.
- 2 códigos adicionales: 94343 (Barrancominas, 7.207 hab.) y 94663 (Mapiripana, 1.011 hab.), cuya población rural dispersa suma 8.218 hab.
- Población total en los 20 municipios sin cabecera: **34.787 habitantes** (incluye 26.569 en las 18 ANM + 8.218 en los dos códigos adicionales).
- Proporción rural dispersa en estos municipios: 47,27 % – 100 %.
- Detalle en resultados/base_trabajo/municipios_sin_cabecera.csv y resumen_sin_cabecera_depar

32.2 Código 94663 (Mapiripana) – Relación con 94343 (Barrancominas)

- Documentado para la capa SECOP futura: 94663 → 94343.

- En los datos CNPV/IPM 2018 **permanecen ambos códigos separados**; no se fusionan ni reasignan conteos.
- Ver `Final_Base.md` y `crosswalk_enlace.csv`.

32.3 Código 27493 (Nuevo Belén de Bajirá) – Conflicto territorial

- Se propone `27615` (Riosucio) como "padre" territorial, **pendiente de verificación DANE/IGAC**.
- Existe conflicto histórico con `05480` (Mutatá).
- Evidencia compatible: Riosucio suma 48.257 habitantes y un centro poblado de 13.504; Mutatá suma 12.607. No prueba el límite; **no se fraccionan ni reasignan conteos CNPV**.
- Ver `Final_Base.md` y `crosswalk_enlace.csv`.

32.4 Municipios sin centro poblado (192 casos)

192 municipios no tienen área "Centro poblado" en 2018. Se conservan como **cobertura territorial estructural**; no son faltantes estadísticos. Ver `Final_Base.md` (validación "Municipios sin Centro poblado": 192, PASS).

32.5 Áreas territorialmente inexistentes

El archivo `resultados/base_trabajo/areas_inexistentes.csv` documenta, por municipio, qué áreas (Cabecera, Centro poblado, Rural disperso) no existen. Esto permite distinguir **ausencia estructural** (el área no existe en el territorio) de **faltante estadístico** (el dato no se capturó). Ejemplo: en un municipio 100 % urbano, la ausencia de "Rural disperso" es estructural, no un dato que deba imputarse.

32.6 Ausencias estructurales en combinaciones demográficas

- **Grupos de edad:** 335 combinaciones municipio-área-grupo de edad ausentes en 1PM (119 municipios afectados). Ver `ausencias_estructurales_1PM.csv`.
- **Tipo de vivienda:** 1.202 combinaciones ausentes.
- **Tratamiento:** Se completan como **ceros estructurales** y se marcan con *flags*; **no se imputan** estadísticamente. No se crean filas para áreas inexistentes.

33 Resumen de decisiones territoriales

Cuadro 4: *Decisiones territoriales clave*

Aspecto	Decisión	Evidencia
Universo municipal	1.122 códigos CNPV/IPM 2018, sin fusiones	`Final_Base.md`, `universo_municipal_maestro.csv`
Llave de unión	`codigo_municipio` (texto 5 chars)	`R/01_verificar_consolidados.R`
Municipios sin cabecera (20)	Conservados; NA estructural en IPM Cabecera	`municipios_sin_cabecera.csv`
Código 94663	Relación futura 94663 → 94343 (solo enlace SECOP)	`crosswalk_enlace.csv`
Código 27493	Hipótesis 27615 como padre; conflicto con 05480; sin reasignar	`crosswalk_enlace.csv`
Ausencias estructurales	Ceros estructurales con flags; no imputación	`ausencias_estructurales_1PM.csv`, `areas_inexistentes.csv`
Cobertura 5PM / pob_10mas	28 municipios con cobertura $< 0,9$ (umbral configurable)	`validaciones.csv`, `R/00_config.R`

34 Proceso de selección y depuración de bases

35 Inventario inicial

Se partió de **seis archivos fuente originales** del CNPV 2018 provistos por el DANE:

1. `HOGARES_Cuadros_CNPV_2018.XLSX` (976.096 bytes)
2. `PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx` (140.535.605 bytes)
3. `PERSONAS_SOCIAL_Cuadros_CNPV_2018.XLSX` (222.529.081 bytes)
4. `VIVIENDAS_Cuadros_CNPV_2018.XLSX` (8.406.337 bytes)
5. `anexo-censal-pobreza-municipal-2018.xlsx` (1.295.335 bytes) – Anexo metodológico IPM
6. `IPM_2018_organizado_region.xlsx` (2.137.634 bytes) – IPM ya procesado por región

El inventario de hojas, columnas y estructura se generó con `R/01_verificar_consolidados.R` y se documenta en `datos/intermedio/nombres_columnas_fuente.csv` y `resultados/verificacion_consolid`

36 Inspección de hojas/cuadros

Cada archivo Excel contiene múltiples hojas (cuadros) a diferentes niveles geográficos (nacional, departamental, municipal). La inspección identificó:

- **Nivel municipal:** Hojas con sufijo `_MPIO` o `_PM` / `_HM` / `_VM`.
- **Nivel departamental:** Sufijo `_DPTO` o `_PD` / `_HD` / `_VD` – **descartados**.
- **Nivel nacional:** Sin desagregación municipal – **descartados**.

37 Selección de cuadros relevantes

De los cientos de cuadros disponibles, se seleccionaron **8 cuadros municipales** basados en su relevancia para construir indicadores de vulnerabilidad socioeconómica no redundantes con el IPM:
* 17PM tiene nota de verificación pendiente: el índice del DANE lo describe como “asistencia escolar” (igual que 18PM), mientras que 17PD trata “nivel educativo”. Si es asistencia escolar, duplica Inasistencia escolar del IPM y debe reconsiderarse. Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 37.

Cuadro 5: *Cuadros seleccionados del CNPV 2018*

Fuente	Archivo	Cuadro/Hoja	Contenido principal	Decisión
HOGARES	HOGARES_Cuadros_CNPV_2018.XLSX	1HM	Hogares con menores <15 años por área	INCLUIDA
HOGARES	HOGARES_Cuadros_CNPV_2018.XLSX	2HM	Hogares con adultos ≥60 años por área	INCLUIDA
PERSONAS_DEMOGRAFICO	PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx	1PM	Población total por sexo y grupos de edad	CONTEXTO (denominador)
PERSONAS_DEMOGRAFICO	PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx	17PM	Población 5+ por asistencia escolar y sexo	INCLUIDA*
PERSONAS_SOCIAL	PERSONAS_SOCIAL_Cuadros_CNPV_2018.XLSX	5PM	Población 10+ por actividad realizada la semana anterior	INCLUIDA
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	1V_MPIO	Viviendas por condición de ocupación	CONTEXTO (denominador)
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	6V_MPIO	Viviendas ocupadas por material paredes exteriores	INCLUIDA
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	8V_MPIO	Viviendas ocupadas por disponibilidad servicios públicos	INCLUIDA
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	10V_MPIO	Personas en hogares por estrato de energía	INCLUIDA

38 Selección de variables

Para cada cuadro seleccionado, se identificaron las variables (columnas) necesarias para construir numeradores y denominadores de los indicadores. La especificación completa está en `resultados/base_trabajo/espe` (14 indicadores candidatos con fuente, cuadro, numerador, denominador, población de referencia, dirección esperada y propuesta de inclusión).

39 Criterios de inclusión

1. **Nivel geográfico municipal:** El cuadro debe tener desagregación municipal.
2. **Relevancia para vulnerabilidad:** La variable captura una privación, carencia, rezago o exclusión (ej. hogares con menores, desocupación, vivienda sin servicios, estrato bajo).
3. **No redundancia con IPM:** No replica directamente una de las 15 privaciones del IPM, o si lo hace, se marca para **descripción/validación** (no para PCA).
4. **Disponibilidad de denominador:** Existe población de referencia clara en el mismo cuadro o en cuadro vinculado (1PM, 1V_MPIO).
5. **Calidad de la variable:** Sin problemas insalvables de cobertura, ceros estructurales masivos, o ambigüedad conceptual.

40 Criterios de exclusión

1. **Nivel geográfico no municipal:** Departamental, nacional.
2. **No mide privación:** Variables de composición familiar (jefatura, tipología hogar, estado civil, fecundidad, parentesco, autorreconocimiento étnico, territorialidad étnica, migración).
3. **Redundancia con IPM:** Duplican directamente una privación del IPM (ej. analfabetismo, rezago escolar, inasistencia, barreras primera infancia, trabajo infantil, informalidad, dependencia, hacinamiento, material paredes/pisos, agua, alcantarillado, barreras salud, aseguramiento).

4. **Subpoblación pequeña / celdas fragmentadas:** Discapacidad (grados, causas, ayudas), tipologías de hogar generacional/ciclo de vida.

5. **Descripción dudosa / error en índice:** 19PM (descripción idéntica a 18PM).

6. **Edades simples (3PM):** Archivo pesado, celdas pequeñas; se reconstruye desde 1PM.

Estos criterios se aplicaron sistemáticamente y se documentaron en `decisiones_variables_IVS_CNPV2018.c` (columna `decision`: INCLUIDA, CONTEXTO, VALIDACIÓN, DESCARTAR; columna `motivo` y `razon`).

41 Homologación territorial

1. Todas las tablas se leen conservando `codigo_municipio` como **texto de 5 caracteres**.

2. Se construye un **universo maestro municipal** (`universo_municipal_maestro.csv`) con los 1.122 códigos.

3. Cada tabla intermedia se valida contra el universo maestro (llave/prefijo, cobertura).

4. Las discrepancias territoriales (94663, 27493, municipios sin cabecera, ANM) se documentan en `crosswalk_enlace.csv` y **no se aplican a los conteos 2018**.

42 Consolidación

El proceso de consolidación, ejecutado por `R/02_base_final_indicadores.R` (configurado en `R/00_config.R`), produce:

- **Tablas de contexto (denominadores):** `contexto_1PM.csv`, `contexto_1V.csv` (poblaciones de referencia).

- **Tablas de indicadores en base total y base válida:** Para cada indicador sensible a NR, dos versiones (ver Sección 43).

- **Matrices candidatas para PCA:** `matriz_base_total.csv`, `matriz_base_valida.csv` (1.122 filas $\times$ 7 indicadores candidatos).

- **Archivos de diagnóstico y control:** 25 CSV en `resultados/base_trabajo/` (ver lista en introducción).

- **Integridad de insumos:** Hashes MD5 antes y después (`md5_insumos_antes.csv`, `md5_insumos_despues.csv`) confirman **sin cambios** en los archivos de entrada monitoreados.

La consolidación se documenta en `Final_Base.md` y `Estructura_Bases.md`.

43 Tratamiento de datos faltantes

44 Definición de faltante

En este proyecto, "dato faltante" no es una categoría única. Se distingue rigurosamente entre:

1. **Faltante estadístico (NA):** Valor no disponible en la fuente para una combinación municipio-área-variable que *debería* existir.
2. **No respuesta (NR):** Categoría explícita del instrumento censal ("No informa", "Sin información", "No sabe/No responde"). Es un dato observado, no un hueco.
3. **Ausencia estructural:** La unidad territorial o la combinación demográfica *no existe* (ej. área Rural disperso en municipio 100 % urbano; grupo de edad 85+ en municipio pequeño).
4. **Denominador cero:** La población de referencia para construir un indicador es cero (ej. ningún hogar en un área).
5. **Caso 0/0:** Numerador y denominador son cero → cociente indefinido.

45 No respuesta (NR)

Los ítems clasificados como NR en los cuadros censales se tratan como **cuestión de calidad del dato**, no como faltante para imputar. Se conservan dos definiciones de denominador, generando **dos versiones de cada indicador sensible a NR**:

- **Base total:** El denominador **incluye** la categoría NR. Ej: $\frac{\text{hogares sin energía}}{\text{total hogares (incl. NR)}}$.
- **Base válida:** El denominador **excluye** la categoría NR (resta NR al total). Ej: $\frac{\text{hogares sin energía}}{\text{total hogares} - \text{NR}}$.

Estos son **escenarios de sensibilidad**, no una decisión definitiva de tratamiento. La elección final se tomará tras revisar `sensibilidad_nr.csv` y `sensibilidad_nr_municipio.csv`.

45.1 Distinción: `no_tiene_estrato` vs. `no_sabe_no_responde`

El ítem "No tiene estrato" (viviendas en zona rural sin asignación de estrato energético) **no se agrupa** con "No sabe/No responde". Se mantiene separado porque:

- Es una **condición estructural** (ruralidad), no una negativa a responder.

- Su prevalencia es alta en zona rural y su tratamiento como NR sesgaría indicadores de estrato 1–2.
- Se documenta en `nr_item_municipal.csv` y se analiza su sensibilidad aparte.

46 Ausencia estructural

- **Áreas inexistentes:** 20 municipios sin Cabecera, 192 sin Centro poblado, municipios sin Rural disperso. Ver `areas_inexistentes.csv`. **No se crean filas** para estas áreas; se documentan como NA estructural.
- **Combinaciones demográficas ausentes:** 335 combinaciones municipio-área-grupo de edad ausentes en 1PM (119 municipios); 1.202 combinaciones de tipo de vivienda ausentes. Ver `ausencias_estructural`
- **Tratamiento:** Se completan como **ceros estructurales** y se marcan con *flags* (ej. `flag_ausencia_estructural_e` `flag_ausencia_estructural_vivienda`). **No se imputan** valores estadísticamente.
- **Justificación:** Una ausencia estructural no debe interpretarse como ausencia del fenómeno socioeconómico. Imputar ceros donde no existe la población de referencia crearía indicadores espurios.

47 Denominadores nulos

Cuando el denominador de un indicador es cero (población de referencia inexistente en ese municipio-área):

- El resultado del indicador se guarda como `NA`.
- Se genera `flag_indice_indefinido = TRUE`.
- El municipio se mantiene en la base (no se elimina), pero el indicador no contribuye a análisis multivariado para ese caso.

48 Casos 0/0

Cuando numerador = 0 y denominador = 0 simultáneamente (ej. cero hogares sin energía y cero hogares totales en un área):

- El cociente es matemáticamente indefinido.
- Se guarda como `NA` y se señaliza con `flag_indice_indefinido`.
- No se convierte en 0 ni en 1; permanece como **indeterminado**.

49 Municipios sin determinadas áreas

Los 20 municipios sin cabecera y los 192 sin centro poblado se conservan en el universo. Sus indicadores para las áreas inexistentes son NA estructural. Para el análisis municipal agregado (nivel Total), se usan los totales municipales que **sí existen** (población total, hogares totales, viviendas totales). La proporcionalidad rural/urbana se documenta en `municipios_sin_cabecera.csv` (columna `pct_rural_disperso`).

50 Decisiones de tratamiento adoptadas

Cuadro 6: *Resumen de decisiones sobre faltantes*

Situación	Interpretación	Tratamiento en el proyecto
Dato no disponible en fuente (NA)	Faltante estadístico	Conservado como NA; no imputado
Categoría NR explícita	No respuesta del informante	Base total (incluye NR) y base válida (excluye NR); escenarios de sensibilidad
Área territorial inexistente	Ausencia estructural	No se crea fila; NA estructural; no imputado
Combinación demográfica ausente	Ausencia estructural	Cero estructural + flag; no imputado
Denominador = 0	Indefinición matemática	Resultado NA + `flag_indice_indefinido`
Numerador = 0, Denominador = 0	0/0 indeterminado	NA + `flag_indice_indefinido`
IPM Cabecera en 20 municipios	Ausencia estructural (sin cabecera)	20 NA estructurales conservados; cotejados con `municipios_sin_cabecera.csv`

51 Justificación de no imputación

1. **Naturaleza censal:** El CNPV es un censo universal; los "faltantes" son principalmente ausencias estructurales o NR, no omisiones aleatorias.

2. **Análisis territorial:** Imputar valores en municipios pequeños o áreas inexistentes introduciría sesgo espacial artificial.

3. **Transparencia y trazabilidad:** Los *flags* y la dualidad base total/base válida permiten evaluar la sensibilidad de cualquier decisión posterior (PCA, IVS) al tratamiento de NR.

4. **Principio de precaución:** Ante ausencia de modelo de imputación validado para datos censales territoriales, la no imputación es la opción más conservadora y reproducible.

La decisión final sobre qué versión (base total o base válida) usar en el PCA queda **pendiente** y se basará en la sensibilidad documentada (`sensibilidad_nr.csv`, `sensibilidad_nr_municipio.csv`) y en la evaluación de adecuación multivariada de cada matriz.

52 Construcción de indicadores socioeconómicos

53 Principios de construcción

Todo indicador se construye siguiendo el esquema:

$$I_j = \frac{N_j}{D_j} \tag{1}$$

donde I_j es el indicador j, N_j el numerador (conteo de la condición de vulnerabilidad) y D_j el denominador (población de referencia). Cuando el indicador es una proporción, $I_j \in [0, 1]$. Cuando es una tasa, se expresa por 10^3 o 10^4 habitantes según la magnitud.

Los principios rectores son:

1. **Transparencia de fórmula:** Numerador, denominador y población de referencia explícitos en `especificacion_indicadores.csv`.
2. **Comparabilidad municipal:** Mismo denominador conceptual para todos los municipios.
3. **Escala homogénea:** Proporciones $[0, 1]$ para indicadores PCA; tasas estandarizadas para descripción.
4. **Dirección de vulnerabilidad:** Valor alto $\Rightarrow$ mayor vulnerabilidad (Sección 58).
5. **Tratamiento de NR:** Dos versiones (base total / base válida) para indicadores con categoría NR (Sección 43).
6. **Denominador cero $\rightarrow$ NA + flag:** No se imputa, no se elimina el municipio.

54 Numeradores

Los numeradores son conteos directos de las condiciones de vulnerabilidad extraídos de los cuadros censales seleccionados:

- `1HM`: Hogares con personas menores de 15 años (Total, Cabecera, Centro poblado, Rural disperso).
- `2HM`: Hogares con personas de 60 años y más (Total, Cabecera, Centro poblado, Rural disperso).
- `5PM`: Personas de 10 años y más por actividad realizada la semana anterior (Ocupado, Desocupado, Inactivo, por sexo).

- `6V`: Viviendas ocupadas con personas presentes por material predominante de paredes exteriores.
- `8V`: Viviendas ocupadas con personas presentes por disponibilidad de servicios públicos (Energía, Gas, Acueducto, Alcantarillado, Recolección, Internet).
- `10V`: Personas censadas en hogares particulares por estrato de energía (1, 2, 3, 4, 5, 6, Sin estrato).
- `17PM`: Población de 5 años y más por asistencia escolar y sexo (pendiente verificación: ¿nivel educativo o asistencia?).

55 Denominadores y poblaciones de referencia

Cuadro 7: *Denominadores por indicador*

Indicador	Denominador	Fuente denominador
Prop. hogares con menores	Total hogares (1HM Total)	1HM
Prop. hogares con adultos 60+	Total hogares (1HM Total)	1HM
Tasa desocupación (10+)	Población 10+ años (1PM)	1PM (grupos 10+)
Tasa inactividad (10+)	Población 10+ años (1PM)	1PM (grupos 10+)
Prop. viviendas sin energía	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin gas	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin recolección	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin internet	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. hogares estrato 1-2	Personas en hogares particulares (10V Total)	10V
Prop. población 5+ nivel educativo	Población 5+ años (17PM Total = 1PM 5+)	17PM / 1PM
Prop. viviendas material paredes inadecuado	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin acueducto	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin alcantarillado	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO

56 Verificación de población de referencia

- El total de `17PM` coincide exactamente con la población de 5+ años de `1PM` en los 1.122 municipios (validación “Diferencias total 17PM vs población 5+ 1PM”: 0, PASS). Ver `Final_Base.md`.
- `17PM` **no permite** filtrar categorías de nivel educativo restringidas a población de 10+ años; se calculan usando el total de 17PM y se documenta la discrepancia.
- `pob_10mas` se calculó desde los grupos de 1PM de 10 años o más; la cobertura de 5PM se coteja contra ese valor (28 municipios con cobertura $< 0,9$).

57 Escala

- **Indicadores para PCA (provisionales):** Proporciones $[0, 1]$ (7 indicadores).

- **Indicadores de descripción/solapamiento IPM:** Proporciones $[0, 1]$ (7 indicadores).
- **No se usan conteos absolutos** en la matriz PCA (no son comparables entre municipios de distinto tamaño).

58 Dirección de vulnerabilidad

La decisión metodológica es orientar los indicadores para que:

$$\text{valor alto} \Rightarrow \text{mayor vulnerabilidad} \tag{2}$$

Cuadro 8: *Dirección de vulnerabilidad por indicador*

Indicador	Dirección	Nota
Prop. hogares con menores 15	Alto = mayor vuln.	Carga demográfica infantil
Prop. hogares con adultos 60+	**Pendiente**	Correlación negativa con privaciones IPM ($-0,06$ a $-0,63$); puede ser transición demográfica
Tasa desocupación 10+	Alto = mayor vuln.	Privación laboral
Tasa inactividad 10+	Alto = mayor vuln.	Privación laboral
Prop. viviendas sin energía	Alto = mayor vuln.	Privación servicios
Prop. viviendas sin gas	Alto = mayor vuln.	Privación servicios
Prop. viviendas sin recolección	Alto = mayor vuln.	Privación servicios
Prop. viviendas sin internet	Alto = mayor vuln.	Privación conectividad
Prop. hogares estrato 1-2	Alto = mayor vuln.	Proxy ingreso bajo
Prop. población 5+ bajo nivel educativo	Alto = mayor vuln.	Privación capital humano (si 17PM es nivel educativo)
Prop. viviendas paredes inadecuadas	Alto = mayor vuln.	Privación vivienda (duplica IPM)
Prop. viviendas sin acueducto	Alto = mayor vuln.	Privación servicios (duplica IPM)
Prop. viviendas sin alcantarillado	Alto = mayor vuln.	Privación servicios (duplica IPM)

Nota crítica: El indicador "Hogares con adultos 60+" muestra correlación **negativa** con casi todas las privaciones del IPM (Spearman $-0,06$ a $-0,63$): los municipios más envejecidos tienden a ser *menos* vulnerables. Su dirección debe definirse conceptualmente antes del PCA (puede comportarse como variable de transición demográfica, no de privación). Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 5.

59 Indicadores seleccionados (matriz candidata provisional)

Siete indicadores conforman la **matriz candidata para diagnóstico PCA** (base total y base válida):

1. `actividad_desocupacion_incapacidad_hogar` (derivado de 5PM) – *dirección: alto = mayor vuln.*
2. `sin_energia_electrica` (derivado de 8V) – alto = mayor vuln.
3. `sin_gas_red_publica` (derivado de 8V) – alto = mayor vuln.

4. `sin_recoleccion_basuras` (derivado de 8V) – alto = mayor vuln.
5. `sin_internet` (derivado de 8V) – alto = mayor vuln.
6. `hogares_con_menores15` (derivado de 1HM) – alto = mayor vuln.
7. `estrato_1_2` (derivado de 10V) – alto = mayor vuln.

Estos 7 indicadores son **provisionales** (Decisión vigente registrada en `Resumen_General.md`, punto 30). La decisión final de inclusión corresponde al autor tras revisar conceptualmente denominadores (gas/internet, actividad, hogares con menores, estrato 1-2) y comparar sensibilidad NR entre matrices.

60 Indicadores descartados del PCA (descripción/solapamiento IPM)

Siete indicadores se calculan para descripción y validación cruzada, pero **quedan fuera de la matriz PCA propuesta** por solapamiento directo con privaciones del IPM:

1. Nivel educativo (17PM) – duplica "Bajo logro educativo" / "Analfabetismo" IPM.
2. Material inadecuado de paredes (6V) – duplica "Material inadecuado de paredes exteriores" IPM.
3. Sin acueducto (8V) – duplica "Sin acceso a fuente de agua mejorada" IPM.
4. Sin alcantarillado (8V) – duplica "Inadecuada eliminación de excretas" IPM.
5. Hacinamiento crítico (5V) – duplica "Hacinamiento crítico" IPM.
6. Trabajo infantil / informalidad / dependencia – no construidos desde CNPV; ya en IPM.
7. Hogares con adultos 60+ – dirección pendiente; correlación negativa con IPM.

61 Indicadores reservados para validación

- **IPM Municipal (agregado):** 15 privaciones ponderadas. **No entra al PCA**. Se usa como criterio de validación externa del IVS (el PC1 de los 14 indicadores IPM correlaciona $\approx 0,95$ en valor absoluto con IPM Municipal). Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 105.
- **IPM por dominio (Cabeceras, Centros poblados y Rural):** Solo para análisis de brechas urbano-rural futuro.

62 Especificación técnica

La especificación completa de los 14 indicadores (fuente, cuadro, numerador, denominador, población de referencia, dirección esperada, propuesta de inclusión, notas) está en `resultados/base_trabajo/especific`
Este archivo es la **fuente única de verdad** para la construcción de indicadores y debe ser aprobado/modificado por el autor antes de ejecutar PCA definitivo.

63 Control de calidad de los indicadores

64 Validaciones estructurales

El script `R/01_verificar_consolidados.R` ejecuta validaciones estructurales sobre las tablas intermedias (`datos/intermedio/`) y genera `resultados/verificacion_consolidados/validaciones.csv`. Todos los controles reportan **cero violaciones** en la ejecución registrada (13/10/2026).

Cuadro 9: *Validaciones estructurales clave (extracto de `validaciones.csv`)*

Validación	Concepto	N evaluado	N violaciones	Estado
Llave/prefijo contexto_1PM	Unicidad y formato llave municipal	80.909	0	PASS
Llave/prefijo contexto_1V	Unicidad y formato llave municipal	4.276	0	PASS
Llave/prefijo hogares_1HM_2HM	Unicidad y formato llave municipal	4.488	0	PASS
Llave/prefijo persona_demo_17PM	Unicidad y formato llave municipal	12.828	0	PASS
Llave/prefijo persona_social_5PM	Unicidad y formato llave municipal	12.828	0	PASS
Llave/prefijo viviendas_6V	Unicidad y formato llave municipal	6.652	0	PASS
Llave/prefijo viviendas_8V	Unicidad y formato llave municipal	4.276	0	PASS
Llave/prefijo viviendas_10V	Unicidad y formato llave municipal	4.276	0	PASS
Llave/prefijo ipm_municipal_ancho	Unicidad 1.122 municipios	1.122	0	PASS
Suma grupos edad = total	Consistencia 1PM	4.276	0	PASS
Hombre + mujer = total 1PM	Consistencia sexo	81.244	0	PASS
Suma población municipal = control nacional	Control nacional 1PM	1	0	PASS
MD5 insumos sin cambios	Integridad archivos entrada	11	0	PASS

65 Consistencia de conteos

La auditoría de conteos (`auditoria_conteos.csv`) verifica por cada variable de conteo:

- Valores disponibles (no NA).
- Valores faltantes (NA).
- Valores negativos (deben ser 0).
- Valores no enteros (deben ser 0, son conteos).

Resultados: **1.037.032 conteos evaluados, 0 valores negativos, 0 valores no enteros** (validaciones "Valores negativos en conteos" y "Valores no enteros en conteos": PASS).

66 Rangos

Todos los indicadores construidos como proporciones se validan en el rango $[0, 1]$:

- `actividad_desocupacion_incapacidad_hogar`: 1.122 municipios, 0 violaciones.

- `sin_energia_electrica`: 1.122 municipios, 0 violaciones.
- `sin_gas_red_publica`: 1.122 municipios, 0 violaciones.
- `sin_recoleccion_basuras`: 1.122 municipios, 0 violaciones.
- `sin_internet`: 1.122 municipios, 0 violaciones.
- `hogares_con_menores15`: 1.122 municipios, 0 violaciones.
- `estrato_1_2`: 1.122 municipios, 0 violaciones.

El IPM Municipal se valida en rango $[0, 100]$: 21.318 valores evaluados, 0 violaciones.

67 Valores imposibles

- **Conteos negativos:** 0 (validado).
- **Conteos no enteros:** 0 (validado).
- **Proporciones** < 0 **o** > 1**:** 0 (validado).
- **IPM fuera de** $[0, 100]$**:** 0 (validado).

68 Duplicados

- **Llaves universo 2018 únicas:** 1.122 municipios, 0 duplicados (validación "Llaves universo 2018 únicas": PASS).
- **IPM Municipal = IPM (columna duplicada):** 1.122 municipios, 0 diferencias $> 10^{-10}$ (validación PASS). Se conserva una sola columna.

69 Cobertura territorial

Cuadro 10: *Cobertura territorial y calidad por fuente*

Fuente/Variable	Universo	Cobertura completa	Hallazgos
CNPV 2018 (todos los cuadros)	1.122 municipios	1.122 (100 %)	20 sin cabecera, 192 sin centro poblado
IPM 2018 Municipal	1.122 municipios	1.122 (100 %)	20 NA en Cabeceras (coinciden con sin cabecera)
IPM 15 privaciones	1.122×15	100 %	Sin NA fuera de Cabeceras
DIVIPOLA 20260917	$\approx$1.122	1.122 coinciden	Diferencias por cambios admin. recientes

70 Integridad de fuentes

- **Hashes MD5:** `md5_insumos_antes.csv` y `md5_insumos_despues.csv` confirman que los 11 archivos de entrada monitoreados **no cambiaron** durante la ejecución del pipeline.
- **Archivos de solo lectura:** Los CSV en `datos/intermedio/` se tratan como entradas de solo lectura; sus hashes se verifican antes y después.
- **Tolerancias numéricas:** Configuradas en `R/00_config.R` (`tolerancia_suma = 1e-8`, `tolerancia_ipm = 1e-10`, `tolerancia_auditoria = 1e-10`).

71 Resumen de hallazgos de control

El archivo `resumen_hallazgos.csv` consolida las cifras de control:

- Universo CNPV/IPM: 1.122 municipios (PASS).
- Combinaciones edad ausentes: 335 (119 municipios) – ausencias estructurales.
- Área Centro poblado: 299 municipios la tienen.
- Área Rural disperso: 25 municipios la tienen.
- Área Cabecera: 6 municipios con incidencias (ver detalle).
- Área Total: 5 municipios con incidencias.
- Edad 85+: 89 ausencias; 80-84: 62; 75-79: 33.
- 18 municipios ANM DIVIPOLA sin cabecera (población 26.569).
- Cobertura baja 5PM / pob_10mas: 28 municipios ($< 0,9$).
- Cobertura baja menores15 HOGARES: 26 municipios ($< 0,9$).
- Cobertura baja 60+ HOGARES: 20 municipios ($< 0,95$).
- Ítems NR $> 5\,\%$: 83 municipios; $> 10\,\%$: 37; $> 20\,\%$: 7 (excluye `no_tiene_estrato`).
- 20 NA IPM Cabeceras = 20 municipios sin cabecera (PASS).

Todos los controles programados están en estado **PASS**. La refactorización del pipeline (octubre 2026) regeneró los 34 CSV previos de `datos/trabajo/` y `resultados/base_trabajo/` **sin diferencias byte a byte** respecto de la línea base (ver `docs/calidad/Refactorizacion_Pipeline_Indicadores` y `R/tests/test_pipeline_indicadores.R`).

72 Diagnóstico estadístico preliminar

73 Estadística descriptiva disponible

El script `R/03_auditoria_indicadores.R` genera diagnósticos estadísticos preliminares sobre la matriz de indicadores candidatos (7 indicadores, base total y base válida). Los resultados se almacenan en `resultados/auditoria_estadistica/` y `resultados/base_trabajo/`.

Cuadro 11: *Estadísticos descriptivos por indicador (matriz base total) – extracto de* `estadisticos_indicadores.csv`

Indicador	Media	Mediana	DE	Asimetría	% Ceros	Rango
actividad_desocupacion_incapacidad_hogar	–	–	–	–	–	[0,1]
sin_energia_electrica	–	–	–	–	–	[0,1]
sin_gas_red_publica	–	–	–	–	–	[0,1]
sin_recoleccion_basuras	–	–	–	–	–	[0,1]
sin_internet	–	–	–	–	–	[0,1]
hogares_con_menores15	–	–	–	–	–	[0,1]
estrato_1_2	–	–	–	–	–	[0,1]

Nota: Los valores exactos deben leerse de `estadisticos_indicadores.csv` *y* `varianza_indicadores.csv`*. En esta versión del informe se reporta la estructura; los números finales se insertarán tras la auditoría integral.*

74 Variabilidad

El archivo `varianza_indicadores.csv` reporta la varianza de cada indicador y señala variables con **varianza casi nula** (umbral configurable en `R/00_config.R`: `varianza_casi_nula = 1e-8`). Una varianza muy baja indica escasa discriminación entre municipios y posible exclusión de la matriz PCA.

75 Correlaciones preliminares

- `correlaciones_pares.csv`: Correlación de Pearson para cada par de los 7 indicadores propuestos (21 pares).
- `pares_correlacion_ge_090.csv`: Pares con $|r| \geq 0,90$ – **vacío** en la ejecución registrada (ningún par alcanza el umbral).
- `pares_correlacion_ge_095.csv`: Pares con $|r| \geq 0,95$ – **vacío**.

La ausencia de correlaciones extremadamente altas ($|r| \geq 0,90$) sugiere que no hay redundancia lineal severa entre los 7 indicadores candidatos, aunque la correlación moderada/alta entre algunos pares debe evaluarse en el contexto multivariado (KMO, MSA).

76 Outliers

- Detección mediante estandarización (z-score) usando `parametros_estandarizacion.csv` (media y DE por indicador).
- Umbral: $|z| > 4$ (configurable en `R/00_config.R`: `z_outlier = 4.0`).
- Resultado: **32 municipios** presentan al menos un indicador con $|z| > 4$. Ver `outliers_z_mayor_4.csv`.
- **No se eliminan automáticamente.** Estos municipios deben revisarse contra las fuentes originales y el contexto territorial antes de cualquier decisión de winsorización o exclusión.

77 Diagnósticos de adecuación multivariada

El archivo `diagnosticos_aptitud.csv` reporta:

Cuadro 12: *Diagnósticos globales de aptitud para PCA (matriz base total, 7 indicadores)*

Diagnóstico	Valor	Interpretación
KMO global	$\approx 0,642$	Moderado (umbral adecuado $\geq 0,70$; mínimo $\geq 0,50$)
Test de Bartlett	$\chi^2 \approx 4664,873$, gl=21, $p < 0,001$	Significativo: rechaza matriz identidad
Determinante de la matriz de correlación	$\approx 0,0154$	$> 0,00001$: no colinealidad perfecta

78 Medida de Adecuación Muestral Individual (MSA por indicador)

El archivo `kmo_por_indicador.csv` reporta el MSA (KMO individual) para cada uno de los 7 indicadores:

- La mayoría de indicadores tienen MSA $> 0,50$ (mínimo aceptable).
- **Alerta:** El indicador `estrato_1_2` (proxy estrato 1–2) tiene **MSA** $\approx 0,414$, **por debajo del mínimo** $(0,50)$. Esto sugiere que este indicador no comparte varianza común suficiente con el resto del conjunto y su inclusión en el PCA debe reconsiderarse.
- Ver `Resumen_General.md`, punto 40: "el MSA de estrato 1–2 es bajo ($\approx 0,414$)".

79 Sensibilidad a No Respuesta (NR)

La comparación entre **base total** (incluye NR en denominador) y **base válida** (excluye NR) muestra:

- `sensibilidad_nr.csv`: Resumen por indicador de diferencias absolutas y relativas.
- `sensibilidad_nr_municipio.csv`: Diferencias municipio a municipio con marcas de sensibilidad (umbrales en `R/00_config.R`: `delta_absoluta = 0.02`, `delta_relativa = 0.10`).
- Las diferencias municipales y agregadas **deben revisarse** antes de fijar la base analítica principal (Decisión vigente en `Resumen_General.md`, punto 27 y punto 59).

80 Estado de la auditoría estadística

Importante: Los diagnósticos reportados en esta sección son **preliminares**. La **auditoría estadística integral está pendiente** y debe incluir, como mínimo:

1. Comparación sistemática de correlaciones, KMO y MSA entre **matriz base total** y **matriz base válida**.
2. Evaluación de transformaciones para variables asimétricas (ej. `sin_internet`, `sin_gas` con techo alto).
3. Análisis de componentes principales *exploratorio* (no definitivo) para inspeccionar eigenvalues, scree plot, cargas, varianza explicada.
4. *Parallel analysis* para criterio de retención de componentes.
5. Evaluación de estabilidad: bootstrap, jackknife, o análisis de sensibilidad a outliers (32 municipios con $|z| > 4$).
6. Decisión fundamentada sobre inclusión/exclusión de `estrato_1_2` (MSA bajo) y `hogares_con_menores15` (cobertura baja en 26 municipios).
7. Definición de dirección de `hogares_con_adultos_60mas` (actualmente fuera de matriz candidata).
8. Documentación de criterios de retención de componentes (eigenvalue > 1, scree, parallel analysis, varianza explicada acumulada $> 60 - 70\,\%$).

No se ha ejecutado un PCA definitivo. Los diagnósticos actuales **no deciden** si el PCA es apropiado; son insumos para la decisión metodológica que debe tomar el autor (ver `Resumen_General.md`, punto 40: "La auditoría estadística recomienda no ejecutar aún un PCA definitivo").

81 Preparación para PCA

82 Objetivo del PCA

El Análisis de Componentes Principales (PCA) tendrá como objetivo:

1. **Reducir la dimensionalidad** de la matriz de indicadores socioeconómicos municipales (inicialmente 7 candidatos provisionales) a un número pequeño de componentes no correlacionados.
2. **Identificar la estructura común latente** que explique la covarianza entre indicadores de vulnerabilidad.
3. **Sintetizar la información socioeconómica** en uno o pocos índices compuestos interpretables.
4. **Construir eventualmente un Índice de Vulnerabilidad Socioeconómica (IVS)** a partir de los scores del primer componente principal (PC1), orientado para que valores altos representen mayor vulnerabilidad.

83 Justificación metodológica

- Los indicadores de vulnerabilidad son **multidimensionales y correlacionados**; el PCA extrae la varianza compartida.
- A diferencia de índices con pesos arbitrarios (iguales, de expertos, o basados en prevalencia), el PCA pondera por la **estructura empírica de covarianzas/correlaciones** de los datos.
- El PC1, si representa un constructo coherente ("vulnerabilidad general"), proporciona una síntesis unidimensional válida para análisis territoriales y validación externa.
- El PCA es **reproducible y transparente**: pesos = eigenvectores, scores = proyecciones, varianza explicada = eigenvalues.

Advertencia: El PCA **no es apropiado** si: (a) la adecuación multivariada es insuficiente (KMO global $< 0,6$, MSA individual $< 0,5$); (b) no existe estructura factorial interpretable; (c) el PC1 no representa vulnerabilidad sino un artefacto matemático; (d) hay circularidad con la validación externa (IPM).

84 Variables candidatas

La **matriz candidata provisional** (base total y base válida) contiene 7 indicadores:

1. `actividad_desocupacion_incapacidad_hogar` – Desocupación/inactividad 10+ años.
2. `sin_energia_electrica` – Viviendas sin energía.
3. `sin_gas_red_publica` – Viviendas sin gas natural.
4. `sin_recoleccion_basuras` – Viviendas sin recolección de basuras.
5. `sin_internet` – Viviendas sin internet.
6. `hogares_con_menores15` – Hogares con menores de 15 años.
7. `estrato_1_2` – Población en estrato 1–2.

Estado: *Provisional*. La decisión final de inclusión corresponde al autor (ver `Resumen_General.md`, puntos 5, 30, 58). Deben aprobarse/modificarse concepto y denominadores de gas/internet, actividad, hogares con menores y estrato 1–2.

85 Criterios que deberán evaluarse

Antes de ejecutar PCA definitivo, se debe evaluar y documentar:

1. **Adecuación multivariada:** KMO global ($\geq 0,70$ deseable), MSA individual ($\geq 0,50$ c/u), Bartlett ($p < 0,05$).
2. **Selección final de variables:** Dirección de vulnerabilidad definida, colinealidad aceptable (VIF $< 5 - 10$), no redundancia con IPM (para validación externa no circular).
3. **Distribución de variables:** Asimetría, curtosis, concentración de ceros; transformaciones si es necesario (log, raíz, winsorización).
4. **Correlaciones y MSA:** Matriz de correlaciones, KMO global e individual, determinante.
5. **Eigenvalues y varianza explicada:** Eigenvalues > 1 (Kaiser), scree plot, *parallel analysis* (Horn, 1965) para retención objetiva.
6. **Estructura factorial:** Cargas del PC1 (y PC2 si se retiene), interpretabilidad teórica, ausencia de cargas cruzadas problemáticas.

7. **Signo del componente:** Orientar PC1 para que **score alto = mayor vulnerabilidad** (el signo es arbitrario en PCA).

8. **Estabilidad:** Sensibilidad a outliers (32 municipios $|z| > 4$), bootstrap/jackknife si procede, comparación base total vs. base válida.

9. **Scores municipales:** Distribución, rangos, percentiles, mapa preliminar.

86 Procedimientos pendientes

1. **Aprobar lista definitiva de indicadores** (concepto, denominador, dirección, tratamiento NR).

2. **Confirmar umbrales de cobertura** configurados en `R/00_config.R` (parámetros operativos editables, no decisiones universales).

3. **Comparar sensibilidad NR** entre matriz base total y base válida (correlaciones, KMO, MSA) – `Resumen_General.md`, punto 59.

4. **Revisar 32 municipios con** $|z| > 4$ contra fuentes y contexto territorial – no eliminar automáticamente.

5. **Resolver decisión sobre** `estrato_1_2` (MSA $\approx 0,414$): excluir, transformar, o mantener con justificación.

6. **Definir dirección de** `hogares_con_adultos_60mas` (correlación negativa con IPM) – incluir o reservar como covariables.

7. **Ejecutar PCA exploratorio**, inspeccionar eigenvalues, scree, parallel analysis, cargas.

8. **Seleccionar componentes** con criterio documentado y justificado.

9. **Interpretar cargas** y validar que PC1 representa "vulnerabilidad general".

10. **Construir IVS** (scores PC1 orientados) y evaluar estabilidad.

11. **Validar externamente con IPM Municipal** (correlación, concordancia de rankings, análisis de residuos).

87 Precauciones frente a circularidad con IPM

- El **IPM Municipal (agregado) se reserva exclusivamente como validación externa**. No entra al PCA.
- Indicadores que **replican directamente privaciones del IPM** (material paredes, acueducto, alcantarillado, hacinamiento, analfabetismo, rezago, inasistencia, barreras primera infancia, trabajo infantil, informalidad, dependencia, barreras salud, aseguramiento, pisos) se han **excluido de la matriz candidata PCA** o se marcan como `DESCRIPCIÓN` en `especificacion_indicadores.csv`.
- Si un indicador censal (ej. 6V: material paredes) duplica una privación IPM, la decisión documentada es: **usar uno solo** (preferiblemente el del IPM por ser oficial validado, y usar el censal solo para validar consistencia). Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 104.
- La validación externa consistirá en correlacionar el IVS (PC1 de indicadores *no IPM*) con el IPM Municipal. Una correlación alta (en valor absoluto) apoya la validez convergente; una correlación baja exige revisión teórica del IVS.

88 Configuración técnica

- `R/00_config.R`: `ejecutar_pca = FALSE`, `ejecutar_bootstrap = FALSE` (bandas de seguridad).
- `R/03_auditoria_indicadores.R`: Genera diagnósticos previos (descriptivos, correlaciones, KMO, Bartlett, outliers, estandarización) **sin estimar componentes**.
- `R/funciones/auditoria_estadistica.R`: Funciones modulares para diagnósticos multivariados.
- Cuando se autorice: `ejecutar_pca = TRUE` activará la estimación (por implementar/extender en pipeline).

89 Reproducibilidad y arquitectura computacional

90 Organización del repositorio

La estructura del repositorio es la siguiente:

Desarrollo_Social_Economico_Agent/ Raíz del proyecto

datos/ intermedio/ Tablas tidy de auditoría estructural (solo lectura)

trabajo/ Denominadores, indicadores, matrices candidatas

***.xlsx** Fuentes originales (CNPV, IPM, DIVIPOLA) – no versionados

docs/ calidad/ auditorias/ Reportes de verificación y auditoría

limpieza/ Reportes de limpieza

refactorizacion/ Doc. de refactorización pipeline

diccionario/ Decisiones variables, diccionarios por fuente

metodologia/ Documentos metodológicos

handoff/ Resúmenes de transferencia

informe1_metodologico/ ESTE INFORME

R/ 00_config.R Parámetros editables (rutas, umbrales, banderas)

01_verificar_consolidados.R Verificación estructural, universo maestro

02_base_final_indicadores.R Construcción indicadores, matrices, diagnósticos

03_auditoria_indicadores.R Auditoría estadística preliminar

funciones/ io.R Lectura/escritura, conversión, hashes MD5

validacion.R Controles estructurales y de calidad

auditoria_estadistica.R Diagnósticos multivariados (KMO, Bartlett, etc.)

tests/ test_pipeline_indicadores.R Prueba de integridad byte-a-byte

resultados/ verificacion_consolidados/ Inventarios, validaciones, especificación

base_trabajo/ 25 CSV: indicadores, calidad, sensibilidad, hashes

auditoria_estadistica/ Diagnósticos multivariados

OLVIDADOS/ 17 scripts históricos archivados

.obsidian/ Bóveda Obsidian (notas metodológicas enlazadas)

main.tex Este informe

91 Scripts principales

Cuadro 13: *Scripts principales del pipeline activo*

Script	Función	Salidas clave
R/00_config.R	Parámetros globales: rutas, umbrales NR, cobertura, outliers, KMO, banderas PCA/bootstrap	Configuración centralizada
R/01_verificar_consolidados.R	Lee Excel como texto, reconstruye llaves 5 chars, genera inventario, mapa llaves, cobertura, discrepancias, universo maestro, tablas tidy	datos/intermedio/*.csv, resultados/verificacion_consolidados/
R/02_base_final_indicadores.R	Crea denominadores, indicadores (base total/válida), matrices candidatas, diagnósticos, sensibilidad NR, hashes	datos/trabajo/, resultados/base_trabajo/
R/03_auditoria_indicadores.R	Descriptivos, correlaciones, KMO global/individual, Bartlett, outliers, estandarización	resultados/auditoria_estadistica/
R/tests/test_pipeline_indicadores.R	Prueba de integridad: regenera 34 CSV y compara byte-a-byte con línea base	PASS/FAIL

92 Flujo de procesamiento

1. **Configuración:** R/00_config.R define todas las rutas, umbrales y banderas.

2. **Verificación consolidados:** R/01_verificar_consolidados.R

   a) Lee los 4 libros Excel CNPV hoja a hoja (como texto, sin chunking real).

   b) Reconstruye codigo_municipio (5 chars) y valida contra universo maestro.

   c) Genera tablas intermedias datos/intermedio/ (contexto, hogares, personas, viviendas, IPM).

   d) Produce inventario, mapa de llaves, cobertura, discrepancias, controles.

   e) Documenta en VERIFICACION_CONSOLIDADOS.md.

3. **Construcción indicadores:** R/02_base_final_indicadores.R

   a) Lee tablas intermedias (solo lectura, verifica MD5).

   b) Calcula denominadores desde 1PM y 1V_MPIO.

   c) Construye 14 indicadores (7 PCA provisionales + 7 descripción/solapamiento IPM).

   d) Genera versiones base total y base válida para indicadores con NR.

   e) Produce matrices candidatas, especificacion_indicadores.csv, controles, sensibilidad, *flags*, hashes.

4. **Auditoría estadística:** R/03_auditoria_indicadores.R

   a) Lee matrices candidatas y calcula descriptivos, correlaciones, KMO, Bartlett, outliers, estandarización.

b) **No ejecuta PCA ni bootstrap** (`ejecutar_pca = FALSE`).

5. **Prueba de integridad:** `R/tests/test_pipeline_indicadores.R` regenera todo y compara MD5.

93 Trazabilidad

Cada decisión metodológica clave tiene su archivo de evidencia:

Cuadro 14: *Trazabilidad decisiones – archivo evidencia*

Decisión	Archivo evidencia
Selección de variables	`docs/diccionario/decisiones_variables_IVS_CNPV2018.csv`
Especificación indicadores	`resultados/base_trabajo/especificacion_indicadores.csv`
Universo municipal (1.122)	`datos/intermedio/universo_municipal_maestro.csv`
Validaciones estructurales	`resultados/verificacion_consolidados/validaciones.csv`
Tratamiento NR (base total/válida)	`R/00_config.R`, `sensibilidad_nr.csv`
Ausencias estructurales	`resultados/base_trabajo/ausencias_estructurales_1PM.csv`
Municipios sin cabecera	`resultados/base_trabajo/municipios_sin_cabecera.csv`
Crosswalk territorial SECOP	`resultados/base_trabajo/crosswalk_enlace.csv`
Integridad insumos (MD5)	`resultados/base_trabajo/md5_insumos_antes/despues.csv`
Diagnósticos aptitud PCA	`resultados/base_trabajo/diagnosticos_aptitud.csv`, `kmo_por_indicador.csv`

94 Control de integridad

- **Hashes MD5:** 11 archivos de entrada monitoreados; hashes antes y después de cada ejecución confirman **sin modificaciones**.
- **Tolerancias numéricas:** `tolerancia_suma = 1e-8`, `tolerancia_ipm = 1e-10`, `tolerancia_auditoria = 1e-10` (en `R/00_config.R`).
- **Controles de consistencia:** Suma grupos edad = total; Hombre + Mujer = Total; Sumas municipales = Control nacional; 17PM total = suma categorías; 5PM total = suma categorías; 8V servicios = suma categorías; 10V BU = suma BV:CD.
- **Refactorización verificada:** Octubre 2026 regeneró 34 CSV idénticos byte-a-byte a la línea base (`docs/calidad/Refactorizacion_Pipeline_Indicadores`).

95 Reproducibilidad

Para reproducir el estado actual del pipeline desde la raíz del repositorio:

```
# 1. Verificación consolidados (genera datos/intermedio/, resultados/verificacion_consolidad
```

```
Rscript R/01_verificar_consolidados.R

# 2. Construcción indicadores y diagnósticos base (genera datos/trabajo/, resultados/base_tr
Rscript R/02_base_final_indicadores.R

# 3. Auditoría estadística preliminar (genera resultados/auditoria_estadistica/)
Rscript R/03_auditoria_indicadores.R

# 4. Prueba de integridad (opcional, verifica regeneración byte-a-byte)
Rscript R/tests/test_pipeline_indicadores.R
```

- Requiere R $\geq$ 4.0 y paquetes: `readxl`, `readr`, `dplyr`, `tidyr`, `stringr`, `purrr`, `janitor`, `tibble`, `lubridate`, `data.table`.
- No hay `renv.lock` ni `DESCRIPTION` versionado; versiones de paquetes no fijadas (deuda técnica documentada).
- Los archivos Excel fuente en `datos/` **no están versionados** (ver `.gitignore`); deben obtenerse del DANE.
- La bóveda Obsidian (`.obsidian/`) contiene notas metodológicas enlazadas (`Inicio_Proyecto.md`, `Final_Base.md`, `VERIFICACION_CONSOLIDADOS.md`, etc.) que documentan decisiones y vinculan a archivos reproducibles.

96 Limitaciones actuales

El presente informe documenta el estado del proyecto al 13 de octubre de 2026. Las siguientes limitaciones son **parte inherente del estado actual de la investigación**, no fallas del proyecto:

97 Auditoría estadística integral pendiente

Los diagnósticos reportados en el Capítulo 72 (KMO $\approx 0,642$, Bartlett significativo, MSA estrato 1–2 $\approx 0,414$, 32 municipios con $|z| > 4$, sensibilidad NR) son **preliminares**. Falta:

- Comparación sistemática base total vs. base válida (correlaciones, KMO, MSA).
- Evaluación de transformaciones para asimetría/curtosis (ej. techo en gas, internet).
- *Parallel analysis* para retención de componentes.
- Análisis de estabilidad (bootstrap, sensibilidad a outliers).
- Decisión fundamentada sobre variables problemáticas (estrato 1–2, hogares con menores, dirección adultos 60+).

No se ha aprobado la matriz para PCA definitivo.

98 PCA no ejecutado

- No se han estimado componentes principales.
- No se han inspeccionado eigenvalues, scree plot, cargas, varianza explicada.
- No se ha evaluado interpretabilidad del PC1 como "vulnerabilidad general".
- No se ha definido criterio de retención (Kaiser, scree, parallel analysis, varianza acumulada).

99 IVS (Índice de Vulnerabilidad Socioeconómica) no construido

- No existe un índice sintético validado.
- No se han calculado scores municipales de vulnerabilidad.
- No se ha orientado el signo (score alto = mayor vulnerabilidad).
- No se ha evaluado estabilidad del ranking municipal.

100 Validación externa con IPM pendiente

- El IPM Municipal agregado está reservado como criterio de validación.
- No se ha correlacionado IVS con IPM (evitando circularidad por exclusión de indicadores redundantes).
- No se ha analizado concordancia de rankings, análisis de residuos, ni sensibilidad de la validación.

101 Integración SECOP II pendiente

- No se han obtenido ni integrado datos de SECOP II.
- No se ha definido ventana temporal definitiva (exploratoria 2015–2025).
- No se han construido indicadores municipales-año de contratación (valor, número, concentración, sectores).
- No se ha resuelto el *crosswalk* territorial definitivo (códigos 94663, 27493 pendientes de verificación DANE/IGAC).
- No se ha definido denominador para tasas de contratación (PIB municipal, población, presupuesto, referencia nacional).

102 Análisis de asociación/correspondencia pendiente

- Condicionado a la existencia de IVS validado y datos SECOP II integrados.
- Requiere definición de hipótesis nulas, modelos (correlación, regresión, panel), y prueba de focalización.

103 Análisis espacial condicionado

- Solo procederá si el diagnóstico de asociación lo justifica.
- Requiere: matriz de pesos espaciales (contigüidad, distancia), test de Moran's I, modelos espaciales (SAR, SEM, SDM), detección de clústeres (LISA).
- Condicionado a resultados de etapas previas.

104 Otras limitaciones técnicas

- **Entorno R no versionado:** No hay `renv.lock` ni `DESCRIPTION`; versiones de paquetes no fijadas.
- **Fuentes Excel no versionadas:** Archivos en `datos/` excluidos por `.gitignore`; reproducibilidad requiere acceso a fuentes originales DANE.
- **Cobertura baja en algunos indicadores:** 28 municipios con cobertura 5PM/pob_10mas $< 0,9$; 26 con menores15 HOGARES $< 0,9$; 20 con 60+ HOGARES $< 0,95$. Umbrales son parámetros operativos editables en `R/00_config.R`, requieren aprobación metodológica.
- **Verificación pendiente 17PM:** El cuadro 17PM está descrito en el índice DANE como "asistencia escolar" (igual que 18PM), pero 17PD trata "nivel educativo". Si es asistencia, duplica Inasistencia IPM y debe reconsiderarse. Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 37.
- **Deuda de modularización:** La construcción principal de denominadores e indicadores permanece en gran parte dentro de `R/02_base_final_indicadores.R` (pendiente extraer a `R/funciones/`).

105 Estado del proyecto y etapas siguientes

106 Tabla de estado general

Cuadro 15: *Estado del proyecto por etapa (corte 13/10/2026)*

Etapa	Estado	Evidencia principal	Próximo paso
Selección de fuentes	**Completado**	`CUADROS_MUNICIPALES_UNIDOS.xlsx`, `IPM_2018_organizado_region.xlsx`, `DIVIPOLA`	–
Selección de variables	**Provisional** (7 PCA + 7 descripción)	`decisiones_variables_IVS_CNPV2018.csv`, `especificacion_indicadores.csv`	Aprobar/modificar lista candidata, confirmar direcciones
Integración territorial	**Completado** (verificación llaves)	`validaciones.csv`, `universo_municipal_maestro.csv`	Resolver 27493 y 94663 para crosswalk SECOP
Tratamiento de faltantes	**Documentado** (sin imputación, dualidad base total/válida)	`R/00_config.R`, `sensibilidad_nr.csv`, `ausencias_estructurales_1PM.csv`	Decidir base analítica principal usando sensibilidad
Construcción indicadores	**Completado** (base total y base válida)	`datos/trabajo/`, `resultados/base_trabajo/`	Confirmar fórmulas, denominadores, dirección
Auditoría estadística	**Pendiente** (diagnósticos preliminares disponibles)	`resultados/auditoria_estadistica/`, `diagnosticos_aptitud.csv`, `kmo_por_indicador.csv`	Ejecutar auditoría integral; decidir sobre PCA
PCA	**Pendiente**	–	Evaluar adecuación, seleccionar componentes, interpretar cargas
IVS	**Pendiente**	–	Construir índice sintético, evaluar estabilidad, orientar signo
Validación IPM	**Pendiente**	–	Correlacionar IVS con IPM Municipal (evitando circularidad)
SECOP II	**Pendiente**	–	Obtener datos, definir período/denominador, integrar municipal-año
Asociación	**Pendiente**	–	Analizar correspondencia IVS vs. SECOP II
Espacial	**Pendiente** (condicionado)	–	Si asociación lo justifica: autocorrelación, modelos espaciales, clústeres

107 Decisiones vigentes registradas (extracto de `Resumen_General.md`)

1. Universo: **1.122 códigos municipales CNPV/IPM 2018**, sin fusiones ni exclusiones en datos 2018.
2. Llave de unión: `codigo_municipio` como texto de 5 caracteres; nunca nombre municipal.
3. Sin imputación estadística: ausencias estructurales → ceros + flags; áreas inexistentes → no crear filas.
4. Cocientes 0/0 → NA + `flag_indice_indefinido`; 20 NA IPM Cabeceras → NA estructural.
5. NR: base total (incluye NR) y base válida (excluye NR) como escenarios de sensibilidad; `no_tiene_estrato` separado.
6. IPM agregado: **validación externa**; no entra al PCA. Privaciones que replican IPM → fuera de matriz candidata.
7. 17PM total = población 5+ de 1PM; `pob_10mas` desde 1PM; 17PM no permite filtrar 10+.
8. Decisiones de inclusión: **provisionales** (7 indicadores matriz candidata).

108 Resultados comprobados que orientan el siguiente paso

- Universo 1.122 municipios; validaciones de llaves, prefijos, sumas y rangos: **cero violaciones**.
- 20 municipios sin cabecera (coinciden con 20 NA IPM Cabeceras); 192 sin centro poblado.
- 335 ausencias estructurales edad (119 municipios); 1.202 ausencias tipo vivienda.

- Códigos 94663 y 27493: asuntos territoriales pendientes, documentados para crosswalk SECOP.
- Matriz candidata base total: KMO $\approx 0,642$; Bartlett $\chi^2 \approx 4664,873$, gl=21, $p < 0,001$; determinante $\approx 0,0154$; sin pares $|r| \geq 0,90$; 32 municipios con $|z| > 4$.
- Sensibilidad NR: diferencias municipales y agregadas documentadas; requieren revisión antes de fijar base analítica.
- **Recomendación auditoría:** no ejecutar PCA definitivo aún (KMO moderado, MSA estrato 1–2 bajo, actividad mezcla estados, falta comparar base total vs. válida).
- Refactorización pipeline: 34 CSV regenerados idénticos byte-a-byte; prueba `test_pipeline_indicadores.R` PASS.

109 Pendientes y decisiones del autor (próximas acciones)

1. Revisar concepto y denominadores de gas/internet, actividad, hogares con menores, estrato 1–2; aprobar o modificar lista candidata.
2. Comparar sensibilidad de correlaciones/KMO entre matriz base total y base válida; revisar 32 códigos extremos con fuentes; no eliminarlos automáticamente.
3. Confirmar umbrales de cobertura en `R/00_config.R` (parámetros operativos editables).
4. Resolver para enlace SECOP el tratamiento de 27493 y 94663, con verificación territorial externa; mantener intactos códigos originales CNPV/IPM.
5. Decidir si se mantienen escenarios base total/base válida NR o cuál será principal, usando sensibilidad documentada.
6. Conseguir/integrar datos SECOP II, definir período, denominador y unidad temporal; pipeline no implementado.
7. Completar extracción de bloques de denominadores y cálculo de indicadores de `R/02_base_final_indicadores.` antes de extender pipeline.
8. **Solo después de lo anterior:** ejecutar y documentar PCA, selección de componentes, estabilidad/bootstrap si corresponde, validación externa con IPM. **El IVS todavía no existe como producto validado.**

110 Arquitectura futura del proyecto

El informe está diseñado para crecer modularmente:

```
INFORME 1 (ESTE DOCUMENTO)
  Metodología y construcción de indicadores
            ↓
AUDITORÍA ESTADÍSTICA INTEGRAL
            ↓
PCA (exploratorio → definitivo)
            ↓
ÍNDICE SINTÉTICO / IVS (construcción + estabilidad)
            ↓
VALIDACIÓN EXTERNA CON IPM MUNICIPAL
            ↓
INTEGRACIÓN SECOP II (panel municipal-año)
            ↓
ANÁLISIS DE ASOCIACIÓN / CORRESPONDENCIA
            ↓
ANÁLISIS ESPACIAL (condicionado a resultados)
```

Cada etapa futura se añadirá como capítulo/sección sin reescribir la metodología ya consolidada en este Informe 1.

111 Conclusiones metodológicas

112 ¿Qué se ha construido hasta ahora?

1. **Universo municipal consolidado:** 1.122 municipios con datos CNPV 2018 e IPM 2018, homologados por `codigo_municipio` (5 caracteres), validados con cero violaciones estructurales.

2. **Bases intermedias auditadas:** 9 tablas tidy en `datos/intermedio/` (contexto 1PM, 1V; hogares 1HM/2HM; personas demo 17PM; personas social 5PM; viviendas 6V, 8V, 10V; IPM municipal ancho), con integridad verificada por MD5.

3. **14 indicadores socioeconómicos municipales** construidos con fórmulas explícitas (numerador, denominador, población de referencia), en dos versiones para NR (base total / base válida), documentados en `especificacion_indicadores.csv`.

4. **7 indicadores candidatos provisionales para PCA:** desocupación/inactividad, sin energía, sin gas, sin recolección, sin internet, hogares con menores, estrato 1–2.

5. **7 indicadores de descripción/solapamiento IPM:** nivel educativo, material paredes, acueducto, alcantarillado, hacinamiento, trabajo infantil/informalidad/dependencia (vía IPM), hogares con adultos 60+ (dirección pendiente).

6. **Diagnósticos estadísticos preliminares:** descriptivos, correlaciones, KMO global ($\approx 0,642$), Bartlett ($p < 0,001$), MSA individual (estrato 1–2 $\approx 0,414$), outliers ($|z| > 4$ en 32 municipios), sensibilidad NR.

7. **Tratamiento territorial documentado:** 20 municipios sin cabecera, 192 sin centro poblado, códigos 94663/27493 con *crosswalk* para SECOP futuro, ausencias estructurales distinguibles de faltantes.

8. **Pipeline reproducible y modularizado parcialmente:** 4 scripts principales + funciones + prueba de integridad byte-a-byte.

113 ¿Qué decisiones metodológicas están consolidadas?

- Municipio como unidad de análisis; `codigo_municipio` (5 chars) como llave única.
- No imputación estadística; ceros estructurales + flags; NA para denominador cero y 0/0.

- Dualidad base total / base válida para NR como escenarios de sensibilidad (no decisión definitiva).
- `no_tiene_estrato` distinguido de NR genuino.
- IPM Municipal reservado como **validación externa**; exclusión de indicadores que replican privaciones IPM de la matriz PCA.
- 17PM total = población 5+ de 1PM; `pob_10mas` desde 1PM.
- Conflictos territoriales (94663, 27493, municipios sin cabecera, ANM) **no resueltos en datos 2018**; reservados para *crosswalk* SECOP.
- Controles de calidad: validaciones estructurales PASS, consistencia conteos PASS, rangos PASS, integridad MD5 PASS.

114 ¿Qué problemas fueron detectados y cómo fueron tratados?

Cuadro 16: *Problemas detectados y tratamiento*

Problema	Detección	Tratamiento adoptado
Municipios sin cabecera (20)	Validación IPM Cabeceras = NA	Conservados; NA estructural; documentados en `municipios_sin_cabecera.csv`
Código 94663 (Mapiripana)	Relación con 94343 (Barrancominas)	Documentado para crosswalk SECOP; no fusionado en 2018
Código 27493 (Nuevo Belén de Bajirá)	Conflicto histórico con 05480 Mutatá	Hipótesis 27615 Riosucio como padre; pendiente verificación DANE/IGAC
Ausencias estructurales edad/vivienda	335 + 1.202 combinaciones ausentes	Ceros estructurales + flags; no imputación
Cobertura baja 5PM / pob_10mas (28)	Validación umbral 0,9	Documentado; umbral editable en `R/00_config.R`
Cobertura baja menores15 HOGARES (26)	Validación umbral 0,9	Documentado; umbral editable
Cobertura baja 60+ HOGARES (20)	Validación umbral 0,95	Documentado; umbral editable
MSA estrato 1–2 bajo ($\approx 0,414$)	`kmo_por_indicador.csv`	Alerta documentada; decisión de inclusión pendiente
Dirección hogares con adultos 60+	Correlación negativa con IPM	Fuera de matriz candidata; decisión conceptual pendiente
Verificación 17PM (asistencia vs. nivel)	Índice DANE describe asistencia	Pendiente abrir hoja; si asistencia, duplica IPM
Sensibilidad NR	Diferencias base total vs. válida	Documentada en `sensibilidad_nr*.csv`; decisión pendiente

115 ¿Qué información queda lista para el análisis multivariado?

- Matriz candidata base total: `datos/trabajo/matriz_base_total.csv` (1.122×7).
- Matriz candidata base válida: `datos/trabajo/matriz_base_valida.csv` (1.122×7).
- Parámetros de estandarización: `resultados/base_trabajo/parametros_estandarizacion.csv`.
- Correlaciones pares: `resultados/base_trabajo/correlaciones_pares.csv`.
- Diagnósticos aptitud: `resultados/base_trabajo/diagnosticos_aptitud.csv`, `kmo_por_indicador.csv`.
- Outliers: `resultados/base_trabajo/outliers_z_mayor_4.csv` (32 municipios).
- Sensibilidad NR: `sensibilidad_nr.csv`, `sensibilidad_nr_municipio.csv`.

- Especificación completa de indicadores: `especificacion_indicadores.csv`.

Condición: La matriz debe ser **aprobada por el autor** tras revisar concepto, denominadores, dirección, cobertura y sensibilidad NR (puntos 58–59 de `Resumen_General.md`).

116 ¿Qué etapas faltan?

1. **Auditoría estadística integral** (comparar base total vs. válida, transformaciones, parallel analysis, estabilidad).
2. **Decisión final de variables** para PCA (aprobar 7 provisionales, resolver estrato 1–2, adultos 60+, 17PM).
3. **Ejecución de PCA** (eigenvalues, scree, parallel analysis, cargas, varianza explicada, interpretabilidad).
4. **Construcción del IVS** (scores PC1 orientados, evaluación de estabilidad/bootstrap).
5. **Validación externa con IPM Municipal** (correlación, rankings, residuos, sin circularidad).
6. **Integración SECOP II** (obtención, limpieza, panel municipal-año, *crosswalk* territorial).
7. **Análisis de asociación** IVS vs. SECOP II (correlación, modelos, focalización).
8. **Análisis espacial** (condicionado a resultados de asociación).

117 Cierre

Este Informe 1 establece una **base metodológica rigurosa, trazable y reproducible** para el análisis de la correspondencia entre contratación pública y vulnerabilidad socioeconómica municipal en Colombia. Las decisiones documentadas priorizan la transparencia sobre la premura: se distinguen claramente los hallazgos consolidados de las decisiones provisionales y de las etapas pendientes. El IVS **no existe aún**; su construcción requerirá completar la auditoría estadística, ejecutar y validar el PCA, y solo entonces proceder a la validación externa y al análisis sustantivo con SECOP II. La arquitectura modular del informe y del pipeline computacional permite incorporar cada etapa futura sin reescribir lo ya consolidado.

Referencias

Abdi, H. and Williams, L. J. (2010). Principal component analysis. *Wiley Interdisciplinary Reviews: Computational Statistics*, 2(4):433–459.

Alkire, S., Foster, J., Seth, S., Santos, M. E., Roche, J. M., and Ballon, P. (2011). *Multidimensional poverty measurement and analysis*. Oxford University Press.

Booysen, F. (2002). An overview and evaluation of composite indices of development. *Social Indicators Research*, 59(2):115–151.

CEPAL (2016). *Horizontes 2030: la igualdad en el centro del desarrollo sostenible*. Comisión Económica para América Latina y el Caribe.

DANE (2019). Metodología del Índice de pobreza multidimensional (ipm) para colombia. Technical report, Departamento Administrativo Nacional de Estadística, Bogotá, Colombia.

Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer, 2nd edition.

Kaiser, H. F. (1974). Little jiffy, mark iv. *Educational and Psychological Measurement*, 34(1):111–117.

Rodríguez, J. et al. (2010). Vulnerabilidad social: un enfoque multidimensional. *Revista CEPAL*, 102:117–136.

Sen, A. (1999). *Development as freedom*. Oxford University Press.

Anexos

A Especificación completa de indicadores (fuente: `especificacion_indicadores.csv`)

Este anexo reproduce la especificación técnica de los 14 indicadores construida por `R/02_base_final_indicado`. La versión autoritativa es el archivo CSV en `resultados/base_trabajo/especificacion_indicadores.csv`.

Cuadro 17: *Especificación completa de indicadores*

Indicador	Fuente	Cuadro	Numerador	Denominador	Pob. ref.	Dirección	Uso
actividad_desocupacion_incapacidad_hogar	PERSONAS_SOCIAL	5PM	Desocupados + Incapacidad	Pob. 10+ años	1PM (10+)	Alto = mayor vuln.	PCA provisional
sin_energia_electrica	VIVIENDAS	8V	Viviendas sin energía	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	PCA provisional
sin_gas_red_publica	VIVIENDAS	8V	Viviendas sin gas	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	PCA provisional
sin_recoleccion_basuras	VIVIENDAS	8V	Viviendas sin recolección	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	PCA provisional
sin_internet	VIVIENDAS	8V	Viviendas sin internet	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	PCA provisional
hogares_con_menores15	HOGARES	1HM	Hogares con menores <15	Total hogares	1HM Total	Alto = mayor vuln.	PCA provisional
estrato_1_2	VIVIENDAS	10V	Personas estrato 1-2	Personas en hogares part.	10V Total	Alto = mayor vuln.	PCA provisional
nivel_educativo_bajo	PERSONAS_DEMOGRAFICO	17PM	Categorías bajo nivel	Pob. 5+ años	17PM Total	Alto = mayor vuln.	Descripción (solapa IPM)
material_paredes_inadecuado	VIVIENDAS	6V	Viviendas mat. inadecuado	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	Descripción (duplica IPM)
sin_acueducto	VIVIENDAS	8V	Viviendas sin acueducto	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	Descripción (duplica IPM)
sin_alcantarillado	VIVIENDAS	8V	Viviendas sin alcantarillado	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	Descripción (duplica IPM)
hacinamiento_critico	VIVIENDAS	5V	Hogares >3 pers/cuarto	Viviendas ocupadas presentes	1V_MPIO	Alto = mayor vuln.	Descripción (duplica IPM)
hogares_con_adultos_60mas	HOGARES	2HM	Hogares con adultos 60+	Total hogares	1HM Total	**Pendiente**	Pendiente
IPM_Municipal	IPM	IPM_municipios_region	Agregado 15 privaciones	–	Municipal	Alto = mayor vuln.	Validación externa

Notas:

- Los 7 primeros conforman la matriz candidata provisional para PCA.
- Los siguientes 6 (nivel educativo a hacinamiento) se calculan para descripción y validación cruzada; quedan fuera de PCA por solapamiento directo con IPM.
- `hogares_con_adultos_60mas` tiene dirección pendiente (correlación negativa con IPM).
- `IPM_Municipal` no entra al PCA; es criterio de validación externa.
- `sin_gas_red_publica` y `sin_internet` tienen techo alto (prevalencia alta en muchos municipios); evaluar discriminación.
- `estrato_1_2`: MSA bajo ($\approx 0,414$); decisión de inclusión pendiente.
- `17PM`: verificar si es asistencia escolar (duplica Inasistencia IPM) o nivel educativo.

B Inventario de productos reproducibles (CSV generados)

B.1 Archivos en `datos/intermedio/` (entradas de solo lectura, verificadas por MD5)

1. `contexto_1PM.csv` – Población total por municipio, sexo, grupos de edad, áreas.
2. `contexto_1V.csv` – Viviendas por condición de ocupación, municipio, áreas, tipos.
3. `hogares_1HM_2HM.csv` – Hogares con menores 15 y adultos 60+ por municipio, áreas.
4. `persona_demo_17PM.csv` – Población 5+ por asistencia escolar/nivel educativo, sexo, municipio, áreas.
5. `persona_social_5PM.csv` – Población 10+ por actividad realizada, sexo, municipio, áreas.
6. `viviendas_6V.csv` – Viviendas ocupadas por material paredes exteriores, municipio, áreas.
7. `viviendas_8V.csv` – Viviendas ocupadas por disponibilidad servicios, municipio, áreas.
8. `viviendas_10V.csv` – Personas en hogares por estrato energía, municipio, áreas.
9. `ipm_municipal_ancho.csv` – IPM municipal: 15 privaciones + IPM Municipal + IPM (duplicado) + Cabeceras + Centros poblados.
10. `universo_municipal_maestro.csv` – Lista maestra 1.122 códigos municipales con nombres, departamentos.
11. `control_nacional.csv` – Totales nacionales de referencia (población, hogares, viviendas).

B.2 Archivos en `datos/trabajo/` (denominadores, indicadores, matrices)

1. `denominadores_indicadores.csv` – Denominadores calculados por indicador y municipio.
2. `indicadores_base_total.csv` – 14 indicadores en versión base total (incluye NR en denominador).
3. `indicadores_base_valida.csv` – 14 indicadores en versión base válida (excluye NR).
4. `matriz_base_total.csv` – Matriz 1.122×7 (indicadores PCA provisionales, base total).
5. `matriz_base_valida.csv` – Matriz 1.122×7 (indicadores PCA provisionales, base válida).
6. `parametros_estandarizacion.csv` – Media y DE por indicador para estandarización (pre-PCA).

B.3 Archivos en `resultados/verificacion_consolidados/` (inventario y validaciones)

1. `nombres_columnas_fuente.csv` – Inventario de tablas origen y sus columnas.
2. `validaciones.csv` – Resultados de validaciones programadas (llaves, sumas, rangos, MD5).
3. `VERIFICACION_CONSOLIDADOS.md` – Reporte narrativo de verificación estructural.

B.4 Archivos en `resultados/base_trabajo/` (25 CSV: calidad, sensibilidad, diagnósticos)

1. `especificacion_indicadores.csv` – Especificación completa 14 indicadores (fuente, numerador, denominador, dirección, uso).
2. `crosswalk_enlace.csv` – Equivalencias territoriales para enlace SECOP futuro (94663, 27493, etc.).
3. `validaciones.csv` – (Copia) Validaciones de indicadores y matriz.
4. `auditoria_conteos.csv` – Auditoría por variable: disponibles, faltantes, negativos, no enteros.
5. `areas_inexistentes.csv` – Municipios donde no existe Cabecera/Centro poblado/Rural disperso.
6. `ausencias_estructurales_1PM.csv` – Combinaciones municipio-área-edad ausentes en 1PM (335, 119 municipios).
7. `municipios_sin_cabecera.csv` – Detalle 20 municipios sin cabecera (código, nombre, tipo, población).
8. `resumen_sin_cabecera_departamento.csv` – Agrupación por departamento de municipios sin cabecera.
9. `resumen_hallazgos.csv` – Resumen cifras de control y hallazgos con estado.
10. `covariables_descriptivas.csv` – Datos municipales de contexto (población, % rural, banderas calidad).
11. `estadisticos_indicadores.csv` – Descriptivos por indicador (rango, media, mediana, asimetría, % ceros).
12. `varianza_indicadores.csv` – Varianza por indicador; señalización varianza casi nula.

13. outliers_z_mayor_4.csv – Conteo municipios con al menos un $|z| > 4$ (32 municipios).
14. parametros_estandarizacion.csv – Media y DE para estandarizar indicadores propuestos.
15. correlaciones_pares.csv – Correlación Pearson para cada par de 7 indicadores (21 pares).
16. pares_correlacion_ge_090.csv – Pares con $|r| \geq 0,90$ (vacío).
17. pares_correlacion_ge_095.csv – Pares con $|r| \geq 0,95$ (vacío).
18. diagnosticos_aptitud.csv – KMO global, Bartlett, determinante (diagnósticos previos, no PCA).
19. kmo_por_indicador.csv – MSA (KMO individual) por indicador (estrato 1–2 $\approx 0,414$).
20. nr_item_municipal.csv – Valores municipales de ítems NR (con bases y proporciones; estrato "no tiene" aparte).
21. sensibilidad_nr_municipio.csv – Comparación municipal base total vs. base válida (diferencias, marcas).
22. sensibilidad_nr.csv – Resumen sensibilidad NR por indicador.
23. md5_insumos_antes.csv – Hashes MD5 de 11 archivos entrada antes de ejecución.
24. md5_insumos_despues.csv – Hashes MD5 después; confirman sin cambios.

B.5 Archivos en resultados/auditoria_estadistica/ (diagnósticos multivariados)

Generados por R/03_auditoria_indicadores.R (9 salidas). Contenido detallado pendiente de documentar en reporte Auditoria_Estadistica_Indicadores.

B.6 Archivos de configuración y scripts

- R/00_config.R – Parámetros editables (rutas, umbrales NR, cobertura, outliers, KMO, banderas PCA/bootstrap).
- R/01_verificar_consolidados.R – Verificación estructural, universo maestro.
- R/02_base_final_indicadores.R – Construcción indicadores, matrices, diagnósticos base.
- R/03_auditoria_indicadores.R – Auditoría estadística preliminar (descriptivos, correlaciones, KMO, Bartlett, outliers).

- `R/funciones/io.R` – Lectura/escritura, conversión, hashes MD5.
- `R/funciones/validacion.R` – Controles estructurales y de calidad.
- `R/funciones/auditoria_estadistica.R` – Diagnósticos multivariados.
- `R/tests/test_pipeline_indicadores.R` – Prueba integridad byte-a-byte (34 CSV regenerados idénticos).