INFORME 1 METODOLÓGICO

Proyecto Desarrollo Social Económico

¿Cómo se asocia la distribución territorial de la contratación pública con las condiciones socioeconómicas de las unidades territoriales colombianas?

Elaborado por:

Juan Diego Gallo

Investigador en Estadística Aplicada

Octubre de 2026

Versión 1.0

Resumen

Este informe documenta el proceso metodológico del proyecto *Desarrollo Social Económico*, que busca estudiar la asociación territorial entre contratación pública (SECOP II) y condiciones socioeconómicas en Colombia. La pregunta guía es: **¿Cómo se asocia la distribución territorial de la contratación pública con las condiciones socioeconómicas de las unidades territoriales colombianas?**

El informe cubre la selección de fuentes (CNPV 2018, IPM 2018 y DIVIPOLA), la homologación territorial, el tratamiento de datos faltantes, la construcción y control de indicadores y los diagnósticos preliminares. El universo contiene 1.122 códigos territoriales, incluidas áreas no municipalizadas; por ello no se describe como 1.122 municipios. Se revisaron nueve cuadros operativos. La especificación vigente registra 17 definiciones de indicadores; siete forman una matriz candidata provisional y las demás son descriptivas, contextuales o requieren revisión. Las fórmulas, denominadores y escenarios de no respuesta se documentan en los archivos reproducibles.

En la matriz base total, los diagnósticos reportan KMO = $0,642$, Bartlett $\chi^2 = 4664,873$ (21 gl; $p < 0,001$), determinante = $0,0154$ y cero pares con $|r| \geq 0,90$. El MSA de estrato 1–2 es $0,414$; 32 unidades territoriales presentan al menos un $|z| > 4$. Son resultados preliminares: Bartlett puede ser sensible al tamaño del universo, un valor significativo no valida el PCA y el análisis de componentes aún no se ha ejecutado.

El Índice de Vulnerabilidad Socioeconómica (IVS) **no está construido**. Además, las variables censales miden condiciones estructurales transversales, no exposición a riesgos ni capacidad de respuesta; un índice futuro sería una aproximación parcial y deberá justificarse conceptualmente. El IPM se reserva para comparación externa, aunque la convergencia con él no sería una prueba independiente de validez. SECOP II y el análisis espacial siguen pendientes.

El informe distingue resultados reproducibles, decisiones provisionales y etapas futuras. Sus cifras deben interpretarse conforme a la fecha de corte y a las fuentes de evidencia indicadas.

Fecha de corte: 13 de octubre de 2026.

Scripts de referencia: `R/00_config.R`, `R/01_verificar_consolidados.R`, `R/02_base_final_indicadores.R`, `R/03_auditoria_indicadores.R`.

Productos reproducibles: `datos/trabajo/`, `resultados/base_trabajo/`, `resultados/auditoria_estadistica`

Palabras clave

Vulnerabilidad socioeconómica, Análisis de Componentes Principales (PCA), Indicadores municipales, Censo Nacional de Población y Vivienda 2018 (CNPV 2018), Índice de Pobreza Multidimensional (IPM) 2018, DIVIPOLA, Contratación pública (SECOP II), Medición multidimensional, Análisis territorial, Metodología de investigación cuantitativa.

Índice

Resumen I

Palabras clave II

1. Introducción **1**

1.1. Contexto y planteamiento del problema 1

1.2. Justificación 1

1.3. Antecedentes del proyecto 1

1.4. Objetivo del informe 2

1.5. Alcance y limitaciones declaradas 2

1.6. Estructura del documento 3

2. Marco metodológico y conceptual **3**

2.1. Vulnerabilidad socioeconómica 3

2.2. Medición multidimensional 3

2.3. Indicadores socioeconómicos 4

2.4. Reducción de dimensionalidad y PCA 4

2.5. Relación futura con contratación pública (SECOP II) 5

3. Planteamiento metodológico **6**

3.1. Pregunta de investigación 6

3.2. Objetivo general 6

3.3. Objetivos específicos 6

3.4. Unidad de análisis 7

3.5. Alcance del estudio 7
3.6. Naturaleza del análisis 8

4. Fuentes de información **8**

4.1. Censo Nacional de Población y Vivienda 2018 (CNPV 2018) 8
4.2. Índice de Pobreza Multidimensional 2018 (IPM 2018) 8
4.3. DIVIPOLA – Códigos municipales 9
4.4. SECOP II – Contratación pública (fuente futura) 9
4.5. Justificación de las fuentes 10

5. Unidad territorial y universo de análisis **10**

5.1. Municipio como unidad de análisis 10
5.2. Códigos territoriales 10
5.3. Cobertura municipal 11
5.4. Coincidencias entre fuentes 11
5.5. Diferencias territoriales y casos especiales 11
5.6. Unidades territoriales sin cabecera (20 casos) 11
5.7. Código 94663 (Mapiripana) – Relación con 94343 (Barrancominas) 12
5.8. Código 27493 (Nuevo Belén de Bajirá) – Conflicto territorial 12
5.9. Municipios sin centro poblado (192 casos) 12
5.10. Áreas territorialmente inexistentes 12
5.11. Ausencias estructurales en combinaciones demográficas 13
5.12. Resumen de decisiones territoriales 13

6. Proceso de selección y depuración de bases **13**

6.1. Inventario inicial 13
6.2. Inspección de hojas/cuadros 14
6.3. Selección de cuadros relevantes 14
6.4. Selección de variables 14
6.5. Criterios de inclusión 14
6.6. Criterios de exclusión 15
6.7. Homologación territorial 15
6.8. Consolidación 16

7. Tratamiento de datos faltantes **16**

7.1. Definición de faltante 16

7.2. No respuesta (NR) 17

7.3. Distinción: `no_tiene_estrato` vs. `no_sabe_no_responde` 17

7.4. Ausencia estructural 17

7.5. Denominadores nulos 18

7.6. Casos 0/0 18

7.7. Municipios sin determinadas áreas 18

7.8. Decisiones de tratamiento adoptadas 18

7.9. Justificación de no imputación 18

8. Construcción de indicadores socioeconómicos **19**

8.1. Principios de construcción 19

8.2. Numeradores 20

8.3. Denominadores y poblaciones de referencia 20

8.4. Verificación de población de referencia 20

8.5. Escala 21

8.6. Dirección de vulnerabilidad 21

8.7. Indicadores seleccionados (matriz candidata provisional) 22

8.8. Indicadores descartados del PCA (descripción/solapamiento IPM) 22

8.9. Indicadores reservados para validación 23

8.10. Especificación técnica 23

9. Control de calidad de los indicadores **23**

9.1. Validaciones estructurales 23

9.2. Consistencia de conteos 23

9.3. Rangos 24

9.4. Valores imposibles 25

9.5. Duplicados 25

9.6. Cobertura territorial 25

9.7. Integridad de fuentes 25

9.8. Resumen de hallazgos de control 25

10. Diagnóstico estadístico preliminar **26**

10.1. Estadística descriptiva disponible 26

10.2. Variabilidad 27

10.3. Correlaciones preliminares 27

10.4. Outliers 27

10.5. Diagnósticos de adecuación multivariada 28

10.6. Medida de Adecuación Muestral Individual (MSA por indicador) 28

10.7. Sensibilidad a No Respuesta (NR) 28

10.8. Estado de la auditoría estadística 29

11. Preparación para PCA **29**

11.1. Objetivo del PCA 29

11.2. Justificación metodológica 30

11.3. Variables candidatas 30

11.4. Criterios que deberán evaluarse 31

11.5. Procedimientos pendientes 32

11.6. Precauciones frente a circularidad con IPM 32

11.7. Configuración técnica 33

12. Reproducibilidad y arquitectura computacional **33**

12.1. Organización del repositorio 33

12.2. Scripts principales 34

12.3. Flujo de procesamiento 35

12.4. Trazabilidad 35

12.5. Control de integridad 36

12.6. Reproducibilidad 36

13. Limitaciones actuales **37**

13.1. Auditoría estadística integral pendiente 37

13.2. PCA no ejecutado 38

13.3. IVS (Índice de Vulnerabilidad Socioeconómica) no construido 38

13.4. Validación externa con IPM pendiente 38

13.5. Integración SECOP II pendiente 38

13.6. Análisis de asociación/correspondencia pendiente 39
13.7. Análisis espacial condicionado 39
13.8. Otras limitaciones técnicas 39

14. Estado del proyecto y etapas siguientes **40**

14.1. Tabla de estado general 40
14.2. Decisiones vigentes registradas (extracto de `Resumen_General.md`) 40
14.3. Resultados comprobados que orientan el siguiente paso 40
14.4. Pendientes y decisiones del autor (próximas acciones) 41
14.5. Arquitectura futura del proyecto 42

15. Conclusiones metodológicas **42**

15.1. ¿Qué se ha construido hasta ahora? 42
15.2. ¿Qué decisiones metodológicas están consolidadas? 43
15.3. ¿Qué problemas fueron detectados y cómo fueron tratados? 44
15.4. ¿Qué información queda lista para el análisis multivariado? 44
15.5. ¿Qué etapas faltan? 44
15.6. Cierre 45

Anexos **47**

A. Especificación vigente de indicadores **47**

B. Inventario reproducible de datos y productos **49**

B.1. Tablas intermedias 49
B.2. Bases de trabajo 49
B.3. Verificación de consolidados 49
B.4. Resultados y auditoría 49
B.5. Scripts 50

Índice de cuadros

1. Fuentes CNPV 2018 utilizadas 8
2. Justificación de fuentes utilizadas 10
3. Universo de códigos territoriales y cobertura 11
4. Decisiones territoriales clave 13
5. Cuadros seleccionados del CNPV 2018 14
6. Resumen de decisiones sobre faltantes 19
7. Denominadores por indicador 21
8. Dirección de vulnerabilidad por indicador 21
9. Validaciones estructurales clave (extracto de `validaciones.csv`) 24
10. Cobertura territorial y calidad por fuente 25
11. Estadísticos descriptivos por indicador (matriz base total) – extracto de `estadisticos_indicadores.csv` 27
12. Diagnósticos globales de aptitud para PCA (matriz base total, 7 indicadores) 28
13. Scripts principales del pipeline activo 34
14. Trazabilidad decisiones – archivo evidencia 36
15. Estado del proyecto por etapa (corte 13/10/2026) 40
16. Problemas detectados y tratamiento 44
17. Variables de la matriz candidata y principales reservas conceptuales 47

1 Introducción

1.1 Contexto y planteamiento del problema

La distribución territorial de la contratación pública en Colombia ha sido objeto de creciente atención académica y de política pública. La pregunta central de este proyecto es:

> **¿Cómo se distribuye territorialmente la contratación pública en relación con las condiciones socioeconómicas de las unidades territoriales colombianas?**

Esta interrogante conecta dos dimensiones fundamentales del desarrollo: la asignación de recursos públicos a través de la contratación estatal y las condiciones estructurales de los territorios donde esos recursos se ejecutan. Una correspondencia sistemática (o su ausencia) tendría implicaciones directas para el diseño de políticas de equidad territorial, la focalización de la inversión pública y los mecanismos de control y transparencia.

1.2 Justificación

Los municipios colombianos presentan heterogeneidad en sus condiciones socioeconómicas, infraestructura, capacidad institucional y acceso a mercados. La contratación pública también presenta patrones territoriales que pueden responder a necesidades, capacidades administrativas, localización de proveedores y reglas de asignación. Estudiar su asociación con las condiciones socioeconómicas puede aportar evidencia para:

- Evaluar si la contratación pública se concentra en municipios con mayores condiciones de vulnerabilidad (enfoque de equidad) o si reproduce desigualdades preexistentes.
- Proporcionar evidencia empírica para el diseño de mecanismos de focalización territorial.
- Contribuir a la literatura sobre economía política de la contratación pública y desarrollo territorial en contextos de descentralización.

1.3 Antecedentes del proyecto

El proyecto se origina en la necesidad de construir una base de evidencia rigurosa, reproducible y metodológicamente transparente. Las etapas precedentes han incluido:

1. Revisión del estado del arte sobre vulnerabilidad socioeconómica, medición multidimensional y contratación pública en Colombia.

2. Selección y auditoría de fuentes primarias: Censo Nacional de Población y Vivienda 2018 (CNPV 2018), Índice de Pobreza Multidimensional 2018 (IPM 2018) y DIVIPOLA.
3. Definición de la unidad de análisis (municipio) y homologación territorial entre fuentes.
4. Construcción de indicadores socioeconómicos municipales comparables.
5. Diagnósticos estadísticos preliminares de aptitud para análisis multivariado.

El presente informe consolida metodológicamente estas etapas. Su alcance empírico termina en la preparación y diagnóstico preliminar de indicadores censales de 2018; todavía no contiene resultados sobre contratación pública ni permite responder la pregunta sustantiva.

1.4 Objetivo del informe

Documentar de manera rigurosa, reproducible y trazable **todo el proceso metodológico realizado hasta el estado actual del proyecto**, desde la selección y auditoría inicial de las fuentes de información hasta la construcción de los indicadores socioeconómicos municipales y los diagnósticos preliminares. Este documento es el **primer informe metodológico formal del proyecto** y está diseñado para crecer modularmente con las etapas subsiguientes.

1.5 Alcance y limitaciones declaradas

- **No se afirma** que los indicadores hayan sido aprobados definitivamente para PCA.
- **No se afirma** que se haya ejecutado un Análisis de Componentes Principales (PCA).
- **No se afirma** que exista un Índice de Vulnerabilidad Socioeconómica (IVS) definitivo.
- **No se afirma** que se haya seleccionado definitivamente la estructura factorial.
- **No se afirma** que se haya realizado validación estadística definitiva del índice.
- **No se afirma** que SECOP II haya sido integrado.
- **No se afirma** que se haya realizado análisis espacial.

Cuando una etapa esté pendiente, se identifica explícitamente en la sección 13 y en la tabla de estado del proyecto (Sección 14).

1.6 Estructura del documento

El informe presenta, en este orden, el marco conceptual, el diseño y alcance, las fuentes y unidades territoriales, la selección y tratamiento de datos, la construcción y control de indicadores, los diagnósticos preliminares, el plan de PCA y la reproducibilidad. Cierra con las limitaciones, el estado de avance y las decisiones pendientes.

2 Marco metodológico y conceptual

2.1 Vulnerabilidad socioeconómica

La vulnerabilidad social no es sinónimo de pobreza observada. En el enfoque de activos y oportunidades, remite a la exposición a riesgos y a la capacidad desigual de personas y hogares para movilizar activos y responder a cambios adversos; por ello tiene una dimensión dinámica que una medición transversal de privaciones no captura por completo (Kaztman and Filgueira, 1999; Pizarro, 2001).

El proyecto dispone, por ahora, de una fotografía censal de condiciones socioeconómicas y de vivienda de 2018. En consecuencia, sus variables observan principalmente **privaciones o condiciones estructurales territoriales**; no miden directamente exposición a choques, recursos de respuesta, resiliencia ni trayectorias de bienestar. El término *vulnerabilidad* describe la motivación sustantiva del proyecto, pero cualquier índice futuro deberá presentarse como una medida operativa y parcial de condiciones asociadas a ella, no como una medición exhaustiva de vulnerabilidad.

La pobreza multidimensional también difiere de la vulnerabilidad: identifica privaciones según una regla de identificación y agregación definida, mientras que la vulnerabilidad pone el foco en la posibilidad de que riesgos y capacidades de respuesta produzcan pérdidas de bienestar. El enfoque de capacidades de Sen ayuda a situar el bienestar más allá del ingreso, pero no convierte por sí mismo una colección de proporciones municipales en una medida validada de vulnerabilidad (Sen, 1999; Alkire et al., 2011).

2.2 Medición multidimensional

La construcción de una medida territorial requiere:

1. **Selección de dimensiones y indicadores** teóricamente fundados y empíricamente observables.
2. **Construcción de indicadores comparables** a nivel municipal (tasas, proporciones, índices nor-

malizados).

3. **Agregación** explícita, con reglas de normalización y ponderación justificadas y análisis de compensabilidad entre dimensiones.

4. **Validación** conceptual, estadística y externa, con criterios que no reproduzcan mecánicamente los insumos del índice.

En el contexto colombiano, el **Índice de Pobreza Multidimensional (IPM)** del DANE es un referente oficial para medir pobreza mediante 15 indicadores en cinco dimensiones (DANE, 2019). El proyecto lo reserva para una comparación externa posterior. Excluir indicadores idénticos del conjunto de entrada reduce la circularidad, pero no garantiza independencia conceptual: varias condiciones censales pueden estar estrechamente relacionadas con las privaciones del IPM. La validación deberá interpretarse como evidencia de convergencia entre medidas relacionadas, no como prueba autónoma de validez.

2.3 Indicadores socioeconómicos

Un indicador socioeconómico territorial debe documentar:

- **Relevancia:** Captar una faceta de vulnerabilidad (privación, carencia, rezago, exclusión).
- **Comparabilidad:** Mismo denominador conceptual y escala homogénea (proporción $[0, 1]$ o tasa por 10^3/ 10^4 hab.).
- **Direccionalidad:** Qué significa un valor alto y si esa orientación representa una privación, una condición contextual o una composición demográfica.
- **Independencia relativa:** Baja colinealidad con otros indicadores de la matriz; no duplicar privaciones ya capturadas por el IPM si se busca validación externa no circular.
- **Disponibilidad:** Observado para la totalidad (o casi totalidad) del universo municipal.

2.4 Reducción de dimensionalidad y PCA

El Análisis de Componentes Principales (PCA) es una técnica de **reducción de dimensionalidad**: expresa las variables como combinaciones lineales ortogonales ordenadas por la varianza que explican. PCA no es, por sí mismo, un modelo de factores latentes ni demuestra que las variables midan un único constructo (Jolliffe, 2002; Abdi and Williams, 2010).

En el contexto de índices compuestos de vulnerabilidad, el PCA se utiliza para:

- Describir patrones de covariación y resumir la variación observada.
- Evaluar si uno o más componentes ofrecen una síntesis interpretable y estable.
- Considerar scores como una opción de agregación, comparándolos con alternativas y haciendo explícita la ponderación inducida por los datos.

Supuestos y precauciones críticas:

1. **Adecuación multivariada:** KMO y MSA son diagnósticos heurísticos, no pruebas automáticas de aprobación; Bartlett puede ser muy sensible cuando el número de unidades es grande.
2. **Linealidad y correlaciones:** El PCA captura estructura lineal; correlaciones muy altas ($|r| > 0,9$) indican redundancia; correlaciones muy bajas sugieren ausencia de factor común.
3. **Distribución:** Se inspeccionan asimetría, concentración y observaciones influyentes; las transformaciones se justifican según el indicador y no se aplican automáticamente.
4. **Escalado:** Compartir el rango $[0, 1]$ no implica varianzas comparables. Si se usa la matriz de correlaciones, las variables quedan estandarizadas; debe documentarse la matriz y la decisión.
5. **Interpretabilidad:** Ningún componente se denomina "vulnerabilidad general" sin coherencia conceptual y estabilidad empírica.
6. **No circularidad con validación externa:** Si el IPM se usa para validar el IVS, los indicadores que replican directamente privaciones del IPM deben excluirse de la matriz PCA o tratarse con extrema cautela (Booysen, 2002).

Estado actual: En la matriz base total, KMO = $0,642$, Bartlett $\chi^2 = 4664,873$ (21 gl; $p < 0,001$), determinante = $0,0154$ y el MSA de estrato 1–2 es $0,414$. Son diagnósticos preliminares: no constituyen una aprobación del PCA y deben leerse junto con la revisión conceptual, distribución, sensibilidad y estructura de correlaciones (Sección 13.1).

2.5 Relación futura con contratación pública (SECOP II)

La integración con SECOP II es una etapa **posterior y condicionada** a la consolidación del IVS. El diseño metodológico previsto contempla:

- **Unidad temporal y territorial por definir:** La matriz censal es transversal (2018); cualquier análisis temporal de SECOP deberá justificar el periodo comparable y distinguir unidades municipales de áreas no municipalizadas.
- **Indicadores SECOP II:** Valor total contratado, número de contratos, concentración (Herfindahl), tipos de contrato, sectores, adjudicatarios.
- **Denominadores:** PIB municipal, población, presupuesto municipal, o valor total de contratación nacional como referencia.
- **Análisis de asociación:** Correlaciones, modelos de panel, análisis de correspondencia, pruebas de hipótesis sobre focalización.
- **Análisis espacial:** Autocorrelación espacial (Moran's I), modelos espaciales, clústeres de vulnerabilidad-contratación, solo si el diagnóstico lo justifica.

El `crosswalk_enlace.csv` documenta las equivalencias territoriales pendientes para este enlace futuro (códigos 94663 → 94343, hipótesis 27493 → 27615).

3 Planteamiento metodológico

3.1 Pregunta de investigación

¿Cómo se asocia la distribución territorial de la contratación pública con las condiciones socioeconómicas de las unidades territoriales colombianas?

3.2 Objetivo general

En una etapa futura, analizar la asociación territorial entre indicadores de contratación pública (SECOP II) y condiciones socioeconómicas observadas en unidades territoriales colombianas. El diseño previsto contempla construir y evaluar una medida sintética con indicadores del CNPV 2018 y contrastarla con el IPM 2018; el uso de PCA y la denominación IVS son hipótesis metodológicas por evaluar, no decisiones ya validadas.

3.3 Objetivos específicos

1. Auditar y homologar las fuentes de información territorial y socioeconómica (CNPV 2018, IPM 2018, DIVIPOLA) a nivel municipal.

2. Construir indicadores socioeconómicos municipales comparables, con fórmulas explícitas, poblaciones de referencia definidas y dirección de vulnerabilidad orientada.
3. Realizar control de calidad estructural y estadístico de los indicadores (consistencia, cobertura, rangos, outliers, correlaciones, aptitud multivariada).
4. Evaluar la adecuación de la matriz de indicadores para Análisis de Componentes Principales (KMO, Bartlett, MSA, estructura de correlaciones, distribución).
5. Evaluar si PCA es apropiado; si lo es, seleccionar componentes, interpretar cargas y valorar si procede construir un índice sintético (etapa **pendiente**).
6. Validar el IVS externamente mediante correlación con el IPM municipal agregado, evitando circularidad (etapa **pendiente**).
7. Integrar datos de contratación pública SECOP II a nivel municipal-año (etapa **pendiente**).
8. Analizar la asociación/correspondencia entre IVS y patrones de contratación pública (etapa **pendiente**).
9. Realizar análisis espacial condicionado a resultados previos (etapa **pendiente**).

3.4 Unidad de análisis

La unidad observada es el **código territorial** de cinco caracteres en CNPV/IPM 2018. El universo de 1.122 códigos incluye áreas no municipalizadas, por lo que no equivale a 1.122 municipios. No se fusionan ni excluyen códigos en los datos de 2018; los conflictos se documentan para un posible *crosswalk* con SECOP II (`resultados/base_trabajo/crosswalk_enlace.csv`).

3.5 Alcance del estudio

- **Cobertura territorial:** 1.122 códigos/unidades territoriales presentes en CNPV/IPM 2018; el conjunto incluye áreas no municipalizadas y no equivale a 1.122 municipios.
- **Período de referencia:** Año censal 2018 (fotografía transversal).
- **Dimensión analítica:** Condiciones socioeconómicas estructurales observadas en el censo, interpretadas con cautela como aproximaciones parciales a factores asociados con vulnerabilidad.
- **Variables excluidas del alcance actual:** Contratación pública (SECOP II), análisis longitudinal, inferencia causal.

3.6 Naturaleza del análisis

El análisis de esta etapa es **transversal, descriptivo y ecológico**: las unidades de observación son territorios y los datos censales corresponden a 2018. No se realizan inferencias causales ni se infieren condiciones de personas u hogares a partir de promedios territoriales. La asociación con SECOP II requerirá armonizar periodos y unidades geográficas; comparar el censo de 2018 con una ventana contractual 2015–2025 sin una estrategia temporal explícita no sería una comparación contemporánea.

4 Fuentes de información

4.1 Censo Nacional de Población y Vivienda 2018 (CNPV 2018)

El CNPV 2018 es la fuente primaria de información sociodemográfica y de vivienda a nivel municipal. Se utilizaron cuatro de los seis tomos temáticos publicados por el DANE:

Cuadro 1: *Fuentes CNPV 2018 utilizadas*

Tomo	Archivo original	Cuadros municipales seleccionados	Uso principal
Hogares	`HOGARES_Cuadros_CNPV_2018.XLSX`	1HM, 2HM	Estructura hogares: menores 15 años, adultos 60+
Personas Demográfico	`PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx`	1PM, 17PM	Población total (denominadores), nivel educativo
Personas Social	`PERSONAS_SOCIAL_Cuadros_CNPV_2018.XLSX`	5PM	Actividad laboral (desocupación, inactividad)
Viviendas	`VIVIENDAS_Cuadros_CNPV_2018.XLSX`	1V_MPIO, 6V_MPIO, 8V_MPIO, 10V_MPIO	Condición ocupación, materiales, servicios, estrato

Los cuadros departamentales y nacionales fueron **descartados** por no corresponder a la unidad de análisis municipal. La selección de cuadros y variables se documenta en `docs/diccionario/decisiones_variables_` (115 filas, con decisión, motivo y notas de verificación).

4.2 Índice de Pobreza Multidimensional 2018 (IPM 2018)

El IPM 2018 organizado por región (`IPM_2018_organizado_region.xlsx`) contiene:

- Hoja `IPM_municipios_region`: 1.122 municipios × 15 indicadores de privación + IPM Municipal (agregado).
- Hojas por dominio geográfico (Cabeceras, Centros poblados y Rural disperso) — **no usadas para PCA**, solo para análisis de brechas urbano-rural futuras.
- Diccionarios y controles de calidad internos.

Uso en el proyecto:

- **Validación externa futura:** El IPM Municipal agregado se reserva como criterio de validación del IVS (Sección 4.2). **No entra al PCA** para evitar circularidad.

- **Exclusión de indicadores redundantes:** Las 15 privaciones del IPM se compararon con los indicadores censales candidatos; aquellas que replican directamente conceptos del IPM (ej. material inadecuado de paredes, hacinamiento, agua, alcantarillado, analfabetismo, rezago escolar, inasistencia, barreras primera infancia, trabajo infantil, informalidad, dependencia, barreras salud, aseguramiento, pisos) se marcaron como `DESCARTAR` o `DESCRIPCIÓN` en la especificación de indicadores, según el criterio documentado en `decisiones_variables_IVS_CNPV2018.csv`.

4.3 DIVIPOLA – Códigos municipales

Archivo: `DIVIPOLA-_Codigos_municipios_20260917.csv` (82.076 bytes).

- Provee la lista maestra de códigos municipales (5 dígitos), nombres, departamentos y tipos de cabecera.
- Se utiliza como **referencia territorial** para homologación y verificación de cobertura.
- Los 1.122 códigos del universo CNPV/IPM 2018 se validan contra DIVIPOLA; las discrepancias (ej. códigos 94663, 27493, 18 áreas no municipalizadas – ANM) se documentan y **no se resuelven en la base 2018**, reservándose para el *crosswalk* SECOP.

4.4 SECOP II – Contratación pública (fuente futura)

El Sistema Electrónico de Contratación Pública (SECOP II) es la fuente de datos de contratación pública a nivel nacional. **No se ha integrado aún**. Su incorporación está planificada como etapa posterior (Sección 2.5). Requiere:

- Obtención de datos (parquet trimestrales, API, o descarga masiva).
- Definición de ventana temporal (exploratoria 2015–2025).
- Construcción de indicadores municipales-año (valor, número, concentración, sectores).
- *Crosswalk* territorial con códigos 2018 (ver `crosswalk_enlace.csv`).

Cuadro 2: *Justificación de fuentes utilizadas*

Fuente	Justificación	Limitaciones reconocidas
CNPV 2018	Cobertura censal universal; desglose municipal; variables de vivienda, demografía, educación, trabajo, hogares.	Fotografía 2018; no captura dinámicas recientes; algunas variables con categorías NR amplias.
IPM 2018	Referente oficial de pobreza multidimensional; 15 privaciones validadas; disponible a nivel municipal.	Agrega privaciones en un índice; usar sus componentes en PCA generaría circularidad si se valida con el agregado.
DIVIPOLA	Estándar oficial de códigos territoriales; permite homologación y trazabilidad.	Versión 2026 vs. datos 2018: cambios administrativos recientes no reflejados en datos censales.
SECOP II	Fuente primaria de contratación pública; detalle contractual, temporal, geográfico.	Pendiente de obtención, limpieza, agregación municipal y definición de denominadores.

4.5 Justificación de las fuentes

5 Unidad territorial y universo de análisis

5.1 Municipio como unidad de análisis

El municipio es la unidad administrativa de interés sustantivo del proyecto. Sin embargo, la base analítica de 2018 contiene **1.122 códigos territoriales** y no debe describirse como un universo de 1.122 municipios: incluye 18 áreas no municipalizadas (ANM), además de unidades con particularidades de cabecera. En esta etapa, la unidad observada es el código territorial conservado en las fuentes CNPV/IPM; las ANM se identifican por separado y no se fusionan con municipios.

La escala territorial es pertinente para el estudio porque:

- Competencias en prestación de servicios públicos (educación, salud, agua, saneamiento).
- Ejecución de contratación pública local y departamental.
- Disponibilidad de información censal y estadística oficial desagregada.
- Identidad territorial para análisis de vulnerabilidad y políticas públicas.

La elección de esta escala responde a la **comparabilidad entre fuentes** y a la posibilidad de armonizarla con la información de contratación pública. La entidad contratante y el lugar de ejecución de SECOP II no son conceptos equivalentes a la residencia de la población censada; la regla territorial para el futuro enlace deberá definirse y validarse antes del análisis.

5.2 Códigos territoriales

- **Formato:** `codigo_municipio` como **texto de 5 caracteres** (DIVIPOLA), p.ej. “11001” (Bogotá), “05001” (Medellín).
- **Nunca se usa el nombre municipal como llave** (riesgo de homónimos, variaciones ortográficas, cambios de nombre).
- **Longitud fija:** Se valida que todos los códigos tengan 5 caracteres; se completan con ceros a la izquierda si es necesario.

- **Consistencia entre fuentes:** La unión entre tablas CNPV, IPM y DIVIPOLA se realiza exclusivamente por `codigo_municipio`.

5.3 Cobertura municipal

El universo de trabajo adoptado son los **1.122 códigos territoriales** con datos en CNPV 2018 e IPM 2018. Esta cifra se valida en `resultados/base_trabajo/validaciones.csv` (llave/prefijo de `ipm_municipal_ancho`: 1.122 evaluados, cero violaciones). La cifra describe registros territoriales, no el número de municipios administrativos.

Cuadro 3: *Universo de códigos territoriales y cobertura*

Concepto	Cantidad	Fuente/Evidencia
Códigos territoriales CNPV 2018	1.122	`universo_municipal_maestro.csv`
Códigos territoriales IPM 2018	1.122	`resultados/base_trabajo/validaciones.csv`
Registros del universo compartido CNPV ∩ IPM	1.122	`Final_Base.md`, validaciones
Áreas no municipalizadas incluidas	18	DIVIPOLA; identificadas en controles territoriales

5.4 Coincidencias entre fuentes

La homologación territorial entre CNPV 2018, IPM 2018 y DIVIPOLA se realizó mediante `codigo_municipio`. Los controles de llave/prefijo en `validaciones.csv` reportan **cero violaciones** para todas las tablas intermedias (`contexto_1PM`, `contexto_1V`, `hogares_1HM_2HM`, `persona_demo_17PM`, `persona_social_5PM`, `viviendas_6V`, `viviendas_8V`, `viviendas_10V`, `ipm_municipal_ancho`).

5.5 Diferencias territoriales y casos especiales

A pesar de la coincidencia en el conteo total (1.122), existen **diferencias estructurales** que no son errores sino consecuencias de definiciones territoriales distintas:

5.6 Unidades territoriales sin cabecera (20 casos)

Veinte unidades territoriales no tienen área "Cabecera" censada en 2018. Coinciden con los **20 valores `NA` estructurales del IPM para Cabeceras** (validación "20 NA IPM cabeceras = unidades sin cabecera": 20 evaluados, 0 violaciones).

- 18 corresponden a **Áreas No Municipalizadas (ANM)** en DIVIPOLA 2026.
- 2 códigos adicionales: `94343` (Barrancominas, 7.207 hab.) y `94663` (Mapiripana, 1.011 hab.), cuya población rural dispersa suma 8.218 hab.

- Población total en las 20 unidades sin cabecera: **34.787 habitantes** (incluye 26.569 en las 18 ANM + 8.218 en los dos códigos adicionales).
- Proporción rural dispersa en estos municipios: 47,27 % – 100 %.
- Detalle en `resultados/base_trabajo/municipios_sin_cabecera.csv` y `resumen_sin_cabecera_depar`

5.7 Código 94663 (Mapiripana) – Relación con 94343 (Barrancominas)

- Documentado para la capa SECOP futura: `94663` → `94343`.
- En los datos CNPV/IPM 2018 **permanecen ambos códigos separados**; no se fusionan ni reasignan conteos.
- Ver `Final_Base.md` y `crosswalk_enlace.csv`.

5.8 Código 27493 (Nuevo Belén de Bajirá) – Conflicto territorial

- Se propone `27615` (Riosucio) como "padre" territorial, **pendiente de verificación DANE/IGAC**.
- Existe conflicto histórico con `05480` (Mutatá).
- Evidencia compatible: Riosucio suma 48.257 habitantes y un centro poblado de 13.504; Mutatá suma 12.607. No prueba el límite; **no se fraccionan ni reasignan conteos CNPV**.
- Ver `Final_Base.md` y `crosswalk_enlace.csv`.

5.9 Municipios sin centro poblado (192 casos)

192 municipios no tienen área "Centro poblado" en 2018. Se conservan como **cobertura territorial estructural**; no son faltantes estadísticos. Ver `Final_Base.md` (validación "Municipios sin Centro poblado": 192, PASS).

5.10 Áreas territorialmente inexistentes

El archivo `resultados/base_trabajo/areas_inexistentes.csv` documenta, por municipio, qué áreas (Cabecera, Centro poblado, Rural disperso) no existen. Esto permite distinguir **ausencia estructural** (el área no existe en el territorio) de **faltante estadístico** (el dato no se capturó). Ejemplo: en un municipio 100 % urbano, la ausencia de "Rural disperso" es estructural, no un dato que deba imputarse.

5.11 Ausencias estructurales en combinaciones demográficas

- **Grupos de edad:** 335 combinaciones municipio-área-grupo de edad ausentes en 1PM (119 municipios afectados). Ver `ausencias_estructurales_1PM.csv`.
- **Tipo de vivienda:** 1.202 combinaciones ausentes.
- **Tratamiento:** Se completan como **ceros estructurales** y se marcan con *flags*; **no se imputan** estadísticamente. No se crean filas para áreas inexistentes.

5.12 Resumen de decisiones territoriales

Cuadro 4: *Decisiones territoriales clave*

Aspecto	Decisión	Evidencia
Universo municipal	1.122 códigos CNPV/IPM 2018, sin fusiones	`Final_Base.md`, `universo_municipal_maestro.csv`
Llave de unión	`codigo_municipio` (texto 5 chars)	`R/01_verificar_consolidados.R`
Municipios sin cabecera (20)	Conservados; NA estructural en IPM Cabecera	`municipios_sin_cabecera.csv`
Código 94663	Relación futura 94663 → 94343 (solo enlace SECOP)	`crosswalk_enlace.csv`
Código 27493	Hipótesis 27615 como padre; conflicto con 05480; sin reasignar	`crosswalk_enlace.csv`
Ausencias estructurales	Ceros estructurales con flags; no imputación	`ausencias_estructurales_1PM.csv`, `areas_inexistentes.csv`
Cobertura 5PM / pob_10mas	28 municipios con cobertura $< 0,9$ (umbral configurable)	`validaciones.csv`, `R/00_config.R`

6 Proceso de selección y depuración de bases

6.1 Inventario inicial

Se partió de **seis archivos fuente originales** del CNPV 2018 provistos por el DANE:

1. `HOGARES_Cuadros_CNPV_2018.XLSX` (976.096 bytes)
2. `PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx` (140.535.605 bytes)
3. `PERSONAS_SOCIAL_Cuadros_CNPV_2018.XLSX` (222.529.081 bytes)
4. `VIVIENDAS_Cuadros_CNPV_2018.XLSX` (8.406.337 bytes)
5. `anexo-censal-pobreza-municipal-2018.xlsx` (1.295.335 bytes) – Anexo metodológico IPM
6. `IPM_2018_organizado_region.xlsx` (2.137.634 bytes) – IPM ya procesado por región

El inventario de hojas, columnas y estructura se generó con `R/01_verificar_consolidados.R` y se documenta en `datos/intermedio/nombres_columnas_fuente.csv` y `resultados/verificacion_consolid`

6.2 Inspección de hojas/cuadros

Cada archivo Excel contiene múltiples hojas (cuadros) a diferentes niveles geográficos (nacional, departamental, municipal). La inspección identificó:

- **Nivel municipal:** Hojas con sufijo `_MPIO` o `_PM` / `_HM` / `_VM`.
- **Nivel departamental:** Sufijo `_DPTO` o `_PD` / `_HD` / `_VD` – **descartados**.
- **Nivel nacional:** Sin desagregación municipal – **descartados**.

6.3 Selección de cuadros relevantes

Se identificaron **nueve cuadros municipales operativos**: siete aportan categorías usadas en indicadores y dos aportan contexto o denominadores. La inclusión de una hoja no implica que todos sus indicadores sean adecuados para PCA:

Cuadro 5: *Cuadros seleccionados del CNPV 2018*

Fuente	Archivo	Cuadro/Hoja	Contenido principal	Decisión
HOGARES	HOGARES_Cuadros_CNPV_2018.XLSX	1HM	Hogares con menores <15 años por área	INCLUIDA
HOGARES	HOGARES_Cuadros_CNPV_2018.XLSX	2HM	Hogares con adultos ≥60 años por área	INCLUIDA
PERSONAS_DEMOGRAFICO	PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx	1PM	Población total por sexo y grupos de edad	CONTEXTO (denominador)
PERSONAS_DEMOGRAFICO	PERSONAS_DEMOGRAFICO_Cuadros_CNPV_2018.xlsx	17PM	Población 5+ por asistencia escolar y sexo	INCLUIDA*
PERSONAS_SOCIAL	PERSONAS_SOCIAL_Cuadros_CNPV_2018.XLSX	5PM	Población 10+ por actividad realizada la semana anterior	INCLUIDA
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	1V_MPIO	Viviendas por condición de ocupación	CONTEXTO (denominador)
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	6V_MPIO	Viviendas ocupadas por material paredes exteriores	INCLUIDA
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	8V_MPIO	Viviendas ocupadas por disponibilidad servicios públicos	INCLUIDA
VIVIENDAS	VIVIENDAS_Cuadros_CNPV_2018.XLSX	10V_MPIO	Personas en hogares por estrato de energía	INCLUIDA

* La identificación y el uso de 17PM deben verificarse contra el inventario y las hojas fuente antes de construir indicadores educativos. En esta versión esos indicadores no integran la matriz candidata; se excluyen por población de referencia y solapamiento conceptual con el IPM.

6.4 Selección de variables

Para cada cuadro se identificaron las variables necesarias para construir numeradores y denominadores. La especificación vigente registra 17 definiciones operativas; siete integran la matriz candidata y las restantes se destinan a descripción, contexto o revisión. La auditoría registra esta cuenta en `resultados/auditoria_estadistica/09_resumen_auditoria.csv`. Los borradores que informan 14 indicadores deben actualizarse antes de citar ese total como cifra consolidada.

6.5 Criterios de inclusión

1. **Nivel geográfico municipal:** El cuadro debe tener desagregación municipal.

2. **Relevancia para vulnerabilidad:** La variable captura una privación, carencia, rezago o exclusión (ej. hogares con menores, desocupación, vivienda sin servicios, estrato bajo).

3. **No redundancia con IPM:** No replica directamente una de las 15 privaciones del IPM, o si lo hace, se marca para **descripción/validación** (no para PCA).

4. **Disponibilidad de denominador:** Existe población de referencia clara en el mismo cuadro o en cuadro vinculado (1PM, 1V_MPIO).

5. **Calidad de la variable:** Sin problemas insalvables de cobertura, ceros estructurales masivos, o ambigüedad conceptual.

6.6 Criterios de exclusión

1. **Nivel geográfico no municipal:** Departamental, nacional.

2. **No mide privación:** Variables de composición familiar (jefatura, tipología hogar, estado civil, fecundidad, parentesco, autorreconocimiento étnico, territorialidad étnica, migración).

3. **Redundancia con IPM:** Duplican directamente una privación del IPM (ej. analfabetismo, rezago escolar, inasistencia, barreras primera infancia, trabajo infantil, informalidad, dependencia, hacinamiento, material paredes/pisos, agua, alcantarillado, barreras salud, aseguramiento).

4. **Subpoblación pequeña / celdas fragmentadas:** Discapacidad (grados, causas, ayudas), tipologías de hogar generacional/ciclo de vida.

5. **Descripción dudosa / error en índice:** 19PM (descripción idéntica a 18PM).

6. **Edades simples (3PM):** Archivo pesado, celdas pequeñas; se reconstruye desde 1PM.

Estos criterios se aplicaron sistemáticamente y se documentaron en `decisiones_variables_IVS_CNPV2018.c` (columna `decision`: INCLUIDA, CONTEXTO, VALIDACIÓN, DESCARTAR; columna `motivo` y `razon`).

6.7 Homologación territorial

1. Todas las tablas se leen conservando `codigo_municipio` como **texto de 5 caracteres**.

2. Se construye un **universo maestro municipal** (`universo_municipal_maestro.csv`) con los 1.122 códigos.

3. Cada tabla intermedia se valida contra el universo maestro (llave/prefijo, cobertura).

4. Las discrepancias territoriales (94663, 27493, municipios sin cabecera, ANM) se documentan en `crosswalk_enlace.csv` y **no se aplican a los conteos 2018**.

6.8 Consolidación

El proceso de consolidación, ejecutado por `R/02_base_final_indicadores.R` (configurado en `R/00_config.R`), produce:

- **Tablas de contexto (denominadores):** `contexto_1PM.csv`, `contexto_1V.csv` (poblaciones de referencia).
- **Tablas de indicadores en base total y base válida:** Para cada indicador sensible a NR, dos versiones (ver Sección 7).
- **Matrices candidatas para PCA:** `matriz_base_total.csv`, `matriz_base_valida.csv` (1.122 filas $\times$ 7 indicadores candidatos).
- **Archivos de diagnóstico y control:** 25 CSV en `resultados/base_trabajo/` (ver lista en introducción).
- **Integridad de insumos:** Hashes MD5 antes y después (`md5_insumos_antes.csv`, `md5_insumos_despues.csv`) confirman **sin cambios** en los archivos de entrada monitoreados.

La consolidación se documenta en `Final_Base.md` y `Estructura_Bases.md`.

7 Tratamiento de datos faltantes

7.1 Definición de faltante

En este proyecto, "dato faltante" no es una categoría única. Se distingue rigurosamente entre:

1. **Faltante estadístico (NA):** Valor no disponible en la fuente para una combinación municipio-área-variable que *debería* existir.

2. **No respuesta (NR):** Categoría explícita del instrumento censal ("No informa", "Sin información", "No sabe/No responde"). Es un dato observado, no un hueco.

3. **Ausencia estructural:** La unidad territorial o la combinación demográfica *no existe* (ej. área Rural disperso en municipio 100 % urbano; grupo de edad 85+ en municipio pequeño).

4. **Denominador cero:** La población de referencia para construir un indicador es cero (ej. ningún hogar en un área).

5. **Caso 0/0:** Numerador y denominador son cero → cociente indefinido.

7.2 No respuesta (NR)

Los ítems clasificados como NR en los cuadros censales se tratan como **cuestión de calidad del dato**, no como faltante para imputar. Se conservan dos definiciones de denominador, generando **dos versiones de cada indicador sensible a NR**:

- **Base total:** El denominador **incluye** la categoría NR. Ej: $\frac{\text{hogares sin energía}}{\text{total hogares (incl. NR)}}$.
- **Base válida:** El denominador **excluye** la categoría NR (resta NR al total). Ej: $\frac{\text{hogares sin energía}}{\text{total hogares}-\text{NR}}$.

Estos son **escenarios de sensibilidad**, no una decisión definitiva de tratamiento. La elección final se tomará tras revisar `sensibilidad_nr.csv` y `sensibilidad_nr_municipio.csv`.

7.3 Distinción: `no_tiene_estrato` vs. `no_sabe_no_responde`

El ítem "No tiene estrato" (viviendas en zona rural sin asignación de estrato energético) **no se agrupa** con "No sabe/No responde". Se mantiene separado porque:

- Es una **condición estructural** (ruralidad), no una negativa a responder.
- Su prevalencia es alta en zona rural y su tratamiento como NR sesgaría indicadores de estrato 1–2.
- Se documenta en `nr_item_municipal.csv` y se analiza su sensibilidad aparte.

7.4 Ausencia estructural

- **Áreas inexistentes:** 20 municipios sin Cabecera, 192 sin Centro poblado, municipios sin Rural disperso. Ver `areas_inexistentes.csv`. **No se crean filas** para estas áreas; se documentan como NA estructural.
- **Combinaciones demográficas ausentes:** 335 combinaciones municipio-área-grupo de edad ausentes en 1PM (119 municipios); 1.202 combinaciones de tipo de vivienda ausentes. Ver `ausencias_estructural`
- **Tratamiento:** Se completan como **ceros estructurales** y se marcan con *flags* (ej. `flag_ausencia_estructural_e` `flag_ausencia_estructural_vivienda`). **No se imputan** valores estadísticamente.

- **Justificación:** Una ausencia estructural no debe interpretarse como ausencia del fenómeno socioeconómico. Imputar ceros donde no existe la población de referencia crearía indicadores espurios.

7.5 Denominadores nulos

Cuando el denominador de un indicador es cero (población de referencia inexistente en ese municipio-área):

- El resultado del indicador se guarda como `NA`.
- Se genera `flag_indice_indefinido = TRUE`.
- El municipio se mantiene en la base (no se elimina), pero el indicador no contribuye a análisis multivariado para ese caso.

7.6 Casos 0/0

Cuando numerador = 0 y denominador = 0 simultáneamente (ej. cero hogares sin energía y cero hogares totales en un área):

- El cociente es matemáticamente indefinido.
- Se guarda como `NA` y se señaliza con `flag_indice_indefinido`.
- No se convierte en 0 ni en 1; permanece como **indeterminado**.

7.7 Municipios sin determinadas áreas

Los 20 municipios sin cabecera y los 192 sin centro poblado se conservan en el universo. Sus indicadores para las áreas inexistentes son NA estructural. Para el análisis municipal agregado (nivel Total), se usan los totales municipales que **sí existen** (población total, hogares totales, viviendas totales). La proporcionalidad rural/urbana se documenta en `municipios_sin_cabecera.csv` (columna `pct_rural_disperso`).

7.8 Decisiones de tratamiento adoptadas

7.9 Justificación de no imputación

1. **Naturaleza censal:** El CNPV es un censo universal; los "faltantes" son principalmente ausencias estructurales o NR, no omisiones aleatorias.

Cuadro 6: *Resumen de decisiones sobre faltantes*

Situación	Interpretación	Tratamiento en el proyecto
Dato no disponible en fuente (NA)	Faltante estadístico	Conservado como NA; no imputado
Categoría NR explícita	No respuesta del informante	Base total (incluye NR) y base válida (excluye NR); escenarios de sensibilidad
Área territorial inexistente	Ausencia estructural	No se crea fila; NA estructural; no imputado
Combinación demográfica ausente	Ausencia estructural	Cero estructural + flag; no imputado
Denominador = 0	Indefinición matemática	Resultado NA + `flag_indice_indefinido`
Numerador = 0, Denominador = 0	0/0 indeterminado	NA + `flag_indice_indefinido`
IPM Cabecera en 20 municipios	Ausencia estructural (sin cabecera)	20 NA estructurales conservados; cotejados con `municipios_sin_cabecera.csv`

2. **Análisis territorial:** Imputar valores en municipios pequeños o áreas inexistentes introduciría sesgo espacial artificial.

3. **Transparencia y trazabilidad:** Los *flags* y la dualidad base total/base válida permiten evaluar la sensibilidad de cualquier decisión posterior (PCA, IVS) al tratamiento de NR.

4. **Principio de precaución:** Ante ausencia de modelo de imputación validado para datos censales territoriales, la no imputación es la opción más conservadora y reproducible.

La decisión final sobre qué versión (base total o base válida) usar en el PCA queda **pendiente** y se basará en la sensibilidad documentada (`sensibilidad_nr.csv`, `sensibilidad_nr_municipio.csv`) y en la evaluación de adecuación multivariada de cada matriz.

8 Construcción de indicadores socioeconómicos

8.1 Principios de construcción

Todo indicador se construye siguiendo el esquema:

$$I_j = \frac{N_j}{D_j} \tag{1}$$

donde I_j es el indicador j, N_j el numerador (conteo de la condición de vulnerabilidad) y D_j el denominador (población de referencia). Cuando el indicador es una proporción, $I_j \in [0, 1]$. Cuando es una tasa, se expresa por 10^3 o 10^4 habitantes según la magnitud.

Los principios rectores son:

1. **Transparencia de fórmula:** Numerador, denominador y población de referencia explícitos en `especificacion_indicadores.csv`.

2. **Comparabilidad municipal:** Mismo denominador conceptual para todos los municipios.

3. **Escala homogénea:** Proporciones $[0, 1]$ para indicadores PCA; tasas estandarizadas para descripción.

4. **Dirección de vulnerabilidad:** Valor alto ⇒ mayor vulnerabilidad (Sección 8.6).

5. **Tratamiento de NR:** Dos versiones (base total / base válida) para indicadores con categoría NR (Sección 7).

6. **Denominador cero → NA + flag:** No se imputa, no se elimina el municipio.

8.2 Numeradores

Los numeradores son conteos directos de las condiciones de vulnerabilidad extraídos de los cuadros censales seleccionados:

- `1HM`: Hogares con personas menores de 15 años (Total, Cabecera, Centro poblado, Rural disperso).
- `2HM`: Hogares con personas de 60 años y más (Total, Cabecera, Centro poblado, Rural disperso).
- `5PM`: Personas de 10 años y más por actividad realizada la semana anterior (Ocupado, Desocupado, Inactivo, por sexo).
- `6V`: Viviendas ocupadas con personas presentes por material predominante de paredes exteriores.
- `8V`: Viviendas ocupadas con personas presentes por disponibilidad de servicios públicos (Energía, Gas, Acueducto, Alcantarillado, Recolección, Internet).
- `10V`: Personas censadas en hogares particulares por estrato de energía (1, 2, 3, 4, 5, 6, Sin estrato).
- `17PM`: Población de 5 años y más por asistencia escolar y sexo (pendiente verificación: ¿nivel educativo o asistencia?).

8.3 Denominadores y poblaciones de referencia

8.4 Verificación de población de referencia

- El total de `17PM` coincide exactamente con la población de 5+ años de `1PM` en los 1.122 municipios (validación "Diferencias total 17PM vs población 5+ 1PM": 0, PASS). Ver `Final_Base.md`.
- `17PM` **no permite** filtrar categorías de nivel educativo restringidas a población de 10+ años; se calculan usando el total de 17PM y se documenta la discrepancia.
- `pob_10mas` se calculó desde los grupos de 1PM de 10 años o más; la cobertura de 5PM se coteja contra ese valor (28 municipios con cobertura $< 0,9$).

Cuadro 7: *Denominadores por indicador*

Indicador	Denominador	Fuente denominador
Prop. hogares con menores	Total hogares (1HM Total)	1HM
Prop. hogares con adultos 60+	Total hogares (1HM Total)	1HM
Proporción de categorías seleccionadas en actividad (10+)	Población 10+ años (1PM)	1PM (grupos 10+)
Prop. viviendas sin energía	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin gas	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin recolección	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin internet	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. hogares estrato 1-2	Personas en hogares particulares (10V Total)	10V
Prop. población 5+ nivel educativo	Población 5+ años (17PM Total = 1PM 5+)	17PM / 1PM
Prop. viviendas material paredes inadecuado	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin acueducto	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO
Prop. viviendas sin alcantarillado	Viviendas ocupadas presentes (1V_MPIO)	1V_MPIO

8.5 Escala

- **Indicadores para PCA (provisionales):** Proporciones $[0, 1]$ (7 indicadores).
- **Indicadores de descripción/solapamiento IPM:** Proporciones $[0, 1]$ (7 indicadores).
- **No se usan conteos absolutos** en la matriz PCA (no son comparables entre municipios de distinto tamaño).

8.6 Dirección de vulnerabilidad

La decisión metodológica es orientar los indicadores para que:

$$\text{valor alto} \Rightarrow \text{mayor vulnerabilidad} \tag{2}$$

Cuadro 8: *Dirección de vulnerabilidad por indicador*

Indicador	Dirección	Nota
Prop. hogares con menores 15	Alto = mayor vuln.	Carga demográfica infantil
Prop. hogares con adultos 60+	**Pendiente**	Correlación negativa con privaciones IPM ($-0,06$ a $-0,63$); puede ser transición demográfica
Tasa desocupación 10+	Alto = mayor vuln.	Privación laboral
Tasa inactividad 10+	Alto = mayor vuln.	Privación laboral
Prop. viviendas sin energía	Alto = mayor vuln.	Privación servicios
Prop. viviendas sin gas	Alto = mayor vuln.	Privación servicios
Prop. viviendas sin recolección	Alto = mayor vuln.	Privación servicios
Prop. viviendas sin internet	Alto = mayor vuln.	Privación conectividad
Prop. hogares estrato 1-2	Alto = mayor vuln.	Proxy ingreso bajo
Prop. población 5+ bajo nivel educativo	Alto = mayor vuln.	Privación capital humano (si 17PM es nivel educativo)
Prop. viviendas paredes inadecuadas	Alto = mayor vuln.	Privación vivienda (duplica IPM)
Prop. viviendas sin acueducto	Alto = mayor vuln.	Privación servicios (duplica IPM)
Prop. viviendas sin alcantarillado	Alto = mayor vuln.	Privación servicios (duplica IPM)

Nota crítica: El indicador "Hogares con adultos 60+" muestra correlación **negativa** con casi todas las privaciones del IPM (Spearman $-0,06$ a $-0,63$): los municipios más envejecidos tienden a ser *menos* vulnerables. Su dirección debe definirse conceptualmente antes del PCA (puede comportarse como

variable de transición demográfica, no de privación). Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 5.

8.7 Indicadores seleccionados (matriz candidata provisional)

Siete indicadores conforman la **matriz candidata para diagnóstico PCA** (base total y base válida):

1. `actividad_desocupacion_incapacidad_hogar` (derivado de 5PM): agrupa búsqueda de trabajo, oficios del hogar, incapacidad permanente y otra situación. No es una tasa de desempleo y su interpretación como privación laboral es parcial; requiere revisión conceptual antes del PCA.
2. `sin_energia_electrica` (derivado de 8V) – alto = mayor vuln.
3. `sin_gas_red_publica` (derivado de 8V) – alto = mayor vuln.
4. `sin_recoleccion_basuras` (derivado de 8V) – alto = mayor vuln.
5. `sin_internet` (derivado de 8V) – alto = mayor vuln.
6. `hogares_con_menores15` (derivado de 1HM): describe composición demográfica y no es una privación por sí misma.
7. `estrato_1_2` (derivado de 10V): proxy territorial sujeto a limitaciones de cobertura rural; MSA = $0,414$ y dirección como vulnerabilidad requiere revisión.

Estos 7 indicadores son **candidatos para diagnóstico, no una selección aprobada**. Cuatro representan servicios/conectividad, uno combina categorías heterogéneas de actividad, uno describe composición del hogar y uno usa estratificación de cobertura territorial desigual. Antes del PCA se debe justificar la cobertura conceptual de cada dominio y el peso implícito que recibiría.

8.8 Indicadores descartados del PCA (descripción/solapamiento IPM)

Siete indicadores se calculan para descripción y validación cruzada, pero **quedan fuera de la matriz PCA propuesta** por solapamiento directo con privaciones del IPM:

1. Nivel educativo (17PM) – duplica “Bajo logro educativo” / “Analfabetismo” IPM.
2. Material inadecuado de paredes (6V) – duplica “Material inadecuado de paredes exteriores” IPM.

3. Sin acueducto (8V) – duplica “Sin acceso a fuente de agua mejorada” IPM.

4. Sin alcantarillado (8V) – duplica “Inadecuada eliminación de excretas” IPM.

5. Hacinamiento crítico (5V) – duplica “Hacinamiento crítico” IPM.

6. Trabajo infantil / informalidad / dependencia – no construidos desde CNPV; ya en IPM.

7. Hogares con adultos 60+ – dirección pendiente; correlación negativa con IPM.

8.9 Indicadores reservados para validación

- **IPM Municipal (agregado):** 15 privaciones ponderadas. No entra en la matriz candidata. Se reserva para un contraste externo posterior, interpretado con cautela por el solapamiento conceptual entre algunas privaciones y variables censales. No se presenta aquí una validación empírica del índice.

- **IPM por dominio (Cabeceras, Centros poblados y Rural):** Solo para análisis de brechas urbano-rural futuro.

8.10 Especificación técnica

La especificación vigente de las 17 definiciones operativas (fuente, cuadro, numerador, denominador, población de referencia, dirección esperada, propuesta de inclusión, notas) está en `resultados/base_trabajo/es`
Este archivo es la **fuente única de verdad** para la construcción de indicadores y debe ser aprobado/modificado por el autor antes de ejecutar PCA definitivo.

9 Control de calidad de los indicadores

9.1 Validaciones estructurales

El script `R/01_verificar_consolidados.R` ejecuta validaciones estructurales sobre las tablas intermedias (`datos/intermedio/`) y genera `resultados/verificacion_consolidados/validaciones.csv`. Todos los controles reportan **cero violaciones** en la ejecución registrada (13/10/2026).

9.2 Consistencia de conteos

La auditoría de conteos (`auditoria_conteos.csv`) verifica por cada variable de conteo:

- Valores disponibles (no NA).

Cuadro 9: *Validaciones estructurales clave (extracto de* `validaciones.csv`*)*

Validación	Concepto	N evaluado	N violaciones	Estado
Llave/prefijo contexto_1PM	Unicidad y formato llave municipal	80.909	0	PASS
Llave/prefijo contexto_1V	Unicidad y formato llave municipal	4.276	0	PASS
Llave/prefijo hogares_1HM_2HM	Unicidad y formato llave municipal	4.488	0	PASS
Llave/prefijo persona_demo_17PM	Unicidad y formato llave municipal	12.828	0	PASS
Llave/prefijo persona_social_5PM	Unicidad y formato llave municipal	12.828	0	PASS
Llave/prefijo viviendas_6V	Unicidad y formato llave municipal	6.652	0	PASS
Llave/prefijo viviendas_8V	Unicidad y formato llave municipal	4.276	0	PASS
Llave/prefijo viviendas_10V	Unicidad y formato llave municipal	4.276	0	PASS
Llave/prefijo ipm_municipal_ancho	Unicidad de códigos territoriales	1.122	0	PASS
Suma grupos edad = total	Consistencia 1PM	4.276	0	PASS
Hombre + mujer = total 1PM	Consistencia sexo	81.244	0	PASS
Suma población municipal = control nacional	Control nacional 1PM	1	0	PASS
MD5 insumos sin cambios	Integridad archivos entrada	11	0	PASS

- Valores faltantes (NA).
- Valores negativos (deben ser 0).
- Valores no enteros (deben ser 0, son conteos).

Resultados: **1.037.032 conteos evaluados, 0 valores negativos, 0 valores no enteros** (validaciones "Valores negativos en conteos" y "Valores no enteros en conteos": PASS).

9.3 Rangos

Todos los indicadores construidos como proporciones se validan en el rango $[0, 1]$:

- `actividad_desocupacion_incapacidad_hogar`: 1.122 unidades territoriales, 0 violaciones.
- `sin_energia_electrica`: 1.122 unidades territoriales, 0 violaciones.
- `sin_gas_red_publica`: 1.122 unidades territoriales, 0 violaciones.
- `sin_recoleccion_basuras`: 1.122 unidades territoriales, 0 violaciones.
- `sin_internet`: 1.122 unidades territoriales, 0 violaciones.
- `hogares_con_menores15`: 1.122 unidades territoriales, 0 violaciones.
- `estrato_1_2`: 1.122 unidades territoriales, 0 violaciones.

El IPM Municipal se valida en rango $[0, 100]$: 21.318 valores evaluados, 0 violaciones.

9.4 Valores imposibles

- **Conteos negativos:** 0 (validado).
- **Conteos no enteros:** 0 (validado).
- **Proporciones** < 0 **o** > 1**:** 0 (validado).
- **IPM fuera de** $[0, 100]$**:** 0 (validado).

9.5 Duplicados

- **Llaves del universo 2018 únicas:** 1.122 códigos territoriales, 0 duplicados (validación "Llaves universo 2018 únicas": PASS).
- **IPM Municipal = IPM (columna duplicada):** 1.122 códigos territoriales, 0 diferencias $> 10^{-10}$ (validación PASS). Se conserva una sola columna.

9.6 Cobertura territorial

Cuadro 10: *Cobertura territorial y calidad por fuente*

Fuente/Variable	Universo	Cobertura completa	Hallazgos
CNPV 2018 (todos los cuadros)	1.122 unidades territoriales	1.122 (100 %)	20 sin cabecera, 192 sin centro poblado
IPM 2018 Municipal	1.122 unidades territoriales	1.122 (100 %)	20 NA en Cabeceras (coinciden con sin cabecera)
IPM 15 privaciones	1.122×15 unidades	100 %	Sin NA fuera de Cabeceras
DIVIPOLA 20260917	$\approx$1.122	1.122 coinciden	Diferencias por cambios admin. recientes

9.7 Integridad de fuentes

- **Hashes MD5:** `md5_insumos_antes.csv` y `md5_insumos_despues.csv` confirman que los 11 archivos de entrada monitoreados **no cambiaron** durante la ejecución del pipeline.
- **Archivos de solo lectura:** Los CSV en `datos/intermedio/` se tratan como entradas de solo lectura; sus hashes se verifican antes y después.
- **Tolerancias numéricas:** Configuradas en `R/00_config.R` (`tolerancia_suma = 1e-8`, `tolerancia_ipm = 1e-10`, `tolerancia_auditoria = 1e-10`).

9.8 Resumen de hallazgos de control

El archivo `resumen_hallazgos.csv` consolida las cifras de control:

- Universo CNPV/IPM: 1.122 códigos territoriales (PASS).
- Combinaciones edad ausentes: 335 (119 municipios) – ausencias estructurales.
- Área Centro poblado: 299 municipios la tienen.
- Área Rural disperso: 25 municipios la tienen.
- Área Cabecera: 6 municipios con incidencias (ver detalle).
- Área Total: 5 municipios con incidencias.
- Edad 85+: 89 ausencias; 80-84: 62; 75-79: 33.
- 18 municipios ANM DIVIPOLA sin cabecera (población 26.569).
- Cobertura baja 5PM / pob_10mas: 28 municipios ($< 0,9$).
- Cobertura baja menores15 HOGARES: 26 municipios ($< 0,9$).
- Cobertura baja 60+ HOGARES: 20 municipios ($< 0,95$).
- Ítems NR > 5 %: 83 municipios; > 10 %: 37; > 20 %: 7 (excluye `no_tiene_estrato`).
- 20 NA IPM Cabeceras = 20 municipios sin cabecera (PASS).

Todos los controles programados están en estado **PASS**. La refactorización del pipeline (octubre 2026) regeneró los 34 CSV previos de `datos/trabajo/` y `resultados/base_trabajo/` **sin diferencias byte a byte** respecto de la línea base (ver `docs/calidad/Refactorizacion_Pipeline_Indicadores` y `R/tests/test_pipeline_indicadores.R`).

10 Diagnóstico estadístico preliminar

10.1 Estadística descriptiva disponible

El script `R/03_auditoria_indicadores.R` genera diagnósticos estadísticos preliminares sobre la matriz de indicadores candidatos (7 indicadores, base total y base válida). Los resultados se almacenan en `resultados/auditoria_estadistica/` y `resultados/base_trabajo/`.

Nota: $n = 1{,}122$ en todos los indicadores. Estadísticos de `resultados/base_trabajo/estadisticos_indicadores.` DE calculada como raíz cuadrada de la varianza en `varianza_indicadores.csv`. P1–P99 resume el 98 % central y no sustituye el rango completo. Los valores son descriptivos de la base total, no estimaciones poblacionales con error muestral.

Cuadro 11: *Estadísticos descriptivos por indicador (matriz base total) – extracto de* `estadisticos_indicadores.csv`

Indicador	Mediana	Media	DE	P1–P99	Asimetría
actividad_desocupacion_incapacidad_hogar	0,366	0,377	0,083	0,203–0,651	1,148
sin_energia_electrica	0,033	0,089	0,155	0,002–0,859	3,368
sin_gas_red_publica	0,713	0,671	0,273	0,083–1,000	−0, 486
sin_recoleccion_basuras	0,506	0,490	0,255	0,015–0,988	−0, 102
sin_internet	0,920	0,869	0,141	0,328–0,989	−2, 305
hogares_con_menores15	0,451	0,460	0,094	0,276–0,699	0,382
estrato_1_2	0,901	0,837	0,184	0,048–0,988	−2, 374

10.2 Variabilidad

El archivo `varianza_indicadores.csv` reporta la varianza de cada indicador y señala variables con **varianza casi nula** (umbral configurable en `R/00_config.R`: `varianza_casi_nula = 1e-8`). Una varianza muy baja indica escasa discriminación entre municipios y posible exclusión de la matriz PCA.

10.3 Correlaciones preliminares

- `correlaciones_pares.csv`: Correlación de Pearson para cada par de los 7 indicadores propuestos (21 pares).
- `pares_correlacion_ge_090.csv`: Pares con $|r| \geq 0,90$ – **vacío** en la ejecución registrada (ningún par alcanza el umbral).
- `pares_correlacion_ge_095.csv`: Pares con $|r| \geq 0,95$ – **vacío**.

La ausencia de pares por encima del umbral descriptivo $|r| \geq 0,90$ indica que no se detectó colinealidad bivariada extrema; no descarta redundancia conceptual ni patrones multivariados. Cuatro de los siete candidatos describen servicios y conectividad, por lo que el componente podría reflejar en gran medida ese bloque. Debe evaluarse el equilibrio entre dominios antes de construir una puntuación compuesta.

10.4 Outliers

- Detección mediante estandarización (z-score) usando `parametros_estandarizacion.csv` (media y DE por indicador).
- Umbral: $|z| > 4$ (configurable en `R/00_config.R`: `z_outlier = 4.0`).

- Resultado: **32 municipios** presentan al menos un indicador con $|z| > 4$. Ver `outliers_z_mayor_4.csv`.
- **No se eliminan automáticamente.** Estos municipios deben revisarse contra las fuentes originales y el contexto territorial antes de cualquier decisión de winsorización o exclusión.

10.5 Diagnósticos de adecuación multivariada

El archivo `diagnosticos_aptitud.csv` reporta para la matriz base total:

Cuadro 12: *Diagnósticos globales de aptitud para PCA (matriz base total, 7 indicadores)*

Diagnóstico	Valor	Interpretación
KMO global	0,642	Diagnóstico heurístico intermedio; no es criterio único de aprobación
Test de Bartlett	$\chi^2 = 4664,873$, gl=21, $p < 0,001$	Rechaza matriz identidad; con $n = 1,122$ puede detectar asociaciones pequeñas
Determinante de la matriz de correlación	0,0154	Describe la matriz; por sí solo no demuestra una solución adecuada

10.6 Medida de Adecuación Muestral Individual (MSA por indicador)

El archivo `kmo_por_indicador.csv` reporta el MSA (KMO individual) para cada uno de los 7 indicadores:

- Seis indicadores tienen MSA entre 0,554 y 0,882; estos valores son diagnósticos y no sustituyen la revisión conceptual ni de cargas/comunalidades.
- **Alerta:** `estrato_1_2` tiene MSA = $0,414$. Su inclusión debilita la adecuación compartida y debe reconsiderarse junto con su problema de cobertura conceptual en territorios rurales.
- Ver `Resumen_General.md`, punto 40: "el MSA de estrato 1–2 es bajo ($\approx 0,414$)".

10.7 Sensibilidad a No Respuesta (NR)

La comparación entre **base total** (incluye NR en denominador) y **base válida** (excluye NR) muestra:

- `sensibilidad_nr.csv`: Resumen por indicador de diferencias absolutas y relativas.
- `sensibilidad_nr_municipio.csv`: Diferencias municipio a municipio con marcas de sensibilidad (umbrales en `R/00_config.R`: `delta_absoluta = 0.02`, `delta_relativa = 0.10`).
- Las diferencias municipales y agregadas **deben revisarse** antes de fijar la base analítica principal (Decisión vigente en `Resumen_General.md`, punto 27 y punto 59).

10.8 Estado de la auditoría estadística

Importante: Los diagnósticos reportados son **preliminares** y se refieren principalmente a la matriz base total. La **auditoría estadística integral está pendiente** y debe incluir, como mínimo:

1. Comparación sistemática de correlaciones, KMO y MSA entre **matriz base total** y **matriz base válida**.
2. Evaluación de transformaciones para variables asimétricas (ej. `sin_internet`, `sin_gas` con techo alto).
3. Análisis de componentes principales *exploratorio* (no definitivo) para inspeccionar eigenvalues, scree plot, cargas, varianza explicada.
4. *Parallel analysis* para criterio de retención de componentes.
5. Evaluación de estabilidad: bootstrap, jackknife, o análisis de sensibilidad a outliers (32 municipios con $|z| > 4$).
6. Decisión fundamentada sobre inclusión/exclusión de `estrato_1_2` (MSA bajo) y `hogares_con_menores15` (cobertura baja en 26 municipios).
7. Definición de dirección de `hogares_con_adultos_60mas` (actualmente fuera de matriz candidata).
8. Documentación de criterios de retención de componentes (eigenvalue > 1, scree, parallel analysis, varianza explicada acumulada $> 60 - 70\,\%$).

No se ha ejecutado un PCA definitivo. Los diagnósticos actuales **no deciden** si el PCA es apropiado; son insumos para la decisión metodológica que debe tomar el autor (ver `Resumen_General.md`, punto 40: "La auditoría estadística recomienda no ejecutar aún un PCA definitivo").

11 Preparación para PCA

11.1 Objetivo del PCA

El Análisis de Componentes Principales (PCA) tendrá como objetivo:

1. **Reducir la dimensionalidad** de la matriz de indicadores socioeconómicos municipales (inicialmente 7 candidatos provisionales) a un número pequeño de componentes no correlacionados.

2. **Describir la covariación** entre los indicadores, sin asumir de antemano que existe un factor latente único.

3. Evaluar si uno o más componentes ofrecen una reducción interpretable y estable.

4. Solo si la evidencia conceptual y empírica lo respalda, considerar los scores como una medida sintética; no se presupone que el PC1 sea un IVS válido.

11.2 Justificación metodológica

- PCA resume varianza; no determina qué dimensiones son normativamente relevantes ni sustituye la selección teórica de indicadores.
- Los pesos derivados de los componentes reflejan la estructura de varianza de esta matriz y universo; no son pesos neutrales ni automáticamente superiores a otras reglas.
- Un score del PC1 solo podría interpretarse como síntesis territorial si la orientación, cobertura conceptual, cargas y estabilidad resultan defendibles.
- La solución es reproducible si se documentan la matriz de entrada, el tratamiento de faltantes, el escalado, la extracción, la retención y los scores.

Advertencia: No hay un umbral único que apruebe o descarte PCA. La decisión debe combinar propósito, matriz de correlaciones, indicadores individuales, interpretación, sensibilidad y universo observado. KMO/MSA y Bartlett aportan diagnósticos, no una regla mecánica.

11.3 Variables candidatas

La **matriz candidata provisional** (base total y base válida) contiene 7 indicadores:

1. `actividad_desocupacion_incapacidad_hogar` – Combina búsqueda de trabajo, oficios del hogar, incapacidad permanente y otra situación entre personas de 10+; no equivale a tasa de desempleo ni a una medida homogénea de inactividad.
2. `sin_energia_electrica` – Viviendas sin energía.
3. `sin_gas_red_publica` – Viviendas sin gas natural.
4. `sin_recoleccion_basuras` – Viviendas sin recolección de basuras.
5. `sin_internet` – Viviendas sin internet.

6. `hogares_con_menores15` – Composición demográfica del hogar; no es privación por sí sola.

7. `estrato_1_2` – Proporción de personas en estratos 1–2; la clasificación no cubre de forma uniforme el territorio rural y su MSA es bajo.

Estado: *Provisional*. La decisión final de inclusión corresponde al autor (ver `Resumen_General.md`, puntos 5, 30, 58). Deben aprobarse/modificarse concepto y denominadores de gas/internet, actividad, hogares con menores y estrato 1–2.

11.4 Criterios que deberán evaluarse

Antes de ejecutar PCA definitivo, se debe evaluar y documentar:

1. **Adecuación multivariada:** KMO global ($\geq 0,70$ deseable), MSA individual ($\geq 0,50$ c/u), Bartlett ($p < 0,05$).

2. **Selección final de variables:** Dirección de vulnerabilidad definida, colinealidad aceptable (VIF $< 5 - 10$), no redundancia con IPM (para validación externa no circular).

3. **Distribución de variables:** Asimetría, límites, concentración en techo/suelo y observaciones influyentes; cualquier transformación debe tener justificación sustantiva y conservar interpretabilidad.

4. **Correlaciones y MSA:** Matriz de correlaciones, KMO global e individual, determinante.

5. **Eigenvalues y varianza explicada:** Eigenvalues > 1 (Kaiser), scree plot, *parallel analysis* (Horn, 1965) para retención objetiva.

6. **Estructura de componentes:** Cargas, varianza explicada, interpretación y sensibilidad; evitar llamarla estructura factorial si solo se estima PCA.

7. **Signo del componente:** Orientar PC1 para que **score alto = mayor vulnerabilidad** (el signo es arbitrario en PCA).

8. **Estabilidad:** Sensibilidad a outliers (32 municipios $|z| > 4$), bootstrap/jackknife si procede, comparación base total vs. base válida.

9. **Scores municipales:** Distribución, rangos, percentiles, mapa preliminar.

11.5 Procedimientos pendientes

1. **Aprobar lista definitiva de indicadores** (concepto, denominador, dirección, tratamiento NR).
2. **Confirmar umbrales de cobertura** configurados en `R/00_config.R` (parámetros operativos editables, no decisiones universales).
3. **Comparar sensibilidad NR** entre matriz base total y base válida (correlaciones, KMO, MSA) – `Resumen_General.md`, punto 59.
4. **Revisar 32 municipios con** $|z| > 4$ contra fuentes y contexto territorial – no eliminar automáticamente.
5. **Resolver decisión sobre `estrato_1_2`** (MSA $\approx 0,414$): excluir, transformar, o mantener con justificación.
6. **Revisar el peso implícito de dominios**: cuatro de siete variables candidatas miden servicios/conectividad, por lo que una componente puede reflejar ese bloque más que un constructo equilibrado.
7. **Definir el uso de variables demográficas**: hogares con menores y adultos mayores describen composición, no una dirección universal de privación.
8. **Ejecutar PCA exploratorio**, inspeccionar eigenvalues, scree, parallel analysis, cargas.
9. **Seleccionar componentes** con criterio documentado y justificado.
10. **Interpretar cargas** y evaluar si la síntesis admite una denominación sustantiva acotada.
11. Solo si procede, **construir una medida compuesta** con scores orientados y evaluar su estabilidad; conservar el nombre IVS como provisional hasta justificar el constructo.
12. **Validar externamente con IPM Municipal** (correlación, concordancia de rankings, análisis de residuos).

11.6 Precauciones frente a circularidad con IPM

- El **IPM Municipal (agregado) se reserva exclusivamente como validación externa**. No entra al PCA.
- Indicadores que **replican directamente privaciones del IPM** (material paredes, acueducto, alcantarillado, hacinamiento, analfabetismo, rezago, inasistencia, barreras primera infancia, trabajo

infantil, informalidad, dependencia, barreras salud, aseguramiento, pisos) se han **excluido de la matriz candidata PCA** o se marcan como `DESCRIPCIÓN` en `especificacion_indicadores.csv`.

- Si un indicador censal (ej. 6V: material paredes) duplica una privación IPM, la decisión documentada es: **usar uno solo** (preferiblemente el del IPM por ser oficial validado, y usar el censal solo para validar consistencia). Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 104.
- La validación externa consistirá en correlacionar el IVS (PC1 de indicadores *no IPM*) con el IPM Municipal. Una correlación alta (en valor absoluto) apoya la validez convergente; una correlación baja exige revisión teórica del IVS.

11.7 Configuración técnica

- `R/00_config.R`: `ejecutar_pca = FALSE`, `ejecutar_bootstrap = FALSE` (bandas de seguridad).
- `R/03_auditoria_indicadores.R`: Genera diagnósticos previos (descriptivos, correlaciones, KMO, Bartlett, outliers, estandarización) **sin estimar componentes**.
- `R/funciones/auditoria_estadistica.R`: Funciones modulares para diagnósticos multivariados.
- Cuando se autorice: `ejecutar_pca = TRUE` activará la estimación (por implementar/extender en pipeline).

12 Reproducibilidad y arquitectura computacional

12.1 Organización del repositorio

La estructura del repositorio es la siguiente:

`Desarrollo_Social_Economico_Agent/` Raíz del proyecto

`datos/ intermedio/` Tablas tidy de auditoría estructural (solo lectura)

`trabajo/` Denominadores, indicadores, matrices candidatas

`*.xlsx` Fuentes originales (CNPV, IPM, DIVIPOLA) – no versionados

`docs/ calidad/ auditorias/` Reportes de verificación y auditoría

`limpieza/` Reportes de limpieza

refactorizacion/ Doc. de refactorización pipeline

diccionario/ Decisiones variables, diccionarios por fuente

metodologia/ Documentos metodológicos

handoff/ Resúmenes de transferencia

informe1_metodologico/ ESTE INFORME

R/ 00_config.R Parámetros editables (rutas, umbrales, banderas)

01_verificar_consolidados.R Verificación estructural, universo maestro

02_base_final_indicadores.R Construcción indicadores, matrices, diagnósticos

03_auditoria_indicadores.R Auditoría estadística preliminar

funciones/ io.R Lectura/escritura, conversión, hashes MD5

validacion.R Controles estructurales y de calidad

auditoria_estadistica.R Diagnósticos multivariados (KMO, Bartlett, etc.)

tests/ test_pipeline_indicadores.R Prueba de integridad byte-a-byte

resultados/ verificacion_consolidados/ Inventarios, validaciones, especificación

base_trabajo/ 25 CSV: indicadores, calidad, sensibilidad, hashes

auditoria_estadistica/ Diagnósticos multivariados

OLVIDADOS/ 17 scripts históricos archivados

.obsidian/ Bóveda Obsidian (notas metodológicas enlazadas)

main.tex Este informe

12.2 Scripts principales

Cuadro 13: *Scripts principales del pipeline activo*

Script	Función	Salidas clave
`R/00_config.R`	Parámetros globales: rutas, umbrales NR, cobertura, outliers, KMO, banderas PCA/bootstrap	Configuración centralizada
`R/01_verificar_consolidados.R`	Lee Excel como texto, reconstruye llaves 5 chars, genera inventario, mapa llaves, cobertura, discrepancias, universo maestro, tablas tidy	`datos/intermedio/*.csv`, `resultados/verificacion_consolidados/`
`R/02_base_final_indicadores.R`	Crea denominadores, indicadores (base total/válida), matrices candidatas, diagnósticos, sensibilidad NR, hashes	`datos/trabajo/`, `resultados/base_trabajo/`
`R/03_auditoria_indicadores.R`	Descriptivos, correlaciones, KMO global/individual, Bartlett, outliers, estandarización	`resultados/auditoria_estadistica/`
`R/tests/test_pipeline_indicadores.R`	Prueba de integridad: regenera 34 CSV y compara byte-a-byte con línea base	PASS/FAIL

12.3 Flujo de procesamiento

1. **Configuración:** `R/00_config.R` define todas las rutas, umbrales y banderas.

2. **Verificación consolidados:** `R/01_verificar_consolidados.R`

   a) Lee los 4 libros Excel CNPV hoja a hoja (como texto, sin chunking real).

   b) Reconstruye `codigo_municipio` (5 chars) y valida contra universo maestro.

   c) Genera tablas intermedias `datos/intermedio/` (contexto, hogares, personas, viviendas, IPM).

   d) Produce inventario, mapa de llaves, cobertura, discrepancias, controles.

   e) Documenta en `VERIFICACION_CONSOLIDADOS.md`.

3. **Construcción indicadores:** `R/02_base_final_indicadores.R`

   a) Lee tablas intermedias (solo lectura, verifica MD5).

   b) Calcula denominadores desde 1PM y 1V_MPIO.

   c) Construye indicadores a partir de la especificación vigente; la auditoría registra 17 definiciones y siete variables candidatas provisionales.

   d) Genera versiones base total y base válida para indicadores con NR.

   e) Produce matrices candidatas, `especificacion_indicadores.csv`, controles, sensibilidad, *flags*, hashes.

4. **Auditoría estadística:** `R/03_auditoria_indicadores.R`

   a) Lee matrices candidatas y calcula descriptivos, correlaciones, KMO, Bartlett, outliers, estandarización.

   b) **No ejecuta PCA ni bootstrap** (`ejecutar_pca = FALSE`).

5. **Prueba de integridad:** `R/tests/test_pipeline_indicadores.R` regenera todo y compara MD5.

12.4 Trazabilidad

Cada decisión metodológica clave tiene su archivo de evidencia:

Cuadro 14: *Trazabilidad decisiones – archivo evidencia*

Decisión	Archivo evidencia
Selección de variables	`docs/diccionario/decisiones_variables_IVS_CNPV2018.csv`
Especificación indicadores	`resultados/base_trabajo/especificacion_indicadores.csv`
Universo municipal (1.122)	`datos/intermedio/universo_municipal_maestro.csv`
Validaciones estructurales	`resultados/verificacion_consolidados/validaciones.csv`
Tratamiento NR (base total/válida)	`R/00_config.R`, `sensibilidad_nr.csv`
Ausencias estructurales	`resultados/base_trabajo/ausencias_estructurales_1PM.csv`
Municipios sin cabecera	`resultados/base_trabajo/municipios_sin_cabecera.csv`
Crosswalk territorial SECOP	`resultados/base_trabajo/crosswalk_enlace.csv`
Integridad insumos (MD5)	`resultados/base_trabajo/md5_insumos_antes/despues.csv`
Diagnósticos aptitud PCA	`resultados/base_trabajo/diagnosticos_aptitud.csv`, `kmo_por_indicador.csv`

12.5 Control de integridad

- **Hashes MD5:** 11 archivos de entrada monitoreados; hashes antes y después de cada ejecución confirman **sin modificaciones**.
- **Tolerancias numéricas:** `tolerancia_suma = 1e-8`, `tolerancia_ipm = 1e-10`, `tolerancia_auditoria = 1e-10` (en `R/00_config.R`).
- **Controles de consistencia:** Suma grupos edad = total; Hombre + Mujer = Total; Sumas municipales = Control nacional; 17PM total = suma categorías; 5PM total = suma categorías; 8V servicios = suma categorías; 10V BU = suma BV:CD.
- **Refactorización verificada:** Octubre 2026 regeneró 34 CSV idénticos byte-a-byte a la línea base (`docs/calidad/Refactorizacion_Pipeline_Indicadores`).

12.6 Reproducibilidad

Para reproducir el estado actual del pipeline desde la raíz del repositorio:

```
# 1. Verificación consolidados (genera datos/intermedio/, resultados/verificacion_consolidac
Rscript R/01_verificar_consolidados.R

# 2. Construcción indicadores y diagnósticos base (genera datos/trabajo/, resultados/base_tr
Rscript R/02_base_final_indicadores.R

# 3. Auditoría estadística preliminar (genera resultados/auditoria_estadistica/)
Rscript R/03_auditoria_indicadores.R
```

```
# 4. Prueba de integridad (opcional, verifica regeneración byte-a-byte)
Rscript R/tests/test_pipeline_indicadores.R
```

- Requiere R ≥ 4.0 y paquetes: `readxl`, `readr`, `dplyr`, `tidyr`, `stringr`, `purrr`, `janitor`, `tibble`, `lubridate`, `data.table`.
- No hay `renv.lock` ni `DESCRIPTION` versionado; versiones de paquetes no fijadas (deuda técnica documentada).
- Los archivos Excel fuente en `datos/` **no están versionados** (ver `.gitignore`); deben obtenerse del DANE.
- La bóveda Obsidian (`.obsidian/`) contiene notas metodológicas enlazadas (`Inicio_Proyecto.md`, `Final_Base.md`, `VERIFICACION_CONSOLIDADOS.md`, etc.) que documentan decisiones y vinculan a archivos reproducibles.

13 Limitaciones actuales

El presente informe documenta el estado del proyecto al 13 de octubre de 2026. Las siguientes limitaciones son **parte inherente del estado actual de la investigación**, no fallas del proyecto:

13.1 Auditoría estadística integral pendiente

Los diagnósticos reportados en el Capítulo 10 (KMO $\approx 0,642$, Bartlett significativo, MSA estrato 1–2 $\approx 0,414$, 32 municipios con $|z| > 4$, sensibilidad NR) son **preliminares**. Falta:

- Comparación sistemática base total vs. base válida (correlaciones, KMO, MSA).
- Evaluación de transformaciones para asimetría/curtosis (ej. techo en gas, internet).
- *Parallel analysis* para retención de componentes.
- Análisis de estabilidad (bootstrap, sensibilidad a outliers).
- Decisión fundamentada sobre variables problemáticas (estrato 1–2, hogares con menores, dirección adultos 60+).

No se ha aprobado la matriz para PCA definitivo.

13.2 PCA no ejecutado

- No se han estimado componentes principales.
- No se han inspeccionado eigenvalues, scree plot, cargas, varianza explicada.
- No se ha evaluado interpretabilidad del PC1 como "vulnerabilidad general".
- No se ha definido criterio de retención (Kaiser, scree, parallel analysis, varianza acumulada).

13.3 IVS (Índice de Vulnerabilidad Socioeconómica) no construido

- No existe un índice sintético validado.
- No se han calculado scores municipales de vulnerabilidad.
- No se ha orientado el signo (score alto = mayor vulnerabilidad).
- No se ha evaluado estabilidad del ranking municipal.

13.4 Validación externa con IPM pendiente

- El IPM Municipal agregado está reservado como criterio de validación.
- No se ha correlacionado IVS con IPM (evitando circularidad por exclusión de indicadores redundantes).
- No se ha analizado concordancia de rankings, análisis de residuos, ni sensibilidad de la validación.

13.5 Integración SECOP II pendiente

- No se han obtenido ni integrado datos de SECOP II.
- No se ha definido ventana temporal definitiva (exploratoria 2015–2025).
- No se han construido indicadores municipales-año de contratación (valor, número, concentración, sectores).
- No se ha resuelto el *crosswalk* territorial definitivo (códigos 94663, 27493 pendientes de verificación DANE/IGAC).
- No se ha definido denominador para tasas de contratación (PIB municipal, población, presupuesto, referencia nacional).

13.6 Análisis de asociación/correspondencia pendiente

- Condicionado a la existencia de IVS validado y datos SECOP II integrados.
- Requiere definición de hipótesis nulas, modelos (correlación, regresión, panel), y prueba de focalización.

13.7 Análisis espacial condicionado

- Solo procederá si el diagnóstico de asociación lo justifica.
- Requiere: matriz de pesos espaciales (contigüidad, distancia), test de Moran's I, modelos espaciales (SAR, SEM, SDM), detección de clústeres (LISA).
- Condicionado a resultados de etapas previas.

13.8 Otras limitaciones técnicas

- **Entorno R no versionado:** No hay `renv.lock` ni `DESCRIPTION`; versiones de paquetes no fijadas.
- **Fuentes Excel no versionadas:** Archivos en `datos/` excluidos por `.gitignore`; reproducibilidad requiere acceso a fuentes originales DANE.
- **Cobertura baja en algunos indicadores:** 28 municipios con cobertura 5PM/pob_10mas $< 0,9$; 26 con menores15 HOGARES $< 0,9$; 20 con 60+ HOGARES $< 0,95$. Umbrales son parámetros operativos editables en `R/00_config.R`, requieren aprobación metodológica.
- **Verificación pendiente 17PM:** El cuadro 17PM está descrito en el índice DANE como "asistencia escolar" (igual que 18PM), pero 17PD trata "nivel educativo". Si es asistencia, duplica Inasistencia IPM y debe reconsiderarse. Ver `decisiones_variables_IVS_CNPV2018.csv`, fila 37.
- **Deuda de modularización:** La construcción principal de denominadores e indicadores permanece en gran parte dentro de `R/02_base_final_indicadores.R` (pendiente extraer a `R/funciones/`).

Cuadro 15: *Estado del proyecto por etapa (corte 13/10/2026)*

Etapa	Estado	Evidencia principal	Próximo paso
Selección de fuentes	**Completado**	`CUADROS_MUNICIPALES_UNIDOS.xlsx`, `IPM_2018_organizado_region.xlsx`, `DIVIPOLA`	–
Selección de variables	**Provisional** (7 PCA + 7 descripción)	`decisiones_variables_IVS_CNPV2018.csv`, `especificacion_indicadores.csv`	Aprobar/modificar lista candidata, confirmar direcciones
Integración territorial	**Completado** (verificación llaves)	`validaciones.csv`, `universo_municipal_maestro.csv`	Resolver 27493 y 94663 para crosswalk SECOP
Tratamiento de faltantes	**Documentado** (sin imputación, dualidad base total/válida)	`R/00_config.R`, `sensibilidad_nr.csv`, `ausencias_estructurales_1PM.csv`	Decidir base analítica principal usando sensibilidad
Construcción indicadores	**Completado** (base total y base válida)	`datos/trabajo/`, `resultados/base_trabajo/`	Confirmar fórmulas, denominadores, dirección
Auditoría estadística	**Pendiente** (diagnósticos preliminares disponibles)	`resultados/auditoria_estadistica/`, `diagnosticos_aptitud.csv`, `kmo_por_indicador.csv`	Ejecutar auditoría integral; decidir sobre PCA
PCA	**Pendiente**	–	Evaluar adecuación, seleccionar componentes, interpretar cargas
IVS	**Pendiente**	–	Construir índice sintético, evaluar estabilidad, orientar signo
Validación IPM	**Pendiente**	–	Correlacionar IVS con IPM Municipal (evitando circularidad)
SECOP II	**Pendiente**	–	Obtener datos, definir período/denominador, integrar municipal-año
Asociación	**Pendiente**	–	Analizar correspondencia IVS vs. SECOP II
Espacial	**Pendiente** (condicionado)	–	Si asociación lo justifica: autocorrelación, modelos espaciales, clústeres

14 Estado del proyecto y etapas siguientes

14.1 Tabla de estado general

14.2 Decisiones vigentes registradas (extracto de `Resumen_General.md`)

1. Universo: **1.122 códigos municipales CNPV/IPM 2018**, sin fusiones ni exclusiones en datos 2018.
2. Llave de unión: `codigo_municipio` como texto de 5 caracteres; nunca nombre municipal.
3. Sin imputación estadística: ausencias estructurales → ceros + flags; áreas inexistentes → no crear filas.
4. Cocientes 0/0 → NA + `flag_indice_indefinido`; 20 NA IPM Cabeceras → NA estructural.
5. NR: base total (incluye NR) y base válida (excluye NR) como escenarios de sensibilidad; `no_tiene_estrato` separado.
6. IPM agregado: **validación externa**; no entra al PCA. Privaciones que replican IPM → fuera de matriz candidata.
7. 17PM total = población 5+ de 1PM; `pob_10mas` desde 1PM; 17PM no permite filtrar 10+.
8. Decisiones de inclusión: **provisionales** (7 indicadores matriz candidata).

14.3 Resultados comprobados que orientan el siguiente paso

- Universo 1.122 códigos territoriales (incluye ANM); validaciones de llaves, prefijos, sumas y rangos: **cero violaciones**.
- 20 municipios sin cabecera (coinciden con 20 NA IPM Cabeceras); 192 sin centro poblado.
- 335 ausencias estructurales edad (119 municipios); 1.202 ausencias tipo vivienda.
- Códigos 94663 y 27493: asuntos territoriales pendientes, documentados para crosswalk SECOP.

- Matriz candidata base total: KMO $\approx 0,642$; Bartlett $\chi^2 \approx 4664,873$, gl=21, $p < 0,001$; determinante $\approx 0,0154$; sin pares $|r| \geq 0,90$; 32 municipios con $|z| > 4$.
- Sensibilidad NR: diferencias municipales y agregadas documentadas; requieren revisión antes de fijar base analítica.
- **Recomendación auditoría:** no ejecutar PCA definitivo aún (KMO moderado, MSA estrato 1–2 bajo, actividad mezcla estados, falta comparar base total vs. válida).
- Refactorización pipeline: 34 CSV regenerados idénticos byte-a-byte; prueba `test_pipeline_indicadores.R` PASS.

14.4 Pendientes y decisiones del autor (próximas acciones)

1. Revisar concepto y denominadores de gas/internet, actividad, hogares con menores, estrato 1–2; aprobar o modificar lista candidata.
2. Comparar sensibilidad de correlaciones/KMO entre matriz base total y base válida; revisar 32 códigos extremos con fuentes; no eliminarlos automáticamente.
3. Confirmar umbrales de cobertura en `R/00_config.R` (parámetros operativos editables).
4. Resolver para enlace SECOP el tratamiento de 27493 y 94663, con verificación territorial externa; mantener intactos códigos originales CNPV/IPM.
5. Decidir si se mantienen escenarios base total/base válida NR o cuál será principal, usando sensibilidad documentada.
6. Conseguir/integrar datos SECOP II, definir período, denominador y unidad temporal; pipeline no implementado.
7. Completar extracción de bloques de denominadores y cálculo de indicadores de `R/02_base_final_indicadores.` antes de extender pipeline.
8. **Solo después de lo anterior:** ejecutar y documentar PCA, selección de componentes, estabilidad/bootstrap si corresponde, validación externa con IPM. **El IVS todavía no existe como producto validado.**

14.5 Arquitectura futura del proyecto

El informe está diseñado para crecer modularmente:

```
INFORME 1 (ESTE DOCUMENTO)
  Metodología y construcción de indicadores
            ↓
AUDITORÍA ESTADÍSTICA INTEGRAL
            ↓
PCA (exploratorio → definitivo)
            ↓
ÍNDICE SINTÉTICO / IVS (construcción + estabilidad)
            ↓
VALIDACIÓN EXTERNA CON IPM MUNICIPAL
            ↓
INTEGRACIÓN SECOP II (panel municipal-año)
            ↓
ANÁLISIS DE ASOCIACIÓN / CORRESPONDENCIA
            ↓
ANÁLISIS ESPACIAL (condicionado a resultados)
```

Cada etapa futura se añadirá como capítulo/sección sin reescribir la metodología ya consolidada en este Informe 1.

15 Conclusiones metodológicas

15.1 ¿Qué se ha construido hasta ahora?

1. **Universo territorial consolidado:** 1.122 códigos territoriales, incluidas áreas no municipalizadas con datos CNPV 2018 e IPM 2018, homologados por `codigo_municipio` (5 caracteres), validados con cero violaciones estructurales.

2. **Bases intermedias auditadas:** 9 tablas tidy en `datos/intermedio/` (contexto 1PM, 1V; hogares 1HM/2HM; personas demo 17PM; personas social 5PM; viviendas 6V, 8V, 10V; IPM municipal ancho), con integridad verificada por MD5.

3. **17 definiciones operativas de indicadores** construidos con fórmulas explícitas (numerador, denominador, población de referencia), en dos versiones para NR (base total / base válida), documentados en `especificacion_indicadores.csv`.

4. **7 indicadores candidatos provisionales para PCA:** desocupación/inactividad, sin energía, sin gas, sin recolección, sin internet, hogares con menores, estrato 1–2.

5. **7 indicadores de descripción/solapamiento IPM:** nivel educativo, material paredes, acueducto, alcantarillado, hacinamiento, trabajo infantil/informalidad/dependencia (vía IPM), hogares con adultos 60+ (dirección pendiente).

6. **Diagnósticos estadísticos preliminares:** descriptivos, correlaciones, KMO global ($\approx 0,642$), Bartlett ($p < 0,001$), MSA individual (estrato 1–2 $\approx 0,414$), outliers ($|z| > 4$ en 32 unidades territoriales), sensibilidad NR.

7. **Tratamiento territorial documentado:** 20 municipios sin cabecera, 192 sin centro poblado, códigos 94663/27493 con *crosswalk* para SECOP futuro, ausencias estructurales distinguibles de faltantes.

8. **Pipeline reproducible y modularizado parcialmente:** 4 scripts principales + funciones + prueba de integridad byte-a-byte.

15.2 ¿Qué decisiones metodológicas están consolidadas?

- Municipio como unidad de análisis; `codigo_municipio` (5 chars) como llave única.
- No imputación estadística; las ausencias estructurales se distinguen de los faltantes; NA para denominador cero y 0/0.
- Dualidad base total / base válida para NR como escenarios de sensibilidad (no decisión definitiva).
- `no_tiene_estrato` distinguido de NR genuino.
- IPM Municipal reservado como **validación externa**; exclusión de indicadores que replican privaciones IPM de la matriz PCA.
- 17PM total = población 5+ de 1PM; `pob_10mas` desde 1PM.
- Conflictos territoriales (94663, 27493, municipios sin cabecera, ANM) **no resueltos en datos 2018**; reservados para *crosswalk* SECOP.

- Controles de calidad: validaciones estructurales PASS, consistencia conteos PASS, rangos PASS, integridad MD5 PASS.

15.3 ¿Qué problemas fueron detectados y cómo fueron tratados?

Cuadro 16: *Problemas detectados y tratamiento*

Problema	Detección	Tratamiento adoptado
Municipios sin cabecera (20)	Validación IPM Cabeceras = NA	Conservados; NA estructural; documentados en `municipios_sin_cabecera.csv`
Código 94663 (Mapiripana)	Relación con 94343 (Barrancominas)	Documentado para crosswalk SECOP; no fusionado en 2018
Código 27493 (Nuevo Belén de Bajirá)	Conflicto histórico con 05480 Mutatá	Hipótesis 27615 Riosucio como padre; pendiente verificación DANE/IGAC
Ausencias estructurales edad/vivienda	335 + 1.202 combinaciones ausentes	Ceros estructurales + flags; no imputación
Cobertura baja 5PM / pob_10mas (28)	Validación umbral 0,9	Documentado; umbral editable en `R/00_config.R`
Cobertura baja menores15 HOGARES (26)	Validación umbral 0,9	Documentado; umbral editable
Cobertura baja 60+ HOGARES (20)	Validación umbral 0,95	Documentado; umbral editable
MSA estrato 1–2 bajo ($\approx 0,414$)	`kmo_por_indicador.csv`	Alerta documentada; decisión de inclusión pendiente
Dirección hogares con adultos 60+	Correlación negativa con IPM	Fuera de matriz candidata; decisión conceptual pendiente
Verificación 17PM (asistencia vs. nivel)	Índice DANE describe asistencia	Pendiente abrir hoja; si asistencia, duplica IPM
Sensibilidad NR	Diferencias base total vs. válida	Documentada en `sensibilidad_nr*.csv`; decisión pendiente

15.4 ¿Qué información queda lista para el análisis multivariado?

- Matriz candidata base total: `datos/trabajo/matriz_base_total.csv` (1.122×7).
- Matriz candidata base válida: `datos/trabajo/matriz_base_valida.csv` (1.122×7).
- Parámetros de estandarización: `resultados/base_trabajo/parametros_estandarizacion.csv`.
- Correlaciones pares: `resultados/base_trabajo/correlaciones_pares.csv`.
- Diagnósticos aptitud: `resultados/base_trabajo/diagnosticos_aptitud.csv`, `kmo_por_indicador.csv`.
- Outliers: `resultados/base_trabajo/outliers_z_mayor_4.csv` (32 unidades territoriales).
- Sensibilidad NR: `sensibilidad_nr.csv`, `sensibilidad_nr_municipio.csv`.
- Especificación completa de indicadores: `especificacion_indicadores.csv`.

Condición: La matriz debe ser **aprobada por el autor** tras revisar concepto, denominadores, dirección, cobertura y sensibilidad NR (puntos 58–59 de `Resumen_General.md`).

15.5 ¿Qué etapas faltan?

1. **Auditoría estadística integral** (comparar base total vs. válida, transformaciones, parallel analysis, estabilidad).
2. **Decisión final de variables** para PCA (aprobar 7 provisionales, resolver estrato 1–2, adultos 60+, 17PM).

3. **Ejecución de PCA** (eigenvalues, scree, parallel analysis, cargas, varianza explicada, interpretabilidad).

4. **Construcción del IVS** (scores PC1 orientados, evaluación de estabilidad/bootstrap).

5. **Validación externa con IPM Municipal** (correlación, rankings, residuos, sin circularidad).

6. **Integración SECOP II** (obtención, limpieza, panel municipal-año, *crosswalk* territorial).

7. **Análisis de asociación** IVS vs. SECOP II (correlación, modelos, focalización).

8. **Análisis espacial** (condicionado a resultados de asociación).

15.6 Cierre

Este Informe 1 establece una **base metodológica rigurosa, trazable y reproducible** para el análisis de la correspondencia entre contratación pública y vulnerabilidad socioeconómica municipal en Colombia. Las decisiones documentadas priorizan la transparencia sobre la premura: se distinguen claramente los hallazgos consolidados de las decisiones provisionales y de las etapas pendientes. El IVS **no existe aún**; su construcción requerirá completar la auditoría estadística, ejecutar y validar el PCA, y solo entonces proceder a la validación externa y al análisis sustantivo con SECOP II. La arquitectura modular del informe y del pipeline computacional permite incorporar cada etapa futura sin reescribir lo ya consolidado.

Referencias

Abdi, H. and Williams, L. J. (2010). Principal component analysis. *Wiley Interdisciplinary Reviews: Computational Statistics*, 2(4):433–459.

Alkire, S., Foster, J., Seth, S., Santos, M. E., Roche, J. M., and Ballon, P. (2011). *Multidimensional poverty measurement and analysis*. Oxford University Press.

Booysen, F. (2002). An overview and evaluation of composite indices of development. *Social Indicators Research*, 59(2):115–151.

DANE (2019). Metodología del Índice de pobreza multidimensional (ipm) para colombia. Technical report, Departamento Administrativo Nacional de Estadística, Bogotá, Colombia.

Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer, 2nd edition.

Kaztman, R. and Filgueira, C. H. (1999). Marco conceptual sobre activos, vulnerabilidad y estructuras de oportunidades. Technical Report LC/MVD/R.176/REV.1, Comisión Económica para América Latina y el Caribe, Montevideo.

Pizarro, R. (2001). La vulnerabilidad social y sus desafíos: una mirada desde américa latina. Technical Report 6, Comisión Económica para América Latina y el Caribe, Santiago.

Sen, A. (1999). *Development as freedom*. Oxford University Press.

Anexos

A Especificación vigente de indicadores

La especificación reproducible se mantiene en `resultados/base_trabajo/especificacion_indicadores.`
La auditoría estadística registra 17 definiciones operativas: siete variables de una matriz candidata provisional y otras variables descriptivas, contextuales o pendientes de revisión. La tabla resume únicamente las siete candidatas; su presencia no implica aprobación conceptual ni que se haya ejecutado el PCA.

Cuadro 17: *Variables de la matriz candidata y principales reservas conceptuales*

Variable	Medida observada	Reserva para interpretación
Actividad combinada	Proporción de población 10+ en categorías combinadas de actividad	Agrupa búsqueda de empleo, oficios del hogar, incapacidad permanente y otras categorías; no equivale a desempleo ni a una medida unidimensional de vulnerabilidad.
Sin energía eléctrica	Viviendas ocupadas sin energía eléctrica	Indicador de servicio básico; interpretar con contexto de oferta territorial.
Sin gas de red	Viviendas ocupadas sin gas de red pública	La disponibilidad depende de infraestructura y oferta local.
Sin recolección de basuras	Viviendas ocupadas sin recolección de basuras	La cobertura puede reflejar provisión del servicio y dispersión poblacional.
Sin internet	Viviendas ocupadas sin internet	Distribución próxima al techo en parte del universo; revisar capacidad discriminante y no respuesta.
Hogares con menores de 15	Proporción de hogares con menores de 15 años	Es una característica de composición del hogar, no una privación directa.

Variable	Medida observada	Reserva para interpretación
Estratos 1 y 2	Proporción de personas en estratos 1 y 2	Proxy administrativo con cobertura territorial desigual; MSA individual reportado de 0,414.

Los diagnósticos disponibles son preliminares (KMO global 0,642; Bartlett $\chi^2 = 4664, 873, 21$ grados de libertad, $p < 0, 001$). No certifican por sí mismos la pertinencia del análisis ni sustituyen la revisión conceptual, la evaluación de estabilidad y la decisión sobre balance entre dominios. El IPM Municipal se reserva para análisis descriptivos y eventual contraste externo; cualquier asociación debe interpretarse considerando el solapamiento conceptual de sus privaciones con variables censales.

B Inventario reproducible de datos y productos

Este inventario resume archivos presentes en el repositorio al momento de la revisión. Las rutas se expresan desde la raíz del proyecto; el detalle vigente se encuentra en cada directorio.

B.1 Tablas intermedias

`datos/intermedio/` contiene diez tablas derivadas del flujo de preparación:

- `contexto_1PM.csv`; `contexto_1V.csv`; `control_nacional.csv`.
- `hogares_1HM_2HM.csv`; `ipm_municipal_ancho.csv`.
- `persona_demo_17PM.csv`; `persona_social_5PM.csv`.
- `viviendas_6V.csv`; `viviendas_8V.csv`; `viviendas_10V.csv`.

B.2 Bases de trabajo

`datos/trabajo/` contiene nueve archivos, incluidos `demografico_1PM_completo_largo.csv`, `denominadores_edad_quinquenal.csv`, `denominadores_municipales.csv`, `indicadores_municipales_base` `indicadores_municipales_base_valida.csv`, `ipm_municipal_ancho.csv`, `matriz_pca_base_valida.csv`, `matriz_pca_z.csv` y `matriz_pca.csv`. La matriz es candidata: no equivale a un IVS ni demuestra que se haya ejecutado PCA.

B.3 Verificación de consolidados

`resultados/verificacion_consolidados/` contiene seis productos: `chequeos_consistencia.csv`, `cobertura_municipal_por_hoja.csv`, `discrepancias.csv`, `inventario_hojas_columnas.csv`, `mapa_llaves.csv` y `universo_municipal_maestro.csv`. El universo incluye códigos territoriales y no debe rotularse como 1.122 municipios.

B.4 Resultados y auditoría

`resultados/base_trabajo/` conserva especificaciones, estadísticas descriptivas, diagnósticos de aptitud, correlaciones, análisis de no respuesta y archivos de control. Entre los productos centrales están `especificacion_indicadores.csv`, `estadisticos_indicadores.csv`, `varianza_indicadores.csv`, `diagnosticos_aptitud.csv`, `kmo_por_indicador.csv`, `correlaciones_pares.csv`, `sensibilidad_nr.csv`, `validaciones.csv` y `crosswalk_enlace.csv`. Consulte el directorio para el inventario actualizado.

`resultados/auditoria_estadistica/` contiene salidas de auditoría, incluido `09_resumen_auditoria.csv`

Los diagnósticos apoyan la revisión, pero no sustituyen la decisión metodológica sobre las variables ni constituyen una estimación del índice.

B.5 Scripts

Los scripts reproducibles principales están en `R/`. Consulte sus archivos vigentes para conocer la configuración, las etapas de construcción y auditoría, y las funciones auxiliares. Se evita fijar aquí una lista de pruebas o productos generados que no haya sido verificada contra el estado actual del repositorio.